

Universidade do Minho
Mestrado em Engenharia Informática

Unidade Curricular de
Projeto de Sistemas de Data Warehousing

Ano Lectivo de 2025/2026, 2º Semestre

Monitorização e Previsão de Cheias

Diogo Cunha (PG60248), Diogo Pinto (PG61515),
Mariana Pinto (PG61534), Miguel Pinto (PG57893)

Fevereiro, 2026

Data de Recepção	
Responsável	
Avaliação	
Observações	

Monitorização e Previsão de Cheias

Diogo Cunha (PG60248), Diogo Pinto (PG61515),

Mariana Pinto (PG61534), Miguel Pinto (PG57893)

Fevereiro, 2026

Resumo

Este relatório apresenta o desenvolvimento de um sistema de suporte à decisão para monitorização e previsão de cheias na bacia do rio Mondego, no contexto da organização fictícia HidroVigilância, S.A. O trabalho segue uma abordagem de data lakehouse, estruturando os dados em camadas Bronze, Silver e Gold, com o objetivo de integrar, tratar e disponibilizar informação hidrometeorológica para análise operacional, histórica e preditiva.

A solução desenvolvida assenta na integração de dados provenientes do SNIRH, complementados por ficheiros de referência sobre estações, localização e tipos de evento. A partir destas fontes foi definido um modelo dimensional em constelação, composto por três tabelas de factos: `Fact_Medicoes`, `Fact_Indicadores` e `Fact_Evento_Cheia`. Estas estruturas são suportadas por dimensões conformadas de tempo, estação, localização e variável monitorizada, bem como por uma dimensão especializada de tipo de evento.

O sistema de povoamento foi implementado com recurso a processos ETL em SQL Server Integration Services, garantindo a passagem dos dados pelas diferentes camadas, a aplicação de regras de validação, a resolução de chaves e o carregamento do armazém de dados. Sobre a camada Gold foram desenvolvidos dashboards em Power BI para monitorização operacional, análise de indicadores históricos e exploração de eventos candidatos de cheia.

Por fim, foi construída uma componente de previsão de alerta hidrológico a 24 horas, utilizando dados da camada Gold e modelos de classificação binária em Python. A formulação final, baseada nas variáveis hidrológicas, obteve o melhor desempenho com uma Random Forest, atingindo F1-score de 0,8119 e recall de 0,8834. Os resultados demonstram que o armazém de dados desenvolvido suporta não só exploração histórica e visualização, mas também processos de aquisição de conhecimento orientados à antecipação de risco.

Palavras-chave: Data Warehousing, Data Lakehouse, ETL, Cheias, Monitorização Hidrológica, Power BI, Machine Learning, Previsão de Risco

Índice Geral

1. Definição do Sistema 6
   1.1 Contexto de Aplicação 6
   1.2 Motivação e Objetivos do Trabalho 7
   1.3 Análise da Viabilidade do Processo 10
   1.4 Recursos e Equipa de Trabalho 12
   1.5 Plano de Execução do Projeto 15
2. Levantamento e Análise de Requisitos 19
   2.1 Método Adotado 19
   2.2 Organização dos Requisitos Levantados 20
   2.3 Análise e Validação Geral dos Requisitos 29
3. Modelação Dimensional de Dados 32
   3.1 Apresentação da Abordagem Realizada 32
   3.2 A Matriz de Decisão 35
   3.3 Definição e Caracterização de Dimensões 39
   3.4 Definição e Caracterização das Tabelas de Factos e Respetivos Grãos 50
   3.5 Configuração dos Esquemas 59
   3.6 As Vistas dos Agentes de Decisão 63
   3.7 Modelo Lógico 65
4. Arquitetura Geral do Sistema 72
   4.1 Apresentação Geral 72
   4.2 Fontes de Dados 75
   4.3 Área de Preparação de dados 79
   4.4 O Armazém de Dados 82
   4.5 Exploração e Visualização de Dados 84
   4.6 Aquisição de Conhecimento 86
5. O Povoamento de Dados 88
   5.1 Apresentação da Abordagem Realizada 88
   5.2 Mapeamento de Dados 90
   5.3 Modelação do Sistema de Povoamento 94
   5.4 Implementação do Sistema de Povoamento 100
   5.5 Validação e Testes 105
6. Exploração e Análise de Dados 111
   6.1 Organização geral do sistema de dashboarding 111
   6.2 Serviços de exploração e análise implementados 112
7. Previsão de Cheias 118
   7.1 Definição do problema e compreensão dos elementos de análise envolvidos 119
   7.2 Seleção e preparação dos dados 120
   7.3 Identificação e fundamentação da técnica de análise 122
   7.4 Construção do modelo de previsão 123

7.5 Validação do desempenho do modelo 124
7.6 Avaliação dos resultados 127
8. Conclusões e Trabalho Futuro 130
8.1 Conclusões 130
8.2 Trabalho Futuro 131
Bibliografia 133
Lista de Siglas e Acrónimos 134

1. Definição do Sistema

1.1 Contexto de Aplicação

A monitorização e a previsão de cheias são críticas para a segurança de pessoas e bens, bem como para a proteção de infraestruturas e a continuidade de atividades económicas. Episódios de precipitação intensa podem provocar subidas rápidas do nível da água, exigindo acompanhamento contínuo e capacidade de análise histórica para identificar padrões e condições de risco.

No âmbito deste cenário, considera-se a implementação de um sistema de data lakehouse na HidroVigilância, S.A., uma entidade que desenvolve soluções de monitorização hidrológica e apoio à decisão para municípios, proteção civil, gestores de recursos hídricos e operadores de infraestruturas críticas. A organização disponibiliza painéis de controlo, relatórios e mecanismos de alerta, suportando a antecipação e mitigação do risco associado a cheias.

O caso de estudo é delimitado à bacia do rio Mondego, escolhida pela sua relevância operacional e pela diversidade de contextos hidrológicos presentes ao longo do seu curso, incluindo zonas de montante, albufeiras e áreas a jusante mais expostas a impactos. A ocorrência de episódios de cheia e inundação associados a este sistema fluvial reforça a pertinência de consolidar e explorar os dados disponíveis, permitindo construir análises reprodutíveis e indicadores orientados à compreensão e monitorização do fenómeno.

A atividade analítica assenta na integração de dados temporais observacionais recolhidos por estações e sensores existentes na bacia do Mondego, nomeadamente precipitação, nível hidrométrico e cota de albufeira, com informação de enquadramento mais estável, como localização das estações, organização territorial, pontos críticos e registos de ocorrências. O valor analítico resulta da capacidade de relacionar estas fontes no tempo e no espaço, assegurando consistência e comparabilidade entre observações.

A exploração destes dados suporta diferentes necessidades de utilização. Em contexto operacional, interessa acompanhar a situação corrente e detetar aproximações a limiares

críticos. Numa perspetiva tática, interessa comparar a severidade de eventos entre locais e sustentar a priorização de vigilância e intervenção. Numa perspetiva estratégica, interessa analisar recorrência e tendências históricas, bem como suportar modelos de previsão de risco a curto prazo, relacionando precipitação observada com resposta hidrométrica.

Adicionalmente, este domínio apresenta desafios próprios associados à variabilidade e à qualidade dos dados. Leituras incompletas, falhas temporárias de sensores, diferenças de granularidade temporal entre fontes, desfasamentos de registo e valores extremos podem introduzir ruído e dificultar a análise caso não exista tratamento adequado. Acresce que a natureza temporal e sequencial do problema exige preservação histórica consistente, rastreabilidade das transformações aplicadas e capacidade de distinguir dados brutos, dados tratados e estruturas orientadas à análise.

Perante este enquadramento, a implementação de um sistema de suporte à decisão baseado numa abordagem de data lakehouse revela-se adequada ao caso de estudo da bacia do rio Mondego. Esta abordagem permite integrar dados provenientes das redes hidrométrica e meteorológica, manter diferentes estados de processamento em camadas com funções distintas e disponibilizar uma base consistente para análise histórica, monitorização operacional, produção de indicadores e desenvolvimento de modelos preditivos. Assim, o projeto visa fornecer à HidroVigilância, S.A. uma infraestrutura analítica capaz de organizar e explorar informação relacionada com o rio Mondego, transformando dados dispersos em conhecimento útil para a monitorização e previsão de cheias.

1.2 Motivação e Objetivos do Trabalho

A motivação para o desenvolvimento do sistema resulta de um problema prático associado à gestão do risco de cheia no rio Mondego: a tomada de decisão depende da interpretação conjunta de informação meteorológica, hidrológica e geográfica, mas essa informação tende a encontrar-se dispersa por diferentes sistemas, com estruturas heterogéneas e periodicidades

de atualização distintas. Esta fragmentação dificulta a realização de análises consistentes e torna mais difícil responder em tempo útil a situações potencialmente críticas.

Em contexto operacional, os responsáveis pela monitorização e gestão do risco necessitam frequentemente de responder a questões como: se os valores observados representam uma situação anómala, se determinadas zonas se encontram próximas de limiares críticos ou se já ocorreram eventos semelhantes em condições comparáveis. Quando a informação relevante se encontra distribuída por diferentes fontes e formatos, estas análises tornam-se difíceis de realizar de forma sistemática, exigindo recolha manual de dados, tratamento ad hoc e cruzamento de múltiplos registos.

Neste contexto, a criação de um sistema de suporte à decisão baseado numa abordagem de data lakehouse justifica-se por três necessidades fundamentais. Em primeiro lugar, a integração de dados provenientes de diferentes origens num repositório comum, permitindo analisar conjuntamente medições hidrológicas, dados meteorológicos e informação geográfica associadas à bacia do Mondego. Em segundo lugar, a preservação e organização do histórico de observações, possibilitando o estudo da evolução do fenómeno ao longo do tempo e a identificação de padrões ou recorrências. Em terceiro lugar, a garantia de confiabilidade da informação utilizada em análises e indicadores, assegurando que os dados são validados, documentados e rastreáveis.

Para responder às necessidades identificadas no contexto do problema, o sistema de suporte à decisão foi desenvolvido com um conjunto de objetivos concretos, diretamente relacionados com as necessidades de análise e com as decisões que se pretende suportar.

- **Centralizar e integrar dados relevantes num repositório analítico.** A integração de diferentes fontes permite relacionar, de forma consistente, informação meteorológica, hidrológica e geográfica. Desta forma, evita-se que cada fonte represente apenas uma visão parcial do fenómeno e garante-se uma base comum para todas as análises realizadas.
- **Disponibilizar histórico estruturado e suportar análise temporal e espacial.** A identificação de padrões associados a eventos de cheia depende da existência de séries temporais consolidadas e comparáveis. Em paralelo, a dimensão espacial permite analisar diferenças

entre zonas da bacia do Mondego, identificar áreas mais vulneráveis e compreender o comportamento do fenómeno em diferentes contextos territoriais.

- **Produzir indicadores (KPI) relevantes para monitorização e gestão do risco.** A transformação de observações brutas em métricas comparáveis, como precipitação acumulada em diferentes janelas temporais, níveis máximos registados, variação entre medições consecutivas ou frequência de excedência de limiares, facilita a interpretação do estado do sistema e o acompanhamento da evolução de eventos.
- **Disponibilizar mecanismos de visualização e exploração analítica através de dashboards.** Interfaces visuais e interativas permitem que os agentes de decisão explorem a informação de forma rápida e orientada, utilizando filtros, hierarquias e comparações temporais ou espaciais para interpretar tendências, identificar anomalias e compreender a evolução das variáveis monitorizadas.
- **Suportar a construção de modelos simples de previsão de risco a curto prazo.** A utilização de modelos interpretáveis permite antecipar cenários potencialmente críticos com base em dados recentes e históricos, contribuindo para uma atuação preventiva e informada.

A concretização destes objetivos permite suportar um conjunto de decisões relevantes no domínio da monitorização e gestão do risco de cheia. Entre estas decisões incluem-se a identificação de zonas que se aproximam de limiares críticos, a priorização de áreas que exigem maior atenção ou monitorização reforçada, a comparação entre eventos atuais e episódios históricos semelhantes e a avaliação da evolução de indicadores de risco ao longo do tempo.

Desta forma, o sistema de suporte à decisão proposto não se limita ao armazenamento de dados, mas procura transformar informação dispersa em conhecimento estruturado e operacionalmente útil. Ao integrar dados, preservar histórico, produzir indicadores e disponibilizar mecanismos de análise e previsão, o sistema pretende apoiar de forma consistente o processo de monitorização e antecipação de eventos de cheia no contexto do rio Mondego, no âmbito das atividades desenvolvidas pela HidroVigilância, S.A.

1.3 Análise da Viabilidade do Processo

A viabilidade do projeto pode ser analisada a partir de três dimensões complementares: a viabilidade técnica da solução proposta, a viabilidade associada à disponibilidade e natureza dos dados e a viabilidade de execução do projeto no contexto em que se insere. A análise destas dimensões permite justificar que o desenvolvimento do sistema de suporte à decisão proposto é realizável e adequado ao problema identificado.

Do ponto de vista técnico, o projeto é viável porque se apoia em abordagens e tecnologias consolidadas no domínio dos sistemas de armazéns de dados. A arquitetura proposta baseia-se numa organização em camadas típica de soluções de data lakehouse, na qual os dados são inicialmente recolhidos na sua forma bruta, posteriormente tratados e preparados e, por fim, organizados numa estrutura analítica otimizada para consulta. Esta separação entre extração, preparação e consumo analítico permite reduzir dependências entre componentes e facilita a evolução progressiva do sistema.

Um exemplo concreto desta viabilidade técnica é a utilização de processos de integração de dados (ETL) para recolher e transformar informação proveniente de diferentes fontes, como medições meteorológicas, dados hidrológicos ou informação geográfica. Estes processos permitem limpar dados incompletos, uniformizar formatos temporais e espaciais e produzir conjuntos de dados consistentes para análise. A orquestração destes processos foi implementada com recurso ao Microsoft Visual Studio e ao SQL Server Integration Services (SSIS), garantindo a definição estruturada dos fluxos ETL, a separação entre etapas de extração, transformação e carregamento, e a possibilidade de reproduzir e validar os processos de povoamento do sistema. A utilização do Power BI para visualização e exploração analítica sobre o armazém de dados constitui igualmente uma prática comum em sistemas de suporte à decisão, permitindo transformar os dados integrados em dashboards e indicadores acessíveis aos utilizadores.

A viabilidade técnica é também reforçada pela adequação do domínio à modelação dimensional. O fenómeno de monitorização de cheias pode ser representado através de tabelas de

factos associadas a observações temporais, medições de precipitação, nível hidrométrico ou cota de albufeira, e dimensões de contexto, como tempo, localização geográfica, estação de monitorização ou tipo de variável observada. Esta estrutura permite organizar os dados de forma consistente, definir claramente o grão das observações e suportar diferentes níveis de análise, como agregações por período temporal ou comparações entre zonas geográficas.

A viabilidade associada aos dados resulta do facto de o domínio de estudo assentar em variáveis amplamente utilizadas na monitorização hidrológica e meteorológica. Variáveis como precipitação, nível hidrométrico, cota de albufeira e localização das estações são frequentemente registadas em séries temporais e constituem a base para análise histórica e construção de indicadores de risco. A fonte operacional principal considerada na implementação foi o SNIRH, complementada por ficheiros de referência para localização das estações e tipos de evento. O IPMA e o SNIAmb foram considerados fontes complementares relevantes para evolução futura, mas não constituem fontes centrais do povoamento implementado nesta versão do sistema. Mesmo em contextos onde existem falhas de registo ou diferenças de granularidade temporal entre fontes, estas situações podem ser tratadas através de processos de limpeza e transformação de dados na camada de preparação.

Por fim, a viabilidade de execução do projeto depende da forma como o desenvolvimento é planeado e organizado. Neste contexto, é fundamental delimitar o âmbito do sistema e adotar uma abordagem incremental. O desenvolvimento inicia-se com um núcleo funcional que inclui a integração de um conjunto reduzido de fontes de dados, a definição de um modelo dimensional base e a construção de um conjunto inicial de indicadores e dashboards. Posteriormente, o sistema evolui através da introdução de novas fontes de dados, do enriquecimento das análises e da incorporação de componentes adicionais, como modelos de previsão.

Apesar da viabilidade global identificada, existem alguns riscos técnicos associados ao volume de dados e à granularidade temporal das observações. Registos horários para múltiplas estações e variáveis podem aumentar significativamente o volume de dados armazenados e afetar o desempenho de determinadas consultas analíticas. Este risco é mitigado através da separação entre a tabela de factos transacional, que preserva o detalhe horário, e uma tabela

de factos derivada com indicadores pré-agregados ao nível mensal, evitando que as consultas analíticas mais frequentes recorram ao nível de detalhe máximo.

Considerando estes fatores, conclui-se que o desenvolvimento do sistema de suporte à decisão proposto é tecnicamente realizável, dispõe de fontes de dados adequadas e pode ser executado de forma controlada através de uma abordagem incremental. Estas condições justificam o avanço para as etapas seguintes de levantamento de requisitos, modelação dimensional e definição da arquitetura do sistema.

1.4 Recursos e Equipa de Trabalho

A execução do projeto requer um conjunto de recursos humanos e materiais, nomeadamente competências técnicas, ferramentas de desenvolvimento e infraestrutura de armazenamento e processamento de dados. A identificação e justificação destes recursos é necessária porque um sistema de suporte à decisão baseado em data warehousing envolve diferentes tipos de tarefas, como integração de dados, modelação dimensional, controlo de qualidade, visualização de informação e validação analítica. Cada uma destas tarefas exige competências específicas e ferramentas adequadas para a sua realização.

Relativamente aos recursos humanos, importa definir as competências e responsabilidades envolvidas, assegurando a cobertura das diferentes fases do desenvolvimento do sistema. A equipa de trabalho responsável pelo desenvolvimento do projeto é constituída pelos seguintes elementos:

- **Diogo Cunha**
- **Diogo Pinto**
- **Mariana Pinto**
- **Miguel Pinto**

A organização da equipa baseia-se na identificação de responsabilidades técnicas associadas às diferentes componentes do sistema de data lakehouse a desenvolver. Estas responsabilidades representam funções necessárias ao projeto e não uma divisão rígida e

exclusiva do trabalho por elemento, uma vez que o desenvolvimento foi realizado de forma colaborativa e com participação transversal de toda a equipa nas diferentes etapas.

- **Modelação dimensional:** definição do grão das observações, identificação das tabelas de factos e dimensões, estabelecimento de hierarquias e definição das regras de agregação das medidas. Esta função é determinante porque um modelo dimensional incorreto pode conduzir a indicadores inconsistentes e a estruturas analíticas difíceis de manter e evoluir.
- **Integração de dados (ETL):** implementação dos processos de extração, limpeza, transformação e carregamento dos dados provenientes das diferentes fontes de informação. Esta responsabilidade é crítica porque a integração de dados é o mecanismo que assegura a consistência do repositório analítico e a repetibilidade dos processos de processamento de dados.
- **Qualidade de dados e gestão de metadados:** definição de validações, regras de tratamento de valores em falta, processos de auditoria e mecanismos de documentação das transformações aplicadas aos dados. Esta função garante confiança na informação utilizada e permite rastrear a origem e evolução dos dados no sistema.
- **Visualização e exploração analítica:** desenvolvimento de dashboards, operacionalização de indicadores de desempenho (KPI) e validação dos resultados obtidos nas análises. Este papel é essencial para transformar estruturas de dados e métricas analíticas em informação compreensível e útil para os agentes de decisão.
- **Previsão e validação:** desenvolvimento de modelos simples e interpretáveis para estimar o risco de cheia, definição de variáveis derivadas relevantes e avaliação do desempenho dos modelos utilizados. Esta responsabilidade é importante porque a utilização operacional de modelos preditivos exige validação adequada e capacidade de interpretação dos resultados produzidos.

Embora estas funções permitam estruturar as necessidades técnicas do projeto, o trabalho foi desenvolvido de forma colaborativa entre todos os elementos da equipa. Assim, as várias componentes do sistema foram discutidas, revistas e validadas em conjunto, assegurando

coerência global nas decisões tomadas e reduzindo o risco de fragmentação entre fases de desenvolvimento.

Relativamente aos recursos materiais, foram utilizados os seguintes meios técnicos para suportar a implementação do sistema de data lakehouse e as diferentes etapas do ciclo de extração, armazenamento, análise e visualização de dados.

- **Microsoft Visual Studio e SQL Server Integration Services (SSIS):** ambiente utilizado para a implementação dos processos ETL responsáveis pela extração, transformação e carregamento dos dados entre as camadas Bronze, Silver e Gold. Esta opção permitiu modelar fluxos de dados, aplicar regras de validação, normalizar medições, calcular medidas derivadas, resolver chaves estrangeiras e controlar a sequência de povoamento das dimensões e tabelas de factos.
- **Microsoft SQL Server:** motor relacional utilizado para materializar as camadas Bronze, Silver e Gold do sistema, bem como o modelo dimensional final. A separação por schemas permitiu representar a lógica lakehouse em camadas dentro de uma infraestrutura relacional, preservando a distinção entre dados brutos, dados preparados e dados analíticos.
- **Python com bibliotecas pandas, numpy, scikit-learn e matplotlib:** linguagem de programação utilizada na preparação analítica, exploração dos dados e desenvolvimento da componente de previsão em ambiente Jupyter. A sua flexibilidade permitiu construir datasets de modelação, criar variáveis temporais, treinar modelos de classificação e avaliar métricas de desempenho para previsão de alerta hidrológico.
- **Power BI:** plataforma de visualização e análise de dados da Microsoft, utilizada para a construção dos dashboards e para a exploração analítica da informação armazenada na camada Gold. Constitui o principal meio de interação entre os utilizadores e o sistema, com suporte a conector SQL nativo para o SQL Server e visualização de indicadores associados a limiares e níveis de alerta calculados no processo ETL.

A combinação destes recursos humanos e tecnológicos permite estruturar o desenvolvimento do sistema de forma organizada, assegurando que as diferentes componentes do

sistema de suporte à decisão são concebidas, implementadas e validadas de forma consistente ao longo do projeto.

1.5 Plano de Execução do Projeto

A execução do projeto foi planeada de forma faseada e incremental, em coerência com a natureza do sistema de suporte à decisão a desenvolver e com a necessidade de articular atividades de análise, modelação, integração de dados, visualização e previsão.

Numa primeira fase, foi previsto o enquadramento do problema e a definição do sistema, incluindo a contextualização do domínio, a delimitação do caso de estudo à bacia do rio Mondego, a identificação da motivação do projeto e a análise da sua viabilidade. Esta etapa constitui a base conceptual do trabalho e justifica as opções adotadas nas fases seguintes.

Numa segunda fase, foi previsto o levantamento e análise de requisitos, com identificação dos perfis de decisão envolvidos, caracterização das suas necessidades de informação e validação dos requisitos considerados exequíveis com base nos dados potencialmente disponíveis. Esta etapa estabelece a ponte entre o problema de decisão e a modelação do sistema.

Numa terceira fase, foi prevista a modelação dimensional do armazém de dados, incluindo a definição da matriz de decisão, a caracterização das dimensões, a definição das tabelas de factos e respetivos grãos, a configuração do esquema global do sistema analítico e a elaboração do modelo lógico. Esta etapa condiciona tanto a arquitetura como o processo de povoamento.

Numa quarta fase, foi prevista a definição da arquitetura geral do sistema, identificando as fontes de dados, a área de preparação, a estrutura do armazém de dados, os mecanismos de exploração e a componente de aquisição de conhecimento.

Numa quinta fase, foi previsto o desenho e implementação do sistema de povoamento, incluindo o mapeamento source-to-target, a modelação do pipeline de integração, a implementação dos processos ETL e a definição de mecanismos de validação e teste.

Numa sexta fase, foi previsto o desenvolvimento dos dashboards e serviços de exploração analítica, orientados às necessidades dos diferentes perfis de decisão identificados. Em paralelo, foi planeada a preparação da componente de previsão, com seleção e preparação dos dados, escolha da técnica analítica, construção do modelo e avaliação do seu desempenho.

Por fim, numa última fase, foi prevista a validação global do sistema, a consolidação do relatório e a revisão final dos artefactos produzidos. Esta fase incluiu também a análise crítica do trabalho desenvolvido, bem como a identificação de limitações e possibilidades de trabalho futuro.

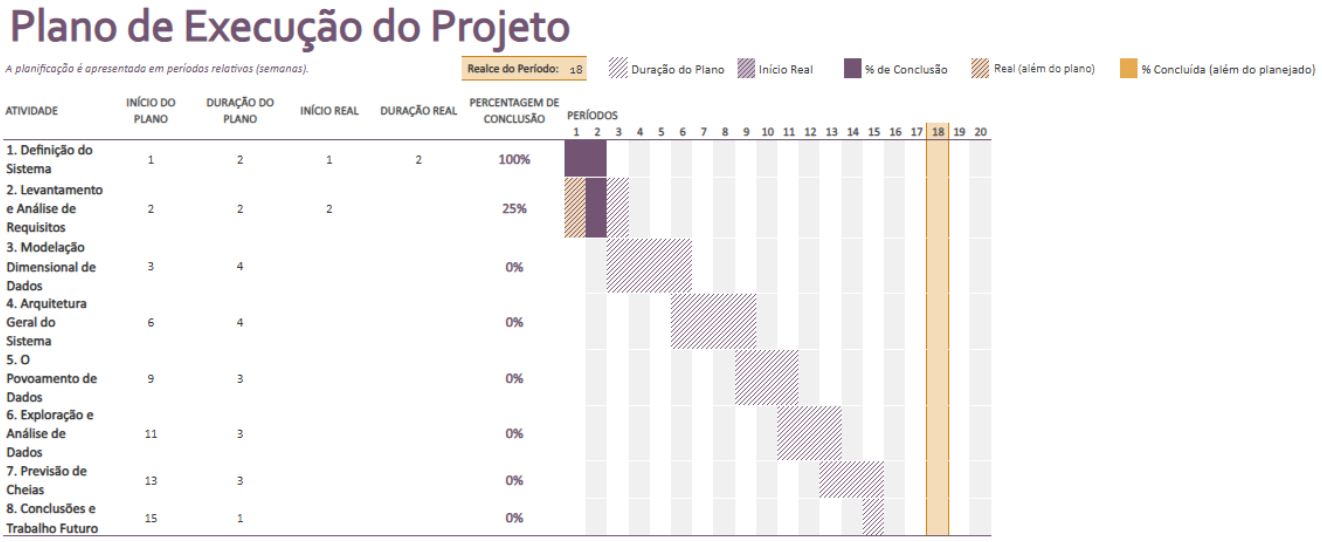


Figura 1: Diagrama de Gantt do plano previsto de execução do projeto

O diagrama de Gantt previsto apresenta a distribuição inicial das atividades ao longo das diferentes fases de desenvolvimento, evidenciando a sequência lógica entre levantamento de requisitos, modelação, arquitetura, povoamento, exploração analítica, previsão e consolidação final. Esta planificação foi definida em períodos relativos, permitindo estruturar o trabalho de forma incremental e identificar dependências entre tarefas.

Execução final do projeto

Após a conclusão do trabalho, foi elaborada uma segunda versão do diagrama de Gantt, com a execução efetiva das principais fases do projeto. Esta comparação permite analisar os desvios entre o planeamento inicial e o trabalho efetivamente realizado, identificando as etapas que exigiram maior esforço do que o previsto.

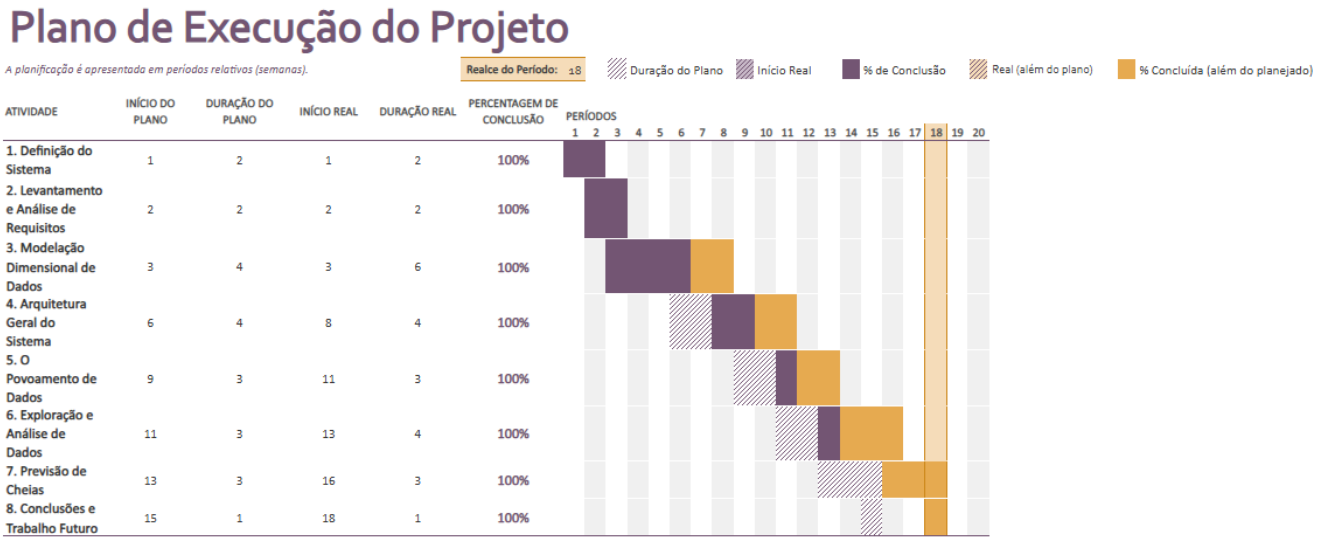


Figura 2: Diagrama de Gantt da execução final do projeto

A execução final manteve a estrutura faseada definida no planeamento inicial, mas revelou alguns desvios relevantes. As fases de definição do sistema e levantamento de requisitos foram concluídas de acordo com o previsto. No entanto, a modelação dimensional exigiu mais tempo do que o inicialmente estimado, devido à necessidade de rever a coerência entre a matriz de decisão, as dimensões, as tabelas de factos, o modelo lógico e os requisitos analíticos suportados.

A arquitetura geral do sistema, o povoamento de dados, a exploração analítica e a previsão foram também afetados por este ajustamento inicial, iniciando-se mais tarde do que o planeado. Ainda assim, estas fases mantiveram uma sequência coerente: primeiro foi consolidado o modelo dimensional e lógico, depois foram implementados os processos ETL e validadas as tabelas da camada Gold, e só posteriormente foram desenvolvidos os dashboards e o notebook de previsão.

A fase de exploração e análise de dados acabou por exigir ligeiramente mais tempo do que o previsto, sobretudo devido à necessidade de alinhar os dashboards com as tabelas finais da camada Gold e validar a correspondência entre vistas analíticas, requisitos e tabelas de factos. A componente de previsão foi realizada no final do projeto, depois de estabilizado o ficheiro exportado da camada Gold, permitindo construir o dataset de modelação, formular o alvo de previsão a 24 horas e avaliar os modelos desenvolvidos.

Assim, a execução final confirma que o projeto manteve a abordagem incremental inicialmente prevista, mas com redistribuição de esforço para as fases de modelação, exploração analítica e validação final. Esta evolução é coerente com a natureza do trabalho, uma vez que as decisões tomadas no modelo dimensional influenciaram diretamente o povoamento, os dashboards e a componente preditiva.

2. Levantamento e Análise de Requisitos

2.1 Método Adotado

O levantamento de requisitos foi conduzido de forma iterativa e orientada ao problema de decisão, tendo como objetivo identificar que informação, indicadores e mecanismos de exploração são necessários para suportar a monitorização e a previsão de cheias no rio Mondego. Atendendo ao facto de a organização considerada no projeto ser idealizada, o processo de levantamento foi realizado com base na definição de perfis de utilização plausíveis, construídos a partir do contexto operacional do domínio e das exigências analíticas identificadas no enunciado do trabalho.

Numa primeira etapa, foi realizada a identificação dos principais perfis de decisão envolvidos no problema. Foram considerados, em particular, três perfis principais: um perfil operacional, associado à monitorização corrente das variáveis hidrometeorológicas; um perfil tático, associado à coordenação e priorização de vigilância e intervenção; e um perfil analítico, orientado ao estudo histórico de eventos, produção de indicadores e apoio ao desenvolvimento de modelos de previsão. Esta caracterização permitiu enquadrar as necessidades de informação em diferentes horizontes temporais e com diferentes graus de detalhe.

Numa segunda etapa, foram conduzidas sessões de elicitação de requisitos sob a forma de entrevistas semiestruturadas simuladas, centradas em decisões concretas que o sistema deverá suportar. O objetivo destas sessões foi identificar perguntas recorrentes no contexto de monitorização de cheias, tais como a deteção de aproximação a limiares críticos, a comparação com episódios históricos semelhantes, a identificação de zonas mais vulneráveis e a necessidade de antecipar evolução de risco no curto prazo. A informação recolhida foi organizada sob a forma de necessidades de análise, indicadores desejados e mecanismos de visualização considerados relevantes.

Paralelamente, foi realizada análise documental sobre fontes de informação e materiais de apoio ao problema em estudo. Foram consultadas descrições e metadados das redes de monitorização hidrométrica e meteorológica, listas de estações, exemplos de séries tempo-

rais observacionais, documentação técnica sobre variáveis disponíveis e registos públicos relacionados com episódios recentes de cheia. Esta análise teve dois objetivos: por um lado, apoiar a formulação dos requisitos com base em elementos concretos do domínio; por outro, verificar a terminologia, unidades, periodicidades e limitações associadas às fontes de dados potencialmente utilizáveis.

Adicionalmente, foi efetuada uma análise exploratória e validação prática dos dados disponíveis, com especial atenção à cobertura temporal, granularidade, continuidade dos registos e qualidade geral da informação. Esta etapa permitiu identificar limitações relevantes, como falhas de registo, diferenças de frequência temporal, inconsistências de unidades e assimetrias entre estações. A validação prática dos dados foi importante para distinguir requisitos desejáveis de requisitos efetivamente viáveis no contexto do projeto.

Por fim, os requisitos recolhidos foram priorizados em função da sua utilidade operacional e da sua exequibilidade. Em primeiro lugar, foram considerados os requisitos indispensáveis à monitorização corrente e consulta histórica. Em segundo lugar, foram priorizados requisitos relacionados com comparação de eventos e produção de indicadores de risco. Por último, foram enquadrados requisitos mais avançados, associados à previsão de risco a curto prazo. Esta priorização foi utilizada para orientar o desenho da solução de data lakehouse e delimitar o âmbito das fases seguintes do projeto.

2.2 Organização dos Requisitos Levantados

Os requisitos levantados foram organizados de forma a facilitar a sua validação, rastreabilidade e posterior tradução para estruturas de dados, indicadores, dashboards e modelos analíticos. A organização adotada combina duas perspetivas complementares. A primeira corresponde à área de decisão ou perfil de utilização a que cada requisito diz respeito. A segunda distingue a natureza do requisito, separando requisitos de decisão, requisitos funcionais e requisitos não funcionais.

Os perfis de decisão considerados no projeto são os seguintes: operador de monitorização hidrológica, coordenador operacional de risco e analista de risco e planeamento. Esta segmentação permite representar diferentes necessidades de utilização do sistema, desde a observação corrente e reação rápida até à análise histórica e apoio à previsão.

Requisitos de Decisão

Operador de Monitorização Hidrológica

- **RD01** - O sistema deve permitir determinar, em qualquer momento, se uma estação de monitorização apresenta valores próximos ou acima dos limiares críticos definidos.
- **RD02** - O sistema deve permitir identificar rapidamente quais as estações ou zonas com maior agravamento recente das variáveis monitorizadas.
- **RD03** - O sistema deve permitir consultar a evolução temporal recente de precipitação observada, nível hidrométrico e cota de albufeira nas estações consideradas da bacia do Mondego.

Coordenador Operacional de Risco

- **RD04** - O sistema deve permitir identificar as zonas da bacia do Mondego que exijam monitorização reforçada com base nos dados observados.
- **RD05** - O sistema deve permitir comparar a severidade do evento atual entre diferentes locais da bacia.
- **RD06** - O sistema deve permitir avaliar se as condições observadas justificam o escalonamento da resposta operacional.

Analista de Risco e Planeamento

- **RD07** - O sistema deve permitir explorar possíveis padrões temporais entre precipitação observada e variáveis hidrométricas registadas nas estações selecionadas, incluindo eventuais desfasamentos entre zonas da bacia.
- **RD08** - O sistema deve permitir avaliar a recorrência e sazonalidade de episódios de cheia ao longo do histórico disponível.

- **RD09** - O sistema deve permitir selecionar variáveis e períodos históricos relevantes para apoio ao desenvolvimento de modelos de previsão de risco.

Requisitos Funcionais

Operador de Monitorização Hidrológica

- **RF01** - O sistema deve disponibilizar consulta de dados por estação e por intervalo temporal configurável.
- **RF02** - O sistema deve apresentar séries temporais recentes das variáveis monitorizadas e indicadores de variação associados, incluindo a variação entre medições consecutivas.
- **RF03** - O sistema deve permitir filtragem por variável observada, estação e zona geográfica.
- **RF04** - O sistema deve sinalizar automaticamente excedências de limiares críticos com base no nível de alerta classificado no processo de integração de dados.

Coordenador Operacional de Risco

- **RF05** - O sistema deve disponibilizar dashboards comparativos entre estações e zonas da bacia.
- **RF06** - O sistema deve apresentar indicadores agregados por período temporal e por localização geográfica.
- **RF07** - O sistema deve permitir a comparação entre o evento atual e eventos históricos com características semelhantes.
- **RF08** - O sistema deve evidenciar áreas prioritárias com base em regras e indicadores previamente definidos.

Analista de Risco e Planeamento

- **RF09** - O sistema deve permitir a análise histórica comparável das medições, indicadores e eventos candidatos de cheia por estação, variável, localização e período temporal.
- **RF10** - O sistema deve permitir agregações temporais em diferentes granularidades, incluindo hora, semana, mês, trimestre, ano e estação do ano.
- **RF11** - O sistema deve apoiar a extração de subconjuntos de dados para análise exploratória e desenvolvimento de modelos.

- **RF12** - O sistema deve disponibilizar indicadores históricos e medidas derivadas, como precipitação acumulada por período, nível máximo, frequência de excedência de limiares e variação entre medições consecutivas.

Requisitos Não Funcionais

Operador de Monitorização Hidrológica

- **RNF01** - A origem e o instante de cada observação devem ser rastreáveis em qualquer ponto do sistema.
- **RNF02** - Os dados presentes nas camadas de análise devem refletir de forma consistente as observações mais recentes disponíveis.
- **RNF03** - A apresentação visual de estados críticos deve ser clara e imediatamente interpretável pelo utilizador.

Coordenador Operacional de Risco

- **RNF04** - Os dados utilizados em comparações entre estações e zonas devem ser consistentes do ponto de vista espacial e temporal.
- **RNF05** - Os tempos de resposta das consultas nos dashboards devem ser adequados para utilização em contexto operacional.
- **RNF06** - Todos os indicadores apresentados devem estar documentados e ser interpretáveis sem conhecimento técnico aprofundado do sistema.

Analista de Risco e Planeamento

- **RNF07** - O sistema deve preservar o histórico completo de observações brutas, independentemente das agregações aplicadas nas camadas analíticas.
- **RNF08** - A qualidade, completude e validade dos dados disponíveis devem estar documentadas por fonte, ficheiro, período e etapa de processamento.
- **RNF09** - Todas as transformações aplicadas aos dados devem ser documentadas e reproduzíveis, permitindo replicar qualquer resultado analítico obtido.

Requisito	Descrição	Vista	Validação	Anomalias Detetadas	Ação Corretiva
RD01	O sistema deve permitir determinar, em qualquer momento, se uma estação apresenta valores próximos ou acima dos limiares críticos definidos.	Operador de Monitorização Hidrológica	Validado	Nenhuma	-
RD02	O sistema deve permitir identificar rapidamente quais as estações ou zonas com maior agravamento recente das variáveis monitorizadas.	Operador de Monitorização Hidrológica	Validado	Nenhuma	-
RD03	O sistema deve permitir consultar a evolução temporal recente de precipitação observada, nível hidrométrico e cota de albufeira nas estações consideradas da bacia do Mondego.	Operador de Monitorização Hidrológica	Reformulado	Formulação inicial genérica; variáveis disponíveis dependem das fontes reais acessíveis	Restringido às variáveis efetivamente disponíveis no SNIRH para a bacia do Mondego
RD04	O sistema deve permitir identificar as zonas da bacia do Mondego que exijam monitorização reforçada com base nos dados observados.	Coordenador Operacional de Risco	Validado	Nenhuma	-
RD05	O sistema deve permitir comparar a severidade do evento atual entre diferentes locais da bacia.	Coordenador Operacional de Risco	Reformulado	Âmbito inicial demasiado abrangente	Restringido às estações da bacia do Mondego
RD06	O sistema deve permitir avaliar se as condições observadas justificam o	Coordenador Operacional de Risco	Validado	Nenhuma	-

	escalonamento da resposta operacional.				
RD07	O sistema deve permitir explorar possíveis padrões temporais entre precipitação observada e variáveis hidrométricas registadas nas estações selecionadas, incluindo eventuais desfasamentos entre zonas da bacia.	Analista de Risco e Planeamento	Reformulado	Formulação inicial demasiado genérica; desfasamento temporal depende de dados com cobertura suficiente	Reformulado para não pressupor relações causais; limitado a estações com cobertura adequada
RD08	O sistema deve permitir avaliar a recorrência e sazonalidade de episódios de cheia ao longo do histórico disponível.	Analista de Risco e Planeamento	Validado	Nenhuma	-
RD09	O sistema deve permitir selecionar variáveis e períodos históricos relevantes para apoio ao desenvolvimento de modelos de previsão de risco.	Analista de Risco e Planeamento	Restringido	Dependência de dados com cobertura temporal não garantida	Limitado a variáveis e períodos com cobertura adequada nas fontes selecionadas
RF01	O sistema deve disponibilizar consulta de dados por estação e por intervalo temporal configurável.	Operador de Monitorização Hidrológica	Validado	Nenhuma	-
RF02	O sistema deve apresentar séries temporais recentes das variáveis monitorizadas e indicadores de variação associados, incluindo a variação entre medições consecutivas.	Operador de Monitorização Hidrológica	Reformulado	Formulação inicial não explicitava a variação entre medições; esta medida é pré-calculada no ETL	Explicitada a variação entre medições consecutivas como medida

					derivada disponível
RF03	O sistema deve permitir filtragem por variável observada, estação e zona geográfica.	Operador de Monitorização Hidrológica	Validado	Nenhuma	-
RF04	O sistema deve sinalizar automaticamente excedências de limiares críticos com base no nível de alerta classificado no processo de integração de dados.	Operador de Monitorização Hidrológica	Reformulado	Formulação inicial referia leituras anómalas e falhas de registo; a implementação usa nivel_alerta INT pré-calculado no ETL	Restringido à sinalização de criticidade via nivel_alerta; qualidade dos dados é tratada na camada Silver
RF05	O sistema deve disponibilizar dashboards comparativos entre estações e zonas da bacia.	Coordenador Operacional de Risco	Validado	Nenhuma	-
RF06	O sistema deve apresentar indicadores agregados por período temporal e por localização geográfica.	Coordenador Operacional de Risco	Validado	Nenhuma	-
RF07	O sistema deve permitir a comparação entre o evento atual e eventos históricos com características semelhantes.	Coordenador Operacional de Risco	Restringido	Dependência de histórico extenso e homogéneo não garantido	Limitado a eventos com cobertura histórica suficiente nas fontes selecionadas
RF08	O sistema deve evidenciar áreas prioritárias com base em regras e	Coordenador Operacional de Risco	Validado	Nenhuma	-

	indicadores previamente definidos.				
RF09	O sistema deve disponibilizar um histórico consolidado e comparável de observações hidrométricas e meteorológicas.	Analista de Risco e Planeamento	Validado	Nenhuma	-
RF10	O sistema deve permitir agregações temporais em diferentes granularidades, incluindo hora, semana, mês, trimestre, ano e estação do ano.	Analista de Risco e Planeamento	Validado	Nenhuma	-
RF11	O sistema deve apoiar a extração de subconjuntos de dados para análise exploratória e desenvolvimento de modelos.	Analista de Risco e Planeamento	Validado	Nenhuma	-
RF12	O sistema deve disponibilizar indicadores históricos e medidas derivadas, como precipitação acumulada por período, nível máximo, frequência de excedência de limiares e variação entre medições consecutivas.	Analista de Risco e Planeamento	Reformulado	Formulação inicial demasiado vaga; medidas derivadas devem corresponder ao modelo físico implementado	Explicitadas as medidas derivadas presentes no modelo físico: variacao_valor, precipitacao_acumulada, nivel_maximo_periodo, num_excedencias_limiar
RNF01	A origem e o instante de cada observação devem ser rastreáveis em qualquer ponto do sistema.	Operador de Monitorização Hidrológica	Validado	Nenhuma	-
RNF02	Os dados presentes nas camadas de análise devem refletir de forma consistente as observações mais recentes disponíveis.	Operador de Monitorização Hidrológica	Reformulado	Formulação inicial demasiado vaga - “atualização consistente dos dados”	Reformulado para especificar a consistência entre

					camadas analíticas e observações mais recentes
RNF03	A apresentação visual de estados críticos deve ser clara e imediatamente interpretável pelo utilizador.	Operador de Monitorização Hidrológica	Validado	Nenhuma	-
RNF04	Os dados utilizados em comparações entre estações e zonas devem ser consistentes do ponto de vista espacial e temporal.	Coordenador Operacional de Risco	Validado	Nenhuma	-
RNF05	Os tempos de resposta das consultas nos dashboards devem ser adequados para utilização em contexto operacional.	Coordenador Operacional de Risco	Validado	Nenhuma	-
RNF06	Todos os indicadores apresentados devem estar documentados e ser interpretáveis sem conhecimento técnico aprofundado do sistema.	Coordenador Operacional de Risco	Validado	Nenhuma	-
RNF07	O sistema deve preservar o histórico completo de observações brutas, independentemente das agregações aplicadas nas camadas analíticas.	Analista de Risco e Planeamento	Validado	Nenhuma	-
RNF08	A qualidade, completude e validade dos dados disponíveis devem estar documentadas por fonte,	Analista de Risco e Planeamento	Reformulado	Formulação inicial demasiado genérica, apenas por fonte e por período	Explicitado o nível de detalhe esperado para documen-

	ficheiro, período e etapa de processamento.				tação de qualidade: por fonte, ficheiro, período e etapa ETL
RNF09	Todas as transformações aplicadas aos dados devem ser documentadas e reproduzíveis, permitindo replicar qualquer resultado analítico obtido.	Analista de Risco e Planeamento	Validado	Nenhuma	-

Para além desta organização por perfis de decisão, os requisitos foram também revistos quanto à sua viabilidade com base nos dados efetivamente disponíveis. Este processo permitiu remover redundâncias, reformular requisitos demasiado vagos e delimitar o âmbito do sistema a funcionalidades compatíveis com as fontes de dados selecionadas para o caso de estudo do rio Mondego. A estrutura final dos requisitos constitui, assim, a base de referência para a definição da matriz de decisão e para a modelação dimensional apresentada nos capítulos seguintes.

2.3 Análise e Validação Geral dos Requisitos

A validação dos requisitos levantados foi realizada através da confrontação entre três elementos: as necessidades identificadas para cada perfil de decisão, a disponibilidade efetiva de dados para a bacia do rio Mondego e a viabilidade técnica da solução a desenvolver no contexto do projeto. Esta validação teve como objetivo assegurar que os requisitos definidos são relevantes para o problema, coerentes entre si e exequíveis com os recursos e dados disponíveis.

De forma geral, verificou-se que os requisitos associados à monitorização corrente, consulta histórica, produção de indicadores e visualização analítica apresentam forte alinhamento

com o domínio do problema e com as capacidades esperadas de um sistema de data lakehouse. Estes requisitos são igualmente compatíveis com a estrutura em camadas prevista para o sistema, bem como com a futura modelação dimensional dos dados.

Durante o processo de validação foram, no entanto, identificadas algumas anomalias e limitações. Em primeiro lugar, alguns requisitos iniciais revelaram-se demasiado genéricos, não indicando de forma suficientemente clara que decisão suportavam nem que dados exigiam. Esta situação foi corrigida através da reformulação dos requisitos em função dos perfis de utilização definidos e da explicitação da sua natureza decisional, funcional ou não funcional. Por exemplo, requisitos como RD07 e RF12 foram reformulados para explicitar, respetivamente, o desfasamento temporal entre precipitação e resposta hidrométrica e as janelas temporais de agregação relevantes para análise histórica.

Em segundo lugar, foram identificados requisitos cuja concretização dependeria de dados não garantidamente disponíveis com a granularidade ou continuidade desejadas. Este problema surgiu sobretudo em requisitos mais ambiciosos relacionados com comparação fina entre estações e com suporte a previsão de risco baseada em histórico extenso e homogéneo. Como ação corretiva, estes requisitos foram mantidos apenas quando compatíveis com as fontes consideradas viáveis, tendo sido restringido o âmbito do sistema a um conjunto reduzido de variáveis observacionais, estações de monitorização e intervalos temporais adequados ao caso de estudo.

Em terceiro lugar, verificou-se a existência de sobreposição parcial entre requisitos de perfis distintos, especialmente entre necessidades do operador de monitorização e do coordenador operacional de risco. A deteção desta sobreposição foi precisamente o que motivou a organização por perfis adotada na secção anterior, na qual se estabeleceu uma separação explícita entre uma vista mais operacional, centrada em observação corrente e deteção de criticidade, e uma vista mais comparativa e agregada, orientada à coordenação e priorização. Esta distinção reflete-se diretamente na forma como os requisitos RD01 a RD03 e RD04 a RD06 foram delimitados e formulados.

A validação permitiu ainda confirmar três decisões estruturantes para o projeto. A primeira é a delimitação do caso de estudo à bacia do rio Mondego. A segunda é a priorização de requisitos diretamente suportados por dados hidrométricos e meteorológicos, considerados nucleares para a monitorização e previsão de cheias. A terceira é a adoção de uma abordagem incremental, em que o núcleo inicial do sistema responde a necessidades de monitorização e análise histórica, sendo posteriormente estendido para suporte a previsão.

Assim, considera-se que o conjunto final de requisitos levantados se encontra suficientemente consolidado para sustentar as etapas seguintes do projeto, nomeadamente a definição da matriz de decisão, a modelação dimensional, o desenho da arquitetura geral do sistema e a conceção do processo de povoamento dos dados.

3. Modelação Dimensional de Dados

3.1 Apresentação da Abordagem Realizada

A modelação dimensional do sistema foi desenvolvida a partir dos requisitos de decisão, funcionais e não funcionais identificados no capítulo anterior, seguindo uma abordagem incremental e orientada aos processos analíticos que o sistema deverá suportar. Em vez de partir imediatamente da estrutura lógica de implementação, optou-se por realizar primeiro uma modelação conceptual multidimensional, permitindo representar de forma mais clara os fenómenos de interesse, as medidas relevantes para análise e os contextos em que essas medidas devem ser observadas.

No contexto do presente projeto, a abordagem adotada combinou uma perspetiva orientada aos requisitos com uma perspetiva condicionada pela viabilidade dos dados disponíveis. Por um lado, a modelação foi guiada pelas necessidades de informação dos perfis de decisão identificados, nomeadamente monitorização operacional, coordenação de risco e análise histórica com suporte a previsão. Por outro lado, as estruturas multidimensionais propostas foram restringidas às variáveis, granularidades temporais e entidades cuja obtenção e integração se consideraram exequíveis no âmbito do caso de estudo. Deste modo, a modelação dimensional não foi tratada como um exercício abstrato, mas como um processo de tradução dos requisitos em estruturas analíticas concretas, compatíveis com as fontes de dados e com a arquitetura de data lakehouse prevista para o sistema.

O processo seguido assentou em quatro decisões metodológicas principais. Em primeiro lugar, identificaram-se os processos analíticos centrais do domínio, isto é, os fenómenos sobre os quais recai a observação e a análise, como as medições hidrometeorológicas, a produção de indicadores agregados e a caracterização de episódios de criticidade. Em segundo lugar, definiu-se para cada processo o respetivo grão, procurando explicitar qual a unidade mínima de observação relevante para análise. Em terceiro lugar, foram identificadas as medidas associadas a cada facto e avaliadas as respetivas possibilidades de agregação ao longo das diferentes dimensões. Em quarto lugar, definiram-se as dimensões e hierarquias necessárias

para suportar análise temporal, espacial, por estação, por variável observada e por contexto operacional. Esta sequência permitiu garantir coerência entre o problema de decisão, os indicadores pretendidos e a futura implementação física do armazém de dados.

A notação adotada para representar a modelação conceptual foi a notação do **Dimensional Fact Model** (DFM), proposta por Golfarelli, Maio e Rizzi. O DFM representa o facto como o foco do processo analítico, as medidas como propriedades quantitativas associadas a esse facto e as dimensões como os eixos discretos segundo os quais essas medidas podem ser observadas e agregadas.

De forma mais concreta, e tal como ilustrado no artigo original de Golfarelli et al., os factos são representados no DFM por um elemento central ao qual se ligam diretamente as dimensões, enquanto os níveis hierárquicos de cada dimensão se organizam em estrutura arbórea ou quase-arbórea, refletindo relações muitos-para-um entre atributos. O modelo contempla ainda a representação de atributos não dimensionais, relações opcionais e restrições de agregabilidade das medidas ao longo das dimensões. Esta expressividade é particularmente útil no presente projeto, uma vez que nem todas as medidas hidrológicas e meteorológicas possuem o mesmo comportamento de agregação ao longo do tempo ou do espaço.

A escolha do DFM justifica-se por três razões principais. Primeiro, por ser uma notação especificamente concebida para modelação conceptual em sistemas de data warehouse, centrada em factos, dimensões, medidas e hierarquias, em vez de adaptar formalismos generalistas menos adequados à análise multidimensional. Segundo, por facilitar o diálogo entre requisitos de decisão e estrutura analítica, tornando mais explícita a relação entre perguntas de negócio e elementos do esquema. Terceiro, por oferecer mecanismos conceptuais relevantes para este domínio, nomeadamente a explicitação do grão, das hierarquias de agregação e das restrições de aditividade das medidas.

Em linha com a literatura de modelação multidimensional, a abordagem seguida pode ser classificada como híbrida. Não se tratou de uma modelação puramente orientada às fontes de dados, nem exclusivamente orientada à elicitação de requisitos. Pelo contrário, procurou-se articular os dois princípios: os requisitos indicaram que fenómenos e indicadores interessava

analisar, enquanto as fontes e a sua estrutura limitaram e moldaram a forma concreta de representar esses fenómenos no modelo dimensional. Esta opção é especialmente adequada em projetos de data warehousing, nos quais é necessário equilibrar o que os utilizadores desejam analisar com o que é efetivamente possível carregar, transformar e manter de forma consistente.

No caso específico da monitorização e previsão de cheias, esta abordagem levou à definição de um núcleo dimensional centrado nas observações hidrometeorológicas como principal processo factual, complementado por uma tabela de factos derivada orientada à produção de indicadores agregados e por uma terceira tabela dedicada ao registo de episódios de cheia identificados. A componente espacial e territorial do problema foi distribuída por duas dimensões complementares: a dimensão **Estação de Monitorização**, que caracteriza o ponto físico de recolha das observações, e a dimensão **Localização**, que representa o enquadramento geográfico e hidrológico desse ponto. Esta separação justifica-se porque a localização possui hierarquias próprias, como bacia, zona de risco, tipo de zona e limites administrativos, que têm valor analítico autónomo e são partilhadas pelas três tabelas de factos. Adicionalmente, foi definida uma dimensão especializada: a dimensão **Tipo de Evento**, que classifica qualitativamente os episódios de cheia registados. A classificação operacional de alerta foi mantida diretamente na **Fact_Medicoes** através do atributo **nivel_alerta**, calculado no processo ETL com base em limiares operacionais exemplificativos. A partir deste núcleo tornou-se possível suportar diferentes vistas analíticas: acompanhamento operacional recente, comparação entre locais, análise de sazonalidade, estudo de excedências de limiares e preparação de dados para previsão. Assim, a modelação dimensional foi construída para servir simultaneamente necessidades operacionais, táticas e analíticas, evitando a criação de estruturas isoladas e promovendo coerência global no desenho do armazém de dados.

Do ponto de vista instrumental, a elaboração do modelo foi realizada com recurso a diagramas conceptuais produzidos especificamente para o projeto, a partir dos requisitos validados e das estruturas de dados consideradas viáveis. Esses diagramas funcionam como suporte de documentação e comunicação entre os membros da equipa, bem como como base

para as etapas seguintes de definição da matriz de decisão, caracterização das dimensões, definição dos factos e configuração dos esquemas analíticos. Nesta perspetiva, a modelação conceptual não constitui apenas uma representação intermédia, mas um artefacto central de projeto, a partir do qual se garante rastreabilidade entre requisitos, arquitetura analítica e implementação.

Em síntese, a abordagem realizada nesta secção assentou numa modelação conceptual multidimensional, incremental e híbrida, guiada pelos requisitos dos agentes de decisão e validada face às restrições das fontes de dados disponíveis. A utilização da notação DFM de Golfarelli permitiu representar de forma rigorosa os três processos factuais identificados, observações hidrometeorológicas, indicadores agregados e episódios de cheia, as suas medidas, os contextos de análise e as respetivas hierarquias, estabelecendo uma base sólida para a definição da matriz de decisão e para a especificação detalhada do esquema dimensional apresentada nas secções seguintes.

3.2 A Matriz de Decisão

A matriz de decisão foi construída de acordo com a lógica de modelação dimensional adotada para o projeto, procurando estabelecer uma correspondência explícita entre os requisitos identificados, os processos analíticos centrais do sistema e as estruturas multidimensionais a implementar no armazém de dados. Seguiu-se, para este efeito, uma organização compatível com a estrutura utilizada na documentação de apoio da unidade curricular, composta por uma caracterização geral do data mart, uma estrutura base que cruza dimensões e tabelas de factos e uma caracterização complementar dos factos em termos do seu tipo, periodicidade, utilidade estratégica, perfis de utilização e observações relevantes.

No presente projeto, e em coerência com a abordagem incremental já assumida nas secções anteriores, optou-se por definir uma matriz de decisão assente em três tabelas de factos complementares. A primeira corresponde ao núcleo transacional do sistema, registando as observações hidrometeorológicas elementares. A segunda é uma tabela derivada orientada

ao armazenamento de indicadores agregados. A terceira regista episódios de cheia identificados, permitindo análise histórica de eventos discretos e suporte ao desenvolvimento de modelos preditivos.

Esta estrutura permite preservar o detalhe necessário à monitorização corrente e à rastreabilidade das observações, disponibilizar métricas agregadas orientadas à produção de KPI e comparação entre períodos e locais, e suportar análise de recorrência e severidade de episódios de cheia. Deste modo, evita-se tanto a excessiva simplificação do modelo como a introdução de estruturas desnecessariamente complexas.

Caracterização do Data Mart de Monitorização de Cheias	
Identificação:	Monitorização de Cheias
Descrição Geral:	Informação para suporte à tomada de decisão no domínio da monitorização e análise de cheias na bacia do rio Mondego, disponibilizando elementos de dados selecionados sobre precipitação, nível hidrométrico e cota de albufeira, bem como a evolução temporal das observações, com vista ao acompanhamento operacional, à comparação entre locais, à produção de indicadores históricos, ao registo de episódios de cheia e à preparação de dados para análise avançada.

Estrutura base			
Dimensões	**Fact_Medicoes**	**Fact_Indicadores**	**Fact_Evento_Cheia**
Tempo	✓	✓	✓
Estação de Monitorização	✓	✓	✓
Localização	✓	✓	✓
Variável Monitorizada	✓	✓	
Tipo de Evento			✓

A estrutura base evidencia que o data mart assenta num conjunto de dimensões conformadas, partilhadas pelas tabelas de factos que as referenciam, e numa dimensão especializada de utilização restrita. As dimensões **Tempo**, **Estação de Monitorização**, **Localização** e **Variável Monitorizada** são conformadas e partilhadas entre os principais processos analíticos. A classificação operacional de alerta não foi modelada como dimensão autónoma, sendo

representada diretamente na **Fact_Medicoes** através do atributo **nivel_alerta**. A dimensão **Tipo de Evento** é utilizada exclusivamente pela **Fact_Evento_Cheia**, classificando os episódios candidatos quanto à sua severidade e origem.

	Fact_Medicoes
Número Dimensões	4
Tipo	Transacional
Periodicidade	Horária ou intradiária
Descrição	Observações hidrometeorológicas elementares registadas por estação, variável monitorizada e instante temporal, constituindo o núcleo factual do sistema.
Utilidade estratégica	Suporte direto à monitorização corrente da situação hidrometeorológica na bacia do rio Mondego. Permite consultar séries temporais, comparar medições entre estações e variáveis, sinalizar excedências de limiares operacionais, produzir agregações temporais e espaciais, calcular indicadores históricos e disponibilizar a base necessária à extração de subconjuntos de dados para análise exploratória e preparação de modelos de previsão.
Utilizadores	Operador de Monitorização Hidrológica; Coordenador Operacional de Risco; Analista de Risco e Planeamento.
Observações	Tabela de factos nuclear do sistema. Serve de base à análise histórica, à produção de KPI e à preparação de dados para componentes analíticas mais avançadas, incluindo a derivação dos episódios de cheia registados na Fact_Evento_Cheia.

	Fact_Indicadores
Número Dimensões	4
Tipo	Derivada / Agregada
Periodicidade	Mensal
Descrição	Tabela de factos derivada que armazena indicadores e agregações calculadas a partir das observações hidrometeorológicas elementares.
Utilidade estratégica	Suporte à produção de KPI, dashboards comparativos, análise histórica agregada e disponibilização de métricas diretamente utilizáveis por perfis operacionais e analíticos, sem necessidade de recalcular agregações sobre o nível transacional.

Utilizadores	Coordenador Operacional de Risco; Analista de Risco e Planeamento; utilização complementar pelo Operador de Monitorização Hidrológica.
Observações	Estrutura derivada orientada à eficiência analítica e à operacionalização de indicadores de monitorização e risco.

	Fact_Evento_Cheia
Número Dimensões	4
Tipo	Derivada de medições em alerta
Periodicidade	Por evento candidato identificado
Descrição	Registo de eventos candidatos de cheia identificados a partir das medições da Fact_Medicoes que apresentam níveis de alerta elevados, caracterizados pela sua duração, precipitação total e nível máximo observado.
Utilidade estratégica	Suporte à análise de recorrência e sazonalidade de situações críticas, comparação entre eventos candidatos, identificação de padrões entre precipitação e resposta hidrométrica, e preparação de variáveis para análise avançada.
Utilizadores	Coordenador Operacional de Risco; Analista de Risco e Planeamento.
Observações	A identificação dos eventos é realizada no processo de ETL com base no atributo nivel_alerta da Fact_Medicoes. Nesta fase, os eventos registados correspondem a eventos candidatos derivados das medições, podendo ser posteriormente validados ou enriquecidos com fontes externas de ocorrências históricas. A dimensão Tempo é utilizada em dois papéis distintos, através de tempo_inicial e tempo_final.

A matriz de decisão assim definida evidencia que o sistema requer três tabelas de factos complementares, partilhando um conjunto de dimensões conformadas e incluindo uma dimensão especializada de utilização restrita. Esta estrutura permite fixar com rigor o grão de cada processo factual, reutilizar dimensões conformadas e garantir consistência analítica ao longo dos diferentes níveis de análise do sistema.

3.3 Definição e Caracterização de Dimensões

As dimensões identificadas para o data mart de monitorização de cheias foram definidas a partir da matriz de decisão apresentada na secção anterior e correspondem às principais perspetivas segundo as quais os factos do sistema deverão ser observados, filtrados e agregados. Em coerência com a abordagem incremental adotada no projeto, optou-se por um conjunto de dimensões suficientemente expressivo para suportar os requisitos nucleares de monitorização corrente, comparação espacial e temporal, análise histórica, identificação de situações de criticidade e estudo de episódios de cheia.

De acordo com a perspetiva de modelação dimensional adotada, uma dimensão representa uma perspetiva de análise sobre um dado objeto de dados, disponibilizando os atributos necessários à exploração das medidas das tabelas de factos. Assim, os atributos dimensionais não são escolhidos de forma arbitrária, mas em função das necessidades de análise identificadas para os agentes de decisão envolvidos no problema. No presente caso, foram definidas cinco dimensões: **Tempo**, **Estação de Monitorização**, **Localização**, **Variável Monitorizada** e **Tipo de Evento**. As dimensões **Tempo**, **Estação de Monitorização**, **Localização** e **Variável Monitorizada** são dimensões conformadas, partilhadas por duas ou mais tabelas de factos. A dimensão **Tipo de Evento** é uma dimensão especializada, associada à **Fact_Evento_Cheia**. Esta distinção permite reutilizar contextos analíticos comuns entre diferentes processos factuais, mantendo uma dimensão específica para a classificação qualitativa dos episódios candidatos de cheia.

A dimensão **Tempo** é indispensável, uma vez que todo o problema é fortemente dependente da evolução cronológica das observações e da análise de padrões temporais. A dimensão **Estação de Monitorização** caracteriza o ponto físico de recolha das observações. A dimensão **Localização** concentra o enquadramento geográfico e hidrológico, representando os territórios e bacias em que as estações se inserem, separada da dimensão Estação porque possui hierarquias territoriais próprias com valor analítico autónomo, nomeadamente bacia, zona de risco, tipo de zona e limites administrativos. A dimensão **Variável Monitorizada**

permite distinguir o fenómeno observado. A classificação operacional de alerta é representada diretamente na **Fact_Medicoes** através do atributo **nivel_alerta**, calculado no processo ETL com base em limiares operacionais exemplificativos. A dimensão **Tipo de Evento** classifica qualitativamente os episódios candidatos de cheia registados.

As dimensões conformadas são partilhadas pelas tabelas de factos que as referenciam, assegurando coerência semântica entre os diferentes níveis de análise. Para além disso, cada dimensão foi caracterizada segundo a estrutura documental adotada nas notas de apoio: caracterização geral, atributos, hierarquias e perfis de utilização.

Dimensão Tempo

A dimensão **Tempo** representa o enquadramento temporal das medições, indicadores e eventos registados no sistema. Esta dimensão permite analisar os dados por hora, semana, mês, trimestre, ano e estação do ano, suportando tanto a monitorização operacional como a análise histórica.

Na implementação realizada, a chave primária **id_tempo** é uma chave temporal calculada no formato **AAAAMMDDHH**. Esta opção permite identificar diretamente o instante horário associado a cada observação, preservando a granularidade temporal necessária à monitorização operacional, à análise histórica e à preparação de modelos preditivos.

Os atributos incluídos na dimensão são **hora**, **semana**, **mes**, **trimestre**, **ano** e **estacao_ano**. Estes atributos são derivados na camada Silver a partir da data e hora original da observação, sendo depois carregados para a camada Gold. A granularidade temporal é representada simultaneamente pelo identificador **id_tempo**, que codifica o instante horário, e pelos atributos temporais usados para filtragem, ordenação e agregação.

Caracterização geral da dimensão Tempo	
Identificação:	Dim_Tempo
Descrição:	Dimensão temporal que suporta a organização cronológica das medições, dos indicadores e dos eventos candidatos de cheia, permitindo filtragem, ordenação e agregação por hora, semana, mês, trimestre, ano e estação do ano.

Tipo:	Dimensão temporal, conforme e partilhada
Variação:	Sem necessidade de tratamento histórico complexo; os seus registos são estáveis após geração no processo ETL.

Atributo	Descrição	Exemplo
id_tempo	Chave temporal inteira calculada no formato **AAAAMMDDHH**, utilizada para identificar cada instante horário.	2024051811
hora	Hora associada ao instante da medição.	11
semana	Semana do ano associada ao instante da medição.	20
mes	Mês numérico associado ao instante da medição.	5
trimestre	Trimestre civil associado ao mês da medição.	2
ano	Ano civil associado ao instante da medição.	2024
estacao_ano	Estação do ano associada ao mês da medição, útil para análise sazonal.	Primavera

A inclusão do atributo **id_tempo** como chave temporal calculada permite identificar cada registo da dimensão Tempo de forma estável e interpretável. O formato **AAAAMMDDHH** preserva a granularidade horária das observações e facilita a ordenação cronológica, a análise temporal e a extração de subconjuntos de dados para modelos de previsão. Apesar de codificar informação temporal, o atributo continua a funcionar como chave primária da dimensão e como referência temporal nas tabelas de factos.

A dimensão **Tempo** suporta uma hierarquia principal de agregação cronológica e uma hierarquia alternativa orientada à análise sazonal.

Hierarquia	Caminho de agregação
H1	mes → trimestre → ano
H2	semana →
H3	estacao_ano
H4	hora

Estas hierarquias são simples e adequadas ao tipo de análise pretendida. A primeira hierarquia suporta operações de agregação temporal ao nível mensal, trimestral e anual. As restantes perspetivas temporais permitem analisar separadamente a sazonalidade, a semana do ano e a hora da observação, dimensões relevantes para a monitorização operacional e para o estudo de padrões temporais.

Perfis de utilização	Utilização principal
Operador de Monitorização Hidrológica	Consulta da evolução recente das medições por hora, semana ou mês.
Coordenador Operacional de Risco	Análise de agravamento por período e comparação entre intervalos temporais recentes.
Analista de Risco e Planeamento	Agregações por mês, trimestre, estação do ano e ano para estudo histórico e sazonal.

Dimensão Estação de Monitorização

A dimensão **Estação de Monitorização** representa a origem operacional das observações e constitui o eixo de identificação do ponto físico de recolha de dados no sistema. A componente geográfica e territorial foi autonomizada numa dimensão própria, neste caso a dimensão **Localização**, porque os atributos de enquadramento territorial possuem hierarquias próprias com valor analítico independente da estação e são partilhados pelas três tabelas de factos. A dimensão **Estação de Monitorização** concentra, assim, os atributos que caracterizam o sensor ou ponto de monitorização enquanto entidade técnica e operacional, incluindo o código natural da estação, mantido para rastreabilidade e resolução de chaves no processo ETL.

Caracterização geral da dimensão Estação de Monitorização	
Identificação:	Dim_Estacao
Descrição:	Dimensão que identifica e caracteriza cada estação ou ponto de monitorização utilizado no sistema, incluindo os atributos físicos e operacionais associados ao ponto de recolha de dados.
Tipo:	Dimensão conforme, partilhada e com potencial de variação lenta
Variação:	Admite evolução lenta em atributos descritivos, como designação ou tipo de estação, embora nesta implementação seja tratada de forma simples.

Atributo	Descrição	Exemplo
id_estacao	Chave substituta da dimensão estação, gerada na camada Gold.	1
codigo_estacao	Código natural da estação, mantido para rastreabilidade e resolução de chaves durante o povoamento.	12G/08H
nome	Designação da estação de monitorização.	PONTE CONRARIA
tipo	Classificação operacional da estação.	Hidrometrica

A dimensão **Estação de Monitorização** suporta uma hierarquia principal baseada no tipo de sensor, uma vez que os atributos de agregação territorial foram transferidos para a dimensão **Localização**.

Hierarquia	Caminho de agregação
H1	id_estacao → tipo

A análise espacial por zona de risco, tipo de zona, concelho ou distrito é realizada através da dimensão **Localização**, enquanto a dimensão **Estação de Monitorização** suporta análise ao nível do ponto de observação individual e por tipo de sensor.

Perfis de utilização	Utilização principal
Operador de Monitorização Hidrológica	Consulta por estação específica e comparação rápida entre pontos de monitorização.
Coordenador Operacional de Risco	Identificação de estações com maior número de excedências e análise por tipo de sensor.
Analista de Risco e Planeamento	Seleção de estações para análise histórica e preparação de dados para modelos preditivos.

A separação entre **Estação de Monitorização** e **Localização** permite distinguir o ponto técnico de recolha das observações do seu enquadramento territorial e hidrológico. Esta decisão é coerente com o modelo dimensional adotado, uma vez que a estação identifica a

origem operacional da medição, enquanto a localização suporta análises por concelho, distrito, bacia, zona de risco e tipo de zona. A ausência de coordenadas geográficas fiáveis nesta fase justifica que a componente espacial seja representada através da dimensão **Localização**, sem comprometer a análise territorial pretendida.

Dimensão Localização

A dimensão **Localização** representa o enquadramento geográfico e hidrológico do sistema, caracterizando os territórios em que as estações de monitorização se inserem. A sua autonomização relativamente à dimensão **Estação de Monitorização** justifica-se por três razões principais. Em primeiro lugar, porque os atributos territoriais possuem hierarquias próprias que têm valor analítico independente da existência de uma estação concreta. Em segundo lugar, porque esta dimensão é partilhada pelas três tabelas de factos, incluindo a **Fact_Evento_Cheia**, que regista episódios com uma localização geográfica associada. Em terceiro lugar, porque esta separação permite uma análise territorial mais limpa, sem sobrecarregar a dimensão **Estação de Monitorização** com atributos que pertencem conceptualmente a uma entidade diferente.

Caracterização geral da dimensão Localização	
Identificação:	Dim_Localizacao
Descrição:	Dimensão que representa o enquadramento geográfico, hidrológico e de risco dos pontos de observação e dos episódios de cheia registados, suportando análise territorial e hierárquica.
Tipo:	Dimensão conforme, partilhada e de variação lenta
Variação:	Estável; admite atualização pontual em atributos territoriais ou classificações de risco, caso exista revisão das fontes geográficas ou das regras de enquadramento territorial.

Atributo	**Descrição**	**Exemplo**
id_localizacao	Chave substituta da dimensão localização, gerada na camada Gold.	1

zona_risco	Classificação simplificada do risco territorial associado à localização.	Alta
bacia	Bacia hidrográfica principal.	Mondego
concelho	Concelho associado à estação ou ao evento.	Coimbra
distrito	Distrito associado à estação ou ao evento.	Coimbra
tipo_zona	Caracterização territorial ou hidrológica da zona analisada.	Urbana

A dimensão **Localização** suporta diferentes caminhos de agregação, refletindo perspetivas de análise espacial complementares: a perspetiva administrativa, útil para relatórios e dashboards de gestão territorial; a perspetiva hidrológica, útil para análise da bacia hidrográfica principal e para o enquadramento dos pontos de observação no sistema do Mondego; e a perspetiva de risco territorial, relevante para comparar zonas urbanas, rurais, montante, jusante ou de maior exposição.

Hierarquia	**Caminho de agregação**
H1	id_localizacao → concelho → distrito
H2	id_localizacao → zona_risco
H3	id_localizacao → tipo_zona
H4	id_localizacao → bacia

Perfis de utilização	**Utilização principal**
Operador de Monitorização Hidrológica	Filtragem de estações por concelho, distrito, tipo de zona e zona de risco.
Coordenador Operacional de Risco	Comparação entre zonas da bacia, identificação de áreas prioritárias com base em zona_risco e análise territorial agregada.
Analista de Risco e Planeamento	Estudo espacial de padrões históricos, diferenças entre zonas de risco, tipos de zona e relações entre montante e jusante.

Dimensão Variável Monitorizada

A dimensão **Variável Monitorizada** identifica o tipo de fenómeno observado em cada registo factual. No âmbito do caso de estudo, esta dimensão permite distinguir as principais variáveis hidrometeorológicas consideradas relevantes para monitorização e análise de cheias, designadamente precipitação, nível hidrométrico e cota de albufeira. A sua função é essencialmente semântica e analítica, uma vez que explicita o significado da medida observada e permite comparar comportamentos distintos segundo o tipo de variável.

Trata-se de uma dimensão relativamente pequena e estável, mas ainda assim necessária, porque a mesma estrutura factual deverá acolher observações de natureza diferente, com unidades, interpretações e regras de agregação potencialmente distintas. A explicitação desta dimensão evita ambiguidades na leitura dos factos e permite suportar filtros e análises comparativas por tipo de variável.

Caracterização geral da dimensão Variável Monitorizada	
Identificação:	Dim_Variavel
Descrição:	Dimensão que identifica e caracteriza o tipo de variável hidrometeorológica observada em cada registo factual.
Tipo:	Dimensão conforme, partilhada e de baixa cardinalidade
Variação:	Baixa ou nula; apenas admite evolução pontual caso novas variáveis sejam integradas no sistema.

Atributo	**Descrição**	**Exemplo**
id_variavel	Chave substituta da dimensão variável, gerada na camada Gold.	1
tipo_variavel	Tipo de fenómeno hidrometeorológico observado.	PRECIPITACAO
unidade	Unidade física associada à variável observada.	mm

Embora a dimensão física final não inclua um atributo autónomo de tipo de agregação, o comportamento analítico das variáveis foi considerado na definição conceptual das medidas.

Assim, a precipitação é tratada como variável acumulável, enquanto o nível hidrométrico e a cota de albufeira são analisados através de máximos, médias ou variações, consoante o indicador pretendido.

A dimensão **Variável Monitorizada** possui uma hierarquia simples, pouco profunda, mas suficiente para suportar agregação por categoria geral do fenómeno observado.

Hierarquia	Caminho de agregação
H1	id_variavel → tipo_variavel

Trata-se de uma estrutura simples, adequada à baixa cardinalidade e à relativa estabilidade desta dimensão, permitindo filtrar e comparar as medições segundo o tipo de fenómeno observado.

Perfis de utilização	Utilização principal
Operador de Monitorização Hidrológica	Filtragem e visualização por variável observada nas séries temporais correntes.
Coordenador Operacional de Risco	Comparação de criticidade segundo o tipo de variável mais relevante em cada local.
Analista de Risco e Planeamento	Análise histórica diferenciada por variável e suporte à seleção de atributos para modelos preditivos.

Dimensão Tipo de Evento

A dimensão **Tipo de Evento** classifica qualitativamente cada episódio candidato de cheia registado na tabela **Fact_Evento_Cheia**. A sua função é permitir filtrar e comparar eventos por características qualitativas, como severidade, origem e tipo de evento, suportando os requisitos associados ao estudo de padrões, recorrência e criticidade de episódios hidrometeorológicos.

Esta dimensão é utilizada exclusivamente pela **Fact_Evento_Cheia**, uma vez que é a única tabela que regista eventos como entidades discretas com características qualitativas próprias.

Caracterização geral da dimensão Tipo de Evento	
Identificação:	Dim_TipoEvento
Descrição:	Dimensão que classifica os episódios candidatos de cheia quanto ao tipo de evento, severidade e origem, suportando análise comparativa e estudo de padrões históricos.
Tipo:	Dimensão especializada, de baixa cardinalidade
Variação:	Muito baixa; apenas admite evolução caso sejam definidas novas classificações operacionais ou analíticas.

Atributo	Descrição	Exemplo
id_Tipo	Chave primária da dimensão tipo de evento.	1
tipo_evento	Classificação qualitativa do episódio candidato de cheia.	Cheia hidrometrica
severidade	Grau operacional ou nível de criticidade associado ao tipo de evento.	Alerta
origem	Origem predominante do evento candidato.	Fluvial

O atributo **origem** permite distinguir eventos candidatos associados predominantemente à precipitação intensa, à resposta hidrométrica do sistema fluvial ou a situações combinadas. Esta distinção é relevante para a análise de padrões entre precipitação e resposta hidrométrica, bem como para a preparação de leituras históricas diferenciadas por tipo de fenómeno observado.

Hierarquia	Caminho de agregação
H1	id_Tipo → tipo_evento
H2	id_Tipo → origem
H3	id_Tipo → severidade

Perfis de utilização	Utilização principal
Coordenador Operacional de Risco	Filtragem de eventos candidatos por tipo e severidade para apoio à priorização operacional.

Analista de Risco e Planeamento	Análise histórica diferenciada por tipo, origem e severidade; suporte ao estudo de padrões e recorrência de eventos.

Do ponto de vista conceptual, as dimensões definidas procuram representar os principais contextos de análise necessários ao domínio da monitorização de cheias: tempo, estação de monitorização, localização, variável observada e tipo de evento. Estes contextos permitem interpretar as medidas registadas nas tabelas de factos segundo perspetivas temporais, espaciais, operacionais e hidrometeorológicas, garantindo coerência com os requisitos de monitorização, análise histórica, comparação territorial e suporte à decisão identificados no capítulo inicial.

Síntese global das dimensões

A definição das cinco dimensões anteriores permite estruturar o data mart em torno de perspetivas de análise claramente alinhadas com o problema de decisão e com os requisitos recolhidos.

Dimensão	Cardinalidade esperada	Tipo	Função principal
Tempo	Elevada	Temporal, conforme, partilhada	Análise cronológica, agregações temporais e estudo de sazonalidade.
Estação de Monitorização	Média	Conforme, partilhada, variação lenta	Identificar o ponto técnico de recolha das observações.
Localização	Média	Conforme, partilhada, estável	Análise espacial, territorial e hidrológica.
Variável Monitorizada	Reduzida	Conforme, partilhada, estável	Distinguir o fenómeno observado e a unidade associada.
Tipo de Evento	Reduzida	Especializada (Fact_Evento_Cheia)	Classificar episódios candidatos de cheia por tipo, severidade e origem.

Em termos de desenho global, estas dimensões foram escolhidas por permitirem um compromisso adequado entre expressividade analítica, simplicidade estrutural e viabilidade de implementação.

3.4 Definição e Caracterização das Tabelas de Factos e Respetivos Grãos

As tabelas de factos constituem o núcleo do modelo dimensional proposto, uma vez que materializam os processos analíticos centrais do sistema e estabelecem a ligação entre as dimensões conformadas anteriormente definidas e as medidas quantitativas relevantes para a monitorização e análise de cheias. No presente projeto, a definição destas tabelas foi realizada de forma incremental, procurando manter coerência com os requisitos validados, com a viabilidade das fontes de dados e com a necessidade de suportar simultaneamente monitorização corrente, produção de indicadores e preparação de dados para etapas posteriores de exploração analítica e previsão.

Nesta perspetiva, optou-se por estruturar o modelo factual em torno de três tabelas de factos complementares. A primeira corresponde ao núcleo transacional do sistema e regista as observações hidrometeorológicas elementares recolhidas ao longo do tempo. A segunda corresponde a uma estrutura factual derivada, orientada à produção de indicadores agregados por período, estação e variável. A terceira regista episódios candidatos de cheia, com as suas características globais de duração, precipitação total e nível máximo. Esta terceira tabela não substitui nem duplica as anteriores, mas antes introduz uma perspetiva de análise orientada ao evento como unidade discreta, complementando a perspetiva de observação contínua das outras duas tabelas. A introdução da tabela **Fact_Indicadores** resulta diretamente dos requisitos RF06 e RF12, que implicam a disponibilização de métricas agregadas e indicadores históricos. A introdução da tabela **Fact_Evento_Cheia** resulta dos requisitos RD07 e RD08,

que exigem análise de padrões de relacionamento entre variáveis e estudo de recorrência de episódios históricos.

A coexistência destas três tabelas de factos é coerente com a arquitetura analítica do projeto. A tabela transacional preserva o detalhe necessário à rastreabilidade e ao estudo fino de séries temporais. A tabela derivada facilita a exploração analítica e a operacionalização de KPI. A tabela de eventos suporta análise histórica de episódios, comparação entre eventos e preparação de dados para modelos preditivos.

Caracterização da Tabela de Factos Fact_Medicoes

A tabela **Fact_Medicoes** representa o facto nuclear do sistema, correspondendo ao registo elementar das medições hidrometeorológicas efetuadas nas estações de monitorização. Esta estrutura foi definida como a principal tabela transacional do data mart, servindo de base a todas as operações de análise detalhada, cálculo de indicadores derivados e preparação de subconjuntos de dados para exploração avançada e previsão.

O seu grão foi definido como uma observação por estação de monitorização, variável observada e instante temporal. Esta definição é coerente com o problema de decisão em causa, uma vez que permite preservar o detalhe necessário para acompanhamento operacional, comparação entre estações, análise de evolução temporal e deteção de situações de criticidade.

Caracterização geral da tabela de factos Fact_Medicoes	
Identificação:	Fact_Medicoes
Descrição:	Tabela de factos transacional que regista observações hidrometeorológicas elementares por estação, variável monitorizada e instante temporal.
Tipo:	Transacional
Grão:	Uma observação por estação de monitorização, variável observada e instante temporal.
Periodicidade:	Horária ou intradiária, dependendo da granularidade das fontes integradas.

Utilidade estratégica:	Suporte à monitorização corrente, análise temporal detalhada, contextualização face a limiares de alerta, cálculo de indicadores derivados, deteção de anomalias e preparação de dados para modelos de previsão.
Perfis de utilização:	Operador de Monitorização Hidrológica; Coordenador Operacional de Risco; Analista de Risco e Planeamento.
Observações:	Constitui a estrutura factual base do sistema. Serve de base à análise histórica, à produção de KPI e à derivação dos episódios de cheia registados na Fact_Evento_Cheia.

Nr	Atributo / Chave	Tipo	Domínio	Descrição
1	fk_id_tempo	FK	int	Chave estrangeira para a dimensão **Dim_Tempo**.
2	fk_id_estacao	FK	int	Chave estrangeira para a dimensão **Dim_Estacao**.
3	fk_id_localizacao	FK	int	Chave estrangeira para a dimensão **Dim_Localizacao**.
4	fk_id_variavel	FK	int	Chave estrangeira para a dimensão **Dim_Variavel**.

Nr	Medida / Atributo factual	Domínio	Tipo	Descrição
1	valor_observado	decimal	Agregável / semi-agregável consoante a variável	Valor numérico observado para a variável monitorizada no instante considerado.
2	nivel_alerta	int	Atributo factual ordinal	Classificação operacional da criticidade da medição, com valores de 0 a 3.
3	variacao_valor	decimal	Não agregável	Diferença entre o valor observado atual e o valor observado anterior para a mesma estação e variável, permitindo analisar subidas ou descidas recentes.

A medida **valor_observado** apresenta comportamentos distintos de agregação consoante a variável observada. No caso da precipitação, é uma medida acumulável ao longo do tempo, sendo adequada a operações de soma em janelas temporais. No caso do nível hidrométrico e da cota de albufeira, a agregação por soma não é semanticamente válida, sendo mais apropriadas operações como máximo, mínimo ou média. Esta distinção é considerada na definição das medidas agregadas da **Fact_Indicadores**.

Caracterização da Tabela de Factos Fact_Indicadores

A tabela **Fact_Indicadores** corresponde a uma estrutura factual derivada, construída a partir da tabela **Fact_Medicoes** com o objetivo de armazenar medidas agregadas e indicadores relevantes para exploração analítica e visualização. A sua introdução justifica-se pela necessidade de disponibilizar KPI e métricas de acompanhamento sem obrigar a recalcular, em tempo de consulta, todas as agregações sobre o nível transacional elementar.

O grão desta tabela foi definido como um registo por estação de monitorização, variável observada, localização e período mensal. A escolha da granularidade mensal permite consolidar indicadores históricos de forma estável, facilitando a comparação entre estações, variáveis, zonas da bacia e períodos temporais. As restantes granularidades temporais continuam a ser suportadas através da **Dim_Tempo** e da **Fact_Medicoes**, enquanto a **Fact_Indicadores** materializa apenas o nível mensal por ser o mais adequado à análise histórica agregada.

Embora a dimensão Dim_Tempo tenha granularidade horária, na Fact_Indicadores o atributo fk_id_tempo deve ser interpretado como referência temporal do período mensal agregado, e não como uma medição horária específica. Nesta implementação, o identificador temporal associado ao indicador funciona como chave de enquadramento do mês de referência, mantendo compatibilidade com a dimensão temporal comum usada pelas restantes tabelas de factos.

Caracterização geral da tabela de factos Fact_Indicadores	
Identificação:	Fact_Indicadores
Descrição:	Tabela de factos derivada que armazena indicadores e agregações calculadas a partir das observações hidrometeorológicas.
Tipo:	Agregada
Grão:	Um registo por estação de monitorização, variável observada, localização e período mensal.
Periodicidade:	Mensal.
Utilidade estratégica:	Suporte à produção de KPI, dashboards comparativos, análise histórica agregada e disponibilização de métricas diretamente utilizáveis por perfis operacionais e analíticos.
Perfis de utilização:	Coordenador Operacional de Risco; Analista de Risco e Planeamento; utilização complementar pelo Operador de Monitorização Hidrológica.
Observações:	Estrutura derivada orientada à eficiência analítica e à operacionalização de indicadores de monitorização e risco.

Nr	Atributo / Chave	Tipo	Domínio	Descrição
1	fk_id_tempo	FK	int	Chave estrangeira para a dimensão **Dim_Tempo**, correspondente ao período temporal de referência da agregação.
2	fk_id_estacao	FK	int	Chave estrangeira para a dimensão **Dim_Estacao**.
3	fk_id_localizacao	FK	int	Chave estrangeira para a dimensão **Dim_Localizacao**.
4	fk_id_variavel	FK	int	Chave estrangeira para a dimensão **Dim_Variavel**.

Nr	Medida	Domínio	Tipo	Descrição
1	precipitacao_acumulada	decimal	Semi-agregável	Precipitação acumulada no período mensal considerado. Relevante para avaliação de episódios de chuva intensa e comparação sazonal.
2	nivel_maximo_periodo	decimal	Não agregável	Valor máximo de nível hidrométrico ou cota de albufeira registado no período mensal. Indicador relevante para identificar situações de maior criticidade hidrológica.

3	caudal_medio_periodo	decimal	Não agregável	Valor médio observado no período mensal para a variável analisada. Apesar da designação física da medida, no âmbito da implementação esta métrica não representa caudal real; corresponde à média dos valores observados das variáveis carregadas, interpretada de acordo com a respetiva unidade de medida.
4	num_excedencias_limiar	int	Agregável	Número de medições do período mensal em que o nível de alerta derivado foi superior a zero. A classificação baseia-se no atributo **nivel_alerta** da **Fact_Medicoes**.

A definição das medidas desta tabela procurou refletir os principais tipos de indicadores necessários à análise histórica do sistema. A medida **precipitacao_acumulada** é relevante para avaliar episódios de precipitação intensa. A medida **nivel_maximo_periodo** permite identificar os valores máximos atingidos por variáveis como nível hidrométrico e cota de albufeira. A medida **caudal_medio_periodo** foi mantida com esta designação por coerência com a implementação física, mas deve ser interpretada como uma média genérica do valor observado no período, e não como medição direta de caudal. A sua leitura depende sempre da variável associada na **Dim_Variavel** e da unidade correspondente. A medida **num_excedencias_limiar** traduz uma noção diretamente ligada à monitorização de criticidade, contando situações em que as observações ultrapassaram os limiares operacionais definidos.

A interpretação das medidas agregadas depende da natureza da variável observada. A precipitação é adequada a acumulação no período, enquanto o nível hidrométrico e a cota de albufeira são analisados através de máximos e médias.

Caracterização da Tabela de Factos Fact_Evento_Cheia

A tabela **Fact_Evento_Cheia** regista episódios candidatos de cheia derivados das medições com níveis de alerta elevados registadas na **Fact_Medicoes**. Enquanto as outras duas tabelas de factos operam ao nível da observação individual ou de período agregado, esta tabela introduz uma perspetiva de análise orientada ao evento como unidade discreta com início, fim e características globais. A sua introdução resulta diretamente dos requisitos RD07 e RD08, que exigem análise de padrões de relacionamento entre variáveis e estudo de recorrência e sazonalidade de episódios históricos.

O grão desta tabela foi definido como um episódio de cheia identificado, por estação de monitorização, referenciado pela data de início do evento. Um episódio candidato é identificado a partir de medições com níveis de alerta elevados registados na **Fact_Medicoes**. Nesta fase, a classificação é baseada no atributo factual **nivel_alerta**, permitindo delimitar períodos de maior criticidade sem recorrer a uma dimensão autónoma de alerta.

A dimensão **Tempo** é utilizada em dois papéis distintos, através dos atributos **tempo_inicial** e **tempo_final**, que representam, respetivamente, o instante de início e o instante de fim do episódio candidato. Esta opção permite reutilizar a mesma dimensão temporal sem duplicar a sua estrutura.

Caracterização geral da tabela de factos Fact_Evento_Cheia	
Identificação:	Fact_Evento_Cheia
Descrição:	Tabela de factos que regista episódios de cheia identificados, caracterizados pela sua duração, precipitação total e nível máximo atingido.
Tipo:	Transacional (derivada de excedências)
Grão:	Um episódio de cheia identificado, por estação de monitorização, referenciado pela data de início do evento.
Periodicidade:	Por evento identificado (irregular).
Utilidade estratégica:	Suporte à análise de recorrência e sazonalidade de episódios históricos, comparação entre eventos atuais e passados, identificação de padrões entre precipitação em montante e resposta hidrométrica em jusante, e preparação de variáveis para modelos preditivos.
Perfis de utilização:	Coordenador Operacional de Risco; Analista de Risco e Planeamento.

Observações:	A fonte primária é derivada das medições em alerta da Fact_Medicoes. Fontes externas de ocorrências históricas poderão ser usadas posteriormente para validação e enriquecimento dos eventos candidatos.

Nr	Atributo / Chave	Tipo	Domínio	Descrição
1	tempo_inicial	FK	int	Chave estrangeira para a dimensão **Dim_Tempo**, correspondente ao instante inicial do evento candidato.
2	tempo_final	FK	int	Chave estrangeira para a dimensão **Dim_Tempo**, correspondente ao instante final do evento candidato.
3	fk_id_estacao	FK	int	Chave estrangeira para a dimensão **Dim_Estacao**.
4	fk_id_localizacao	FK	int	Chave estrangeira para a dimensão **Dim_Localizacao**.
5	fk_id_Tipo	FK	int	Chave estrangeira para a dimensão **Dim_TipoEvento**.

Nr	Medida / Atributo factual	Domínio	Tipo	Descrição
1	duracao_horas	DECIMAL(8,2)	Semi-agregável	Duração total do episódio em horas. Permite distinguir cheias rápidas de cheias prolongadas com perfis de risco distintos.
2	precipitacao_total_evento	decimal	Semi-agregável	Precipitação acumulada durante todo o episódio, calculada a partir das medições horárias da Fact_Medicoes.
3	nivel_max_evento	decimal	Não agregável	Nível hidrométrico máximo atingido durante o episódio. Define a severidade do evento e é o indicador de impacto mais direto.

A medida **duracao_horas** é semi-agregável: pode ser somada ao longo do tempo para obter o total de horas em situação de cheia num dado período, mas não deve ser somada entre estações distintas. A medida **precipitacao_total_evento** é igualmente semi-agregável no tempo. A medida **nivel_max_evento** é não agregável pois apenas é comparável entre eventos ou entre estações, nunca somável.

Síntese global das tabelas de factos

As três tabelas de factos definidas desempenham funções complementares no modelo dimensional do sistema.

Tabela de Factos	Tipo	Grão	Função principal
Fact_Medicoes	Transacional	Uma observação por estação, variável e instante temporal	Preservar o detalhe observacional e suportar monitorização corrente, validação e preparação analítica.
Fact_Indicadores	Derivada / Agregada	Um registo por estação, variável, localização e período mensal	Disponibilizar KPI, métricas agregadas e suporte eficiente à exploração analítica e visualização.
Fact_Evento_Cheia	Transacional derivada	Um episódio por estação e data de início	Análise histórica de episódios de cheia e suporte ao desenvolvimento de modelos preditivos.

Em termos de evolução do modelo, esta estrutura factual permite manter um núcleo coerente e suficientemente expressivo para sustentar as fases seguintes do projeto.

3.5 Configuração dos Esquemas

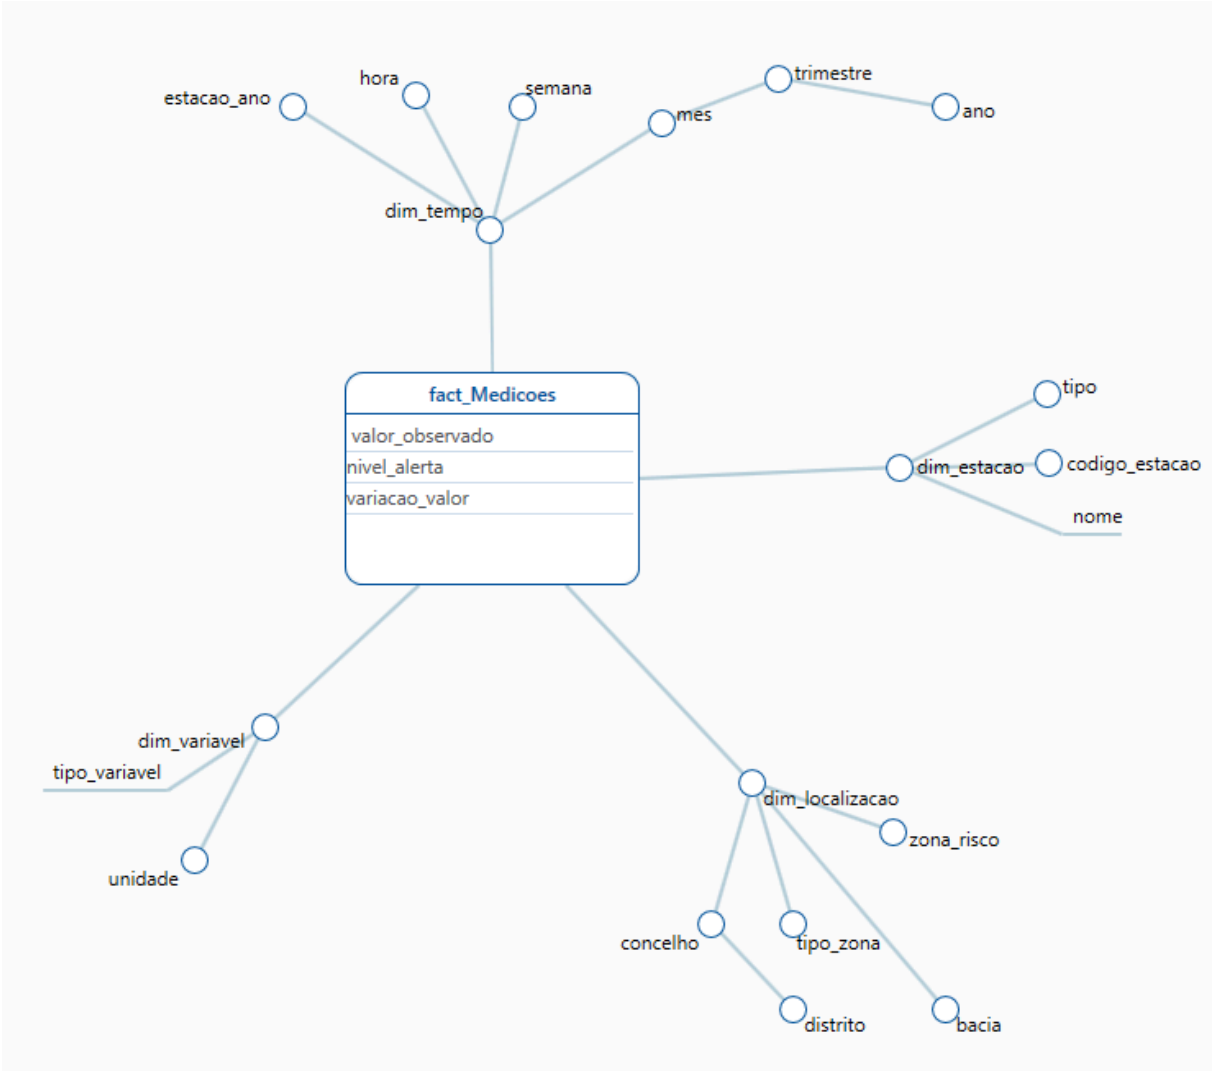


Figura 3: Esquema dimensional da Fact_Medicoes

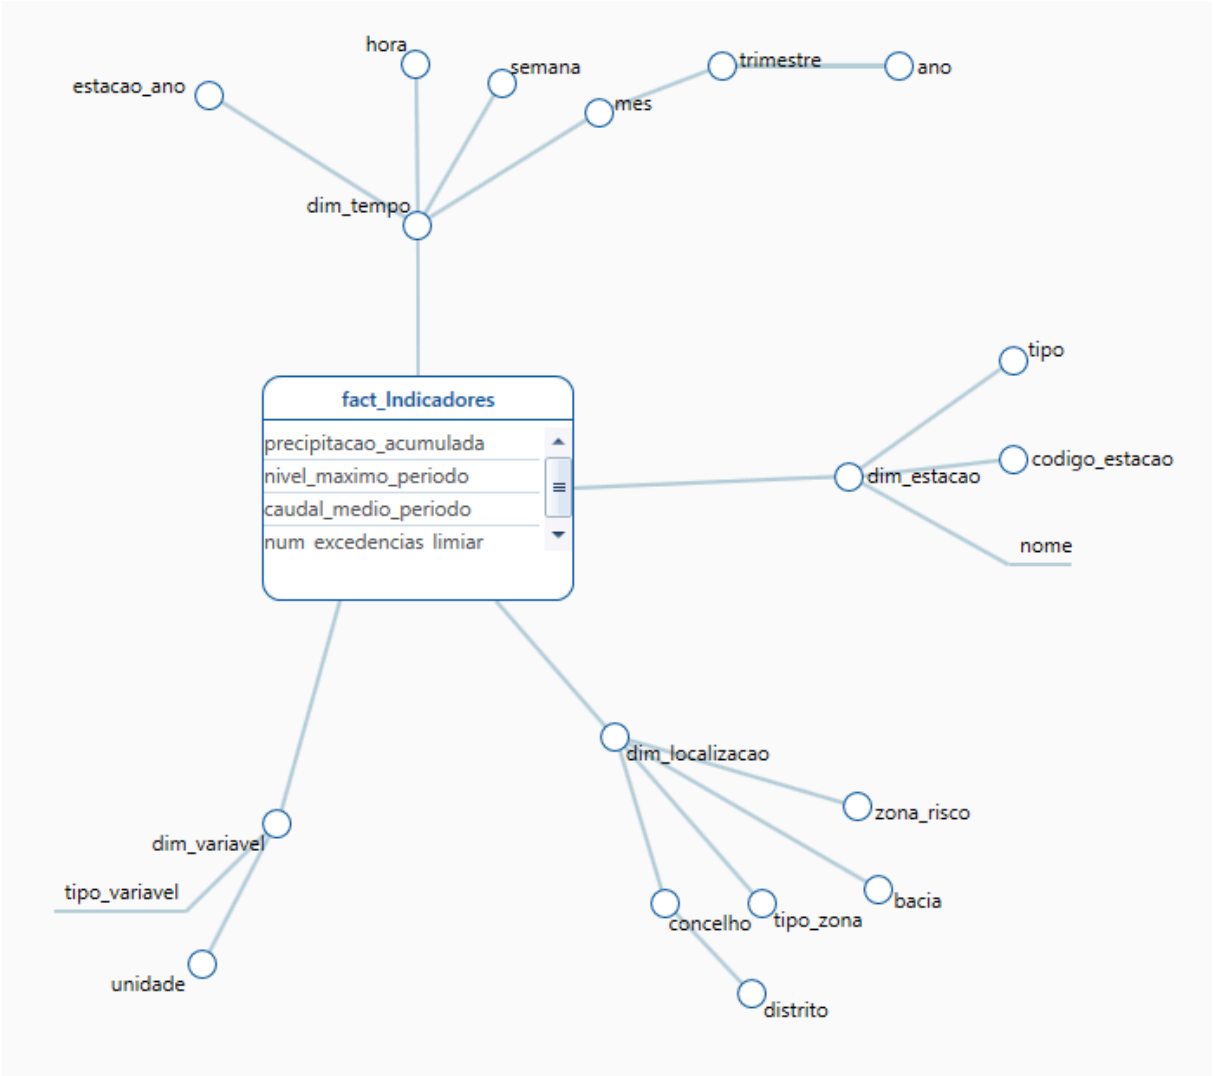


Figura 4: Esquema dimensional da Fact_Indicadores

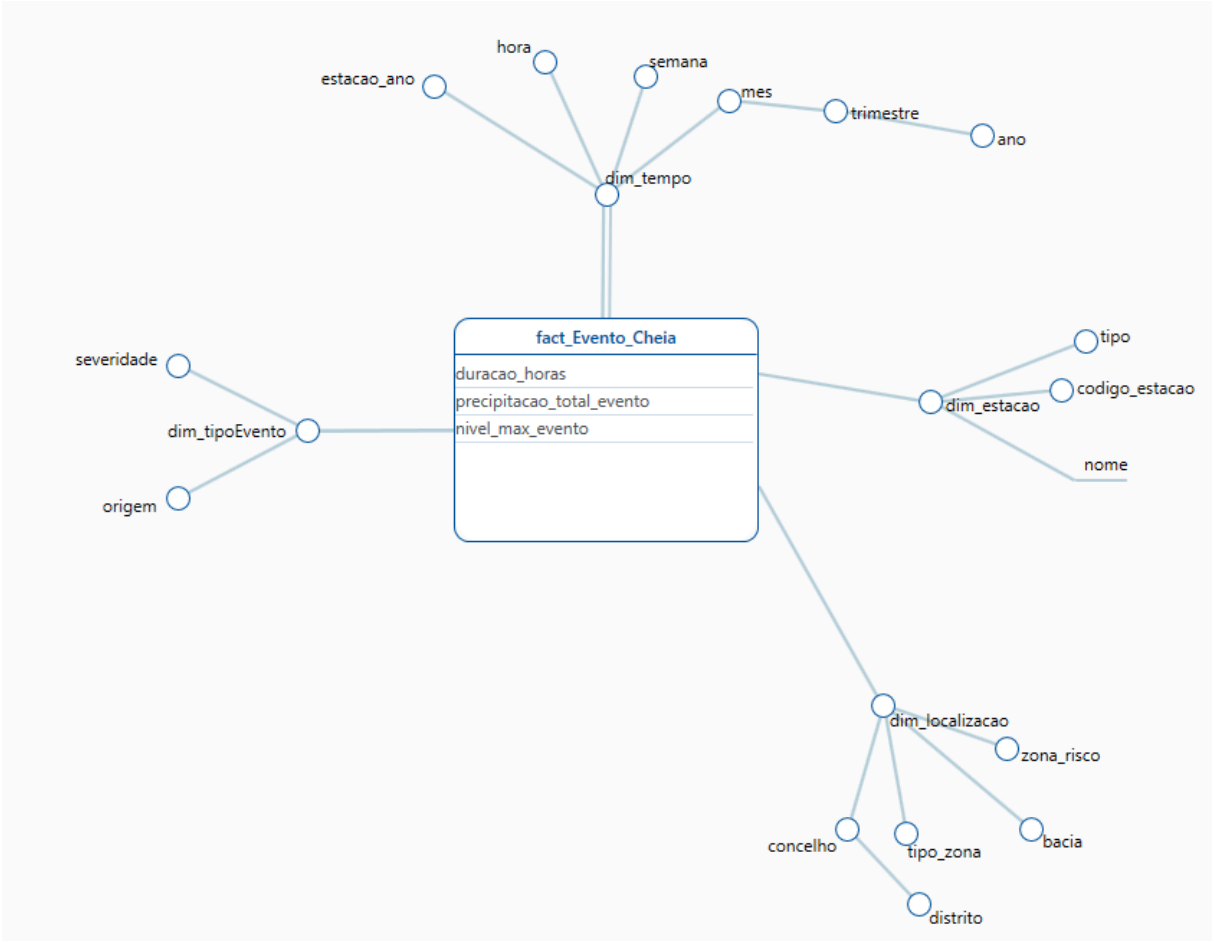


Figura 5: Esquema dimensional da Fact_Evento_Cheia

O esquema dimensional apresentado representa a concretização da modelação conceptual definida nas secções anteriores, organizando três tabelas de factos e cinco dimensões num modelo coerente e orientado à exploração analítica.

O modelo assenta numa estrutura de constelação (**galaxy schema**), na qual três tabelas de factos, **Fact_Medicoes**, **Fact_Indicadores** e **Fact_Evento_Cheia**, partilham dimensões conformadas comuns. As dimensões **Tempo, Estação de Monitorização** e **Localização** são partilhadas pelas três tabelas de factos. A dimensão **Variável Monitorizada** é partilhada pela Fact_Medicoes e pela Fact_Indicadores, enquanto a dimensão **Tipo de Evento** é utilizada exclusivamente pela Fact_Evento_Cheia.

Esta organização garante consistência semântica entre diferentes níveis de análise e permite comparar observações detalhadas, indicadores agregados e episódios candidatos de cheia segundo perspetivas temporais, espaciais e hidrometeorológicas comuns.

A tabela **Fact_Medicoes** constitui o núcleo transacional do sistema, armazenando o detalhe das medições hidrometeorológicas ao nível do seu grão mínimo: estação, variável e instante temporal. A classificação operacional da criticidade é representada diretamente através do atributo factual **nivel_alerta**, evitando a criação de uma dimensão autónoma de alerta e mantendo simples a leitura analítica das medições.

A tabela **Fact_Indicadores** corresponde a uma tabela factual derivada, orientada ao armazenamento de métricas agregadas e indicadores relevantes para análise comparativa e visualização. A partilha das dimensões conformadas com a tabela transacional permite que estas métricas sejam analisadas segundo os mesmos eixos temporal, espacial, operacional e hidrometeorológico.

A tabela **Fact_Evento_Cheia** introduz a perspetiva do evento como unidade discreta de análise. Esta tabela regista episódios candidatos de cheia, caracterizados por medidas como duração, precipitação total e nível máximo observado. A dimensão **Tipo de Evento** permite classificar estes episódios por tipo, severidade e origem, suportando análises históricas e comparativas.

A dimensão **Localização**, autónoma relativamente à dimensão **Estação de Monitorização**, concentra o enquadramento geográfico e hidrológico do sistema. A estação identifica o ponto técnico de recolha da observação, enquanto a localização contextualiza territorialmente esse ponto através de atributos como bacia, concelho, distrito, zona de risco e tipo de zona. Ambas as dimensões são partilhadas pelas tabelas de factos, assegurando coerência na análise espacial a diferentes níveis de detalhe.

A dimensão **Variável Monitorizada** explicita o tipo de fenómeno observado e a respetiva unidade física, permitindo distinguir precipitação, nível hidrométrico e cota de albufeira. Esta separação é essencial porque a interpretação e a agregação das medidas dependem da natureza da variável observada.

Em conjunto, este esquema dimensional permite suportar diferentes tipos de análise, desde a monitorização operacional até à análise histórica de episódios e produção de indicadores, mantendo coerência entre níveis de detalhe e simplicidade na exploração dos dados.

3.6 As Vistas dos Agentes de Decisão

A modelação dimensional desenvolvida no presente projeto foi concebida para suportar diferentes perfis de decisão, cada um com necessidades específicas de informação, níveis de detalhe distintos e objetivos analíticos próprios. A definição destas vistas permite explicitar como o modelo dimensional responde, de forma estruturada, aos requisitos identificados na fase de levantamento.

As vistas dos agentes de decisão não correspondem a estruturas físicas independentes no armazém de dados, mas sim a perspetivas de utilização construídas a partir das mesmas tabelas de factos e dimensões conformadas. Esta abordagem garante consistência entre análises, evitando redundância de dados e promovendo uma interpretação uniforme da informação.

No contexto do projeto, foram considerados três perfis principais: o Operador de Monitorização Hidrológica, o Coordenador Operacional de Risco e o Analista de Risco e Planeamento. Cada um destes perfis explora o modelo dimensional de forma distinta, privilegiando diferentes níveis de granularidade e tipos de indicadores.

Perfil de decisão	Foco principal	Tabela(s) de factos	Tipo de análise suportada
Operador de Monitorização Hidrológica	Monitorização corrente e deteção de situações críticas	Fact_Medicoes	Consulta de valores recentes, análise por hora, semana e mês, acompanhamento de variações e identificação de excedências de limiares

Coordenador Operacional de Risco	Comparação entre locais e avaliação de criticidade	Fact_Indicadores (principal); Fact_Medicoes e Fact_Evento_Cheia (complementar)	Análise agregada por período e localização, comparação entre zonas, identificação de áreas prioritárias e comparação entre eventos candidatos
Analista de Risco e Planeamento	Análise histórica e preparação de dados para previsão	Fact_Indicadores; Fact_Medicoes; Fact_Evento_Cheia	Agregações temporais, estudo de padrões e sazonalidade, análise de eventos candidatos e preparação de dados para modelos preditivos

Para o **Operador de Monitorização Hidrológica**, a vista privilegiada assenta na tabela de factos transacional, permitindo acompanhar a evolução recente das variáveis, analisar variações entre medições consecutivas e detetar situações próximas de limiares críticos. Esta vista exige granularidade fina e acesso direto às observações elementares.

O **Coordenador Operacional de Risco** utiliza predominantemente indicadores agregados, privilegiando a comparação entre estações, zonas da bacia e períodos temporais. A tabela **Fact_Indicadores** permite responder de forma mais eficiente a este tipo de análise, evitando o processamento repetido de grandes volumes de dados transacionais.

O **Analista de Risco e Planeamento** explora o sistema de forma mais abrangente, combinando observações detalhadas, indicadores agregados e registos de eventos candidatos. Esta vista suporta análise histórica, identificação de padrões e preparação de dados para modelos de previsão, exigindo flexibilidade na exploração das dimensões e acesso a diferentes níveis de granularidade.

A tabela **Fact_Evento_Cheia** é utilizada de forma complementar pelo **Coordenador Operacional de Risco**, que a usa para comparar episódios candidatos por severidade, localização e duração, e de forma mais aprofundada pelo **Analista de Risco e Planeamento**, que a utiliza para o estudo de recorrência sazonal, análise de padrões ao longo da bacia e seleção de variáveis para o desenvolvimento de modelos preditivos.

A existência destas três vistas confirma a adequação do modelo dimensional proposto, demonstrando que a combinação das três tabelas de factos com as dimensões conformadas e com a dimensão especializada **Tipo de Evento** permite responder, de forma integrada, a necessidades operacionais, táticas e analíticas, sem comprometer a coerência do sistema.

3.7 Modelo Lógico

3.7.1 Do Modelo Dimensional ao Modelo Lógico

A modelação conceptual desenvolvida nas secções anteriores, assente na notação DFM, descreve os processos analíticos, as medidas e as perspetivas de análise de forma independente da tecnologia de implementação. O modelo lógico constitui a etapa seguinte, traduzindo essas estruturas multidimensionais em tabelas relacionais concretas, com atributos tipificados, chaves primárias, chaves estrangeiras e relações explicitamente definidas. Esta etapa é necessária porque é a partir do modelo lógico que se gera o DDL de implementação no Microsoft SQL Server, se configuram os conectores do Power BI e se definem os scripts de carga ETL.

O modelo lógico foi elaborado com recurso ao MySQL Workbench, que disponibiliza uma notação relacional precisa para a representação de chaves primárias, chaves estrangeiras e tipos de dados. O resultado concretiza o galaxy schema definido conceptualmente, com três tabelas de factos, **Fact_Medicoes**, **Fact_Indicadores** e **Fact_Evento_Cheia**, e cinco dimensões, **Dim_Tempo**, **Dim_Estacao**, **Dim_Localizacao**, **Dim_Variavel** e **Dim_TipoEvento**.

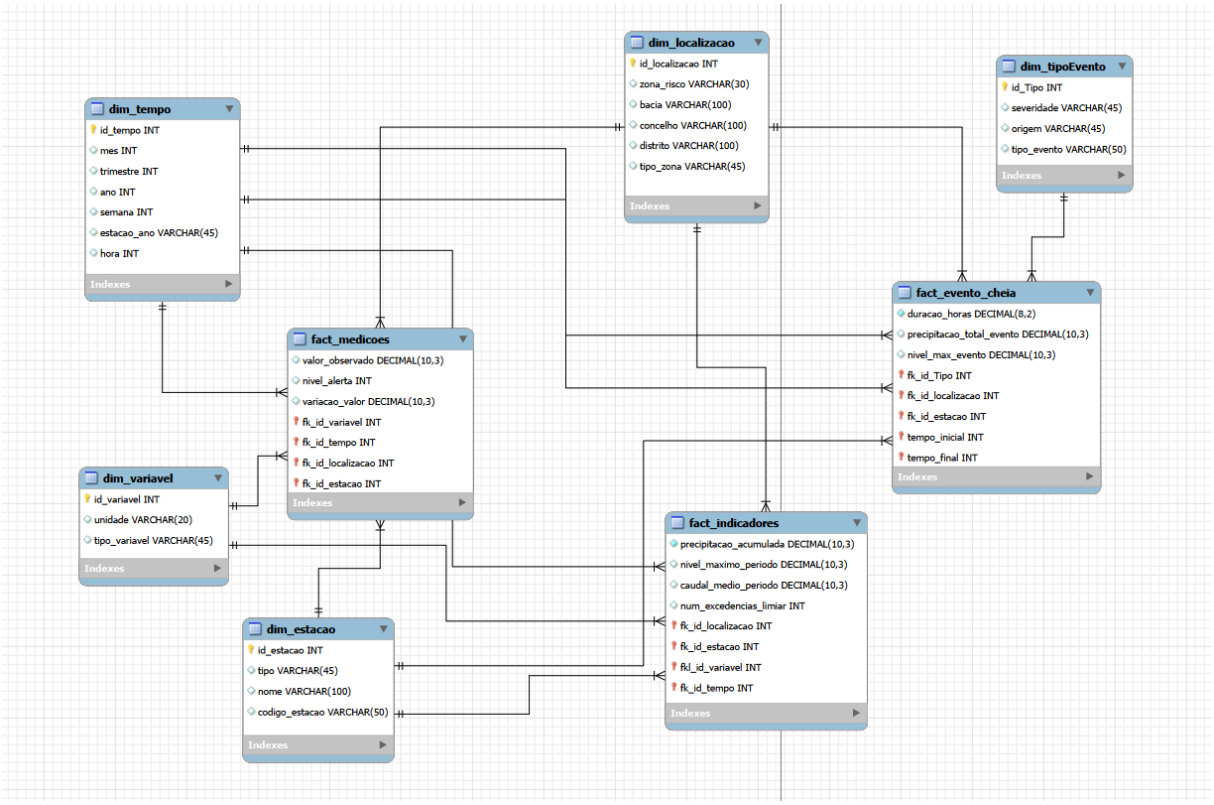


Figura 6: Modelo Lógico do Armazém de Dados

3.7.2 Convenções de Identificação e Tipos de Dados

Nas dimensões foi adotada uma chave primária inteira, designada **id_[dimensão]** ou, no caso da dimensão Tempo, **id_tempo**. Nas dimensões Estação, Localização, Variável e Tipo de Evento, estas chaves funcionam como identificadores técnicos do modelo relacional. Na dimensão Tempo, o atributo **id_tempo** corresponde a uma chave temporal calculada no formato **AAAAMMDDHH**, preservando diretamente a granularidade horária das observações. Todas estas chaves são referenciadas pelas tabelas de factos através de chaves estrangeiras.

As chaves estrangeiras nas tabelas de factos seguem uma convenção simplificada baseada no prefixo **fk_id**, identificando diretamente a dimensão referenciada. Na **Fact_Evento_Cheia**, a dimensão **Tempo** referenciada duas vezes através de **tempo_inicial** e **tempo_final**, representando os papéis de início e fim do episódio.

Tipo	Utilização e justificação
INT	Chaves primárias das dimensões, chaves estrangeiras das tabelas de factos, contadores e atributos temporais. No caso da Dim_Tempo, o identificador inteiro codifica o instante horário no formato AAAAMMDDHH.
VARCHAR(45)	Atributos descritivos de cardinalidade reduzida: classificações, estados operacionais e designações curtas.
VARCHAR(100)	Designações mais longas: nomes de estações, bacias, concelhos e topónimos portugueses em geral.
DECIMAL(10,3)	Medidas hidrometeorológicas: precipitação, nível hidrométrico, cota de albufeira e respetivos indicadores agregados.
DECIMAL(8,2)	Duração de episódios de cheia em horas, com componente fracionária para episódios cuja delimitação não coincide com horas completas.

3.7.3 Dimensões - Estrutura e Tipos de Dados

Dim_Tempo

A dimensão temporal apresenta a chave primária **id_tempo INT**, calculada no formato **AAAAMMDDHH**. Esta opção permite representar diretamente o instante horário de cada observação, mantendo simultaneamente compatibilidade com as chaves estrangeiras das tabelas de factos. Os atributos **mes**, **trimestre**, **ano**, **semana** e **hora** suportam operações de ordenação, filtragem e agregação temporal. O atributo **estacao_ano** é VARCHAR(45), por ser uma classificação textual categórica. A granularidade horária é indispensável para suportar análise intradiária da evolução dos episódios, cálculo de variações entre medições consecutivas e preparação de subconjuntos para modelos preditivos.

Dim_Estacao

A dimensão de estação usa **id_estacao INT** como chave primária. O atributo **codigo_estacao** é VARCHAR(45) e corresponde ao código natural da estação proveniente das fontes de dados, sendo mantido para rastreabilidade e resolução de chaves durante o povoamento. O atributo **nome** é VARCHAR(100), permitindo armazenar designações

completas das estações de monitorização. O atributo **tipo** é VARCHAR(45), adequado a classificações como “Hidrométrica” ou “Meteorológica”.

Dim_Localizacao

A dimensão de localização usa **id_localizacao INT** como chave primária. Os atributos territoriais **bacia**, **concelho** e **distrito** são VARCHAR(100), dimensão adequada à representação de topónimos portugueses. O atributo **zona_risco** é VARCHAR(30) e o atributo **tipo_zona** é VARCHAR(45), representando o enquadramento funcional da localização no sistema fluvial, por exemplo, “Montante”, “Intermédio” ou “Jusante”.

Dim_Variavel

A dimensão de variável usa **id_variavel INT** como chave primária. O atributo **tipo_variavel** é VARCHAR(45) e identifica o fenómeno observado, como precipitação, nível hidrométrico ou cota de albufeira. O atributo **unidade** é VARCHAR(20), suficiente para representar unidades físicas como mm ou m.

Dim_TipoEvento

A dimensão de tipo de evento usa **id_Tipo INT** como chave primária. Os atributos **severidade** e **origem** são VARCHAR(45), adequados a classificações categóricas de cardinalidade reduzida. O atributo **tipo_evento** é VARCHAR(50) e representa a designação geral do episódio, como “Cheia hidrométrica” ou “Evento pluviométrico intenso”, complementando a classificação por severidade e por origem e tornando a dimensão mais expressiva para análise histórica.

3.7.4 Tabelas de Factos - Estrutura e Justificação

Fact_Medicoes

A tabela de factos transacional referencia quatro dimensões via chaves estrangeiras: **fk_id_tempo**, **fk_id_estacao**, **fk_id_localizacao** e **fk_id_variavel**. O seu grão corresponde a uma medição por estação de monitorização, variável observada e instante temporal.

A medida principal é **valor_observado**, definida como DECIMAL(10,3), permitindo armazenar valores hidrometeorológicos como precipitação observada, nível hidrométrico e cota de albufeira. Para além desta medida elementar, foi incluída a medida derivada **variacao_valor**, que representa a diferença entre a medição atual e a medição anterior para a mesma estação e variável. Esta medida permite identificar subidas ou descidas recentes no comportamento observado, sem necessidade de manter o valor anterior como atributo autónomo na tabela de factos.

O atributo **nivel_alerta** foi implementado como INT diretamente na tabela de factos. Esta decisão justifica-se pela simplicidade e baixa cardinalidade da classificação operacional usada nesta fase, composta por quatro níveis: 0 - normal, 1 - atenção, 2 - alerta e 3 - crítico. Os limiares usados para esta classificação são definidos no processo ETL e tratados como regras operacionais exemplificativas. Ao incorporar **nivel_alerta** como atributo factual inteiro, simplifica-se o esquema relacional sem perda de expressividade analítica, mantendo a possibilidade de filtrar observações por nível, contar excedências e construir indicadores de criticidade nos dashboards.

Fact_Indicadores

A tabela de indicadores agregados referencia quatro dimensões: **Dim_Tempo**, **Dim_Estacao**, **Dim_Localizacao** e **Dim_Variavel**. As medidas **precipitacao_acumulada**, **nivel_maximo_periodo** e **caudal_medio_periodo** são DECIMAL(10,3), precisão consistente com a utilizada na tabela transacional. A medida **num_excedencias_limiar** é INT, uma vez

que representa uma contagem de observações. Não se usou DECIMAL para contagens pois seria semanticamente incorreto.

Fact_Evento_Cheia

A tabela de episódios de cheia referencia a **Dim_TipoEvento**, a **Dim_Localizacao**, a **Dim_Estacao** e a dimensão **Dim_Tempo** em modo **role-play**. A dimensão **Tempo** é referenciada duas vezes através das chaves **tempo_inicial** e **tempo_final**, representando respetivamente o instante de início e o instante de fim do episódio. Esta é a concretização lógica do padrão de dimensão role-play: a mesma dimensão temporal é reutilizada com dois papéis semânticos distintos, sem necessidade de criar uma segunda dimensão temporal com os mesmos valores.

A medida **duracao_horas** é DECIMAL(8,2) para acomodar durações com componente fracionária, dado que a delimitação do início e do fim de um episódio pode não coincidir exatamente com horas completas. As medidas **precipitacao_total_evento** e **nivel_max_evento** são DECIMAL(10,3), em coerência com a precisão adotada nas restantes tabelas de factos.

3.7.5 Síntese do Modelo Lógico

O modelo lógico concretiza o galaxy schema conceptual numa estrutura relacional com três tabelas de factos e cinco dimensões. A tabela seguinte sintetiza as decisões de concretização mais relevantes tomadas na passagem do modelo conceptual para o modelo lógico.

Decisão	Justificação
Chaves INT nas dimensões	Nas dimensões Estação, Localização, Variável e Tipo de Evento são usadas chaves substitutas inteiras. Na dimensão Tempo é usada uma chave temporal calculada no formato AAAAMMDDHH, preservando a granularidade horária e mantendo integridade referencial nas tabelas de factos.

nivel_alerta como INT na Fact_Medicoes	Cardinalidade muito reduzida (tipicamente quatro níveis); simplifica o esquema sem comprometer a capacidade analítica.
Referenciação dupla de Dim_Tempo na Fact_Evento_Cheia (**tempo_inicial** e **tempo_final**)	Implementação do padrão role-play para registar início e fim de cada episódio sem duplicar a dimensão temporal.
duracao_horas como DECIMAL(8,2)	Acomoda durações com componente fracionária quando a delimitação do episódio não coincide com horas completas.
DECIMAL(10,3) para medidas hidrometeorológicas	Precisão consistente entre tabelas de factos; adequada a precipitação, nível hidrométrico e cota de albufeira.

Em conjunto, estas decisões produzem um esquema coerente com o modelo conceptual e adequado à implementação no Microsoft SQL Server, assegurando consistência entre camadas e facilitando tanto a carga ETL como a exploração analítica via Power BI.

4. Arquitetura Geral do Sistema

4.1 Apresentação Geral

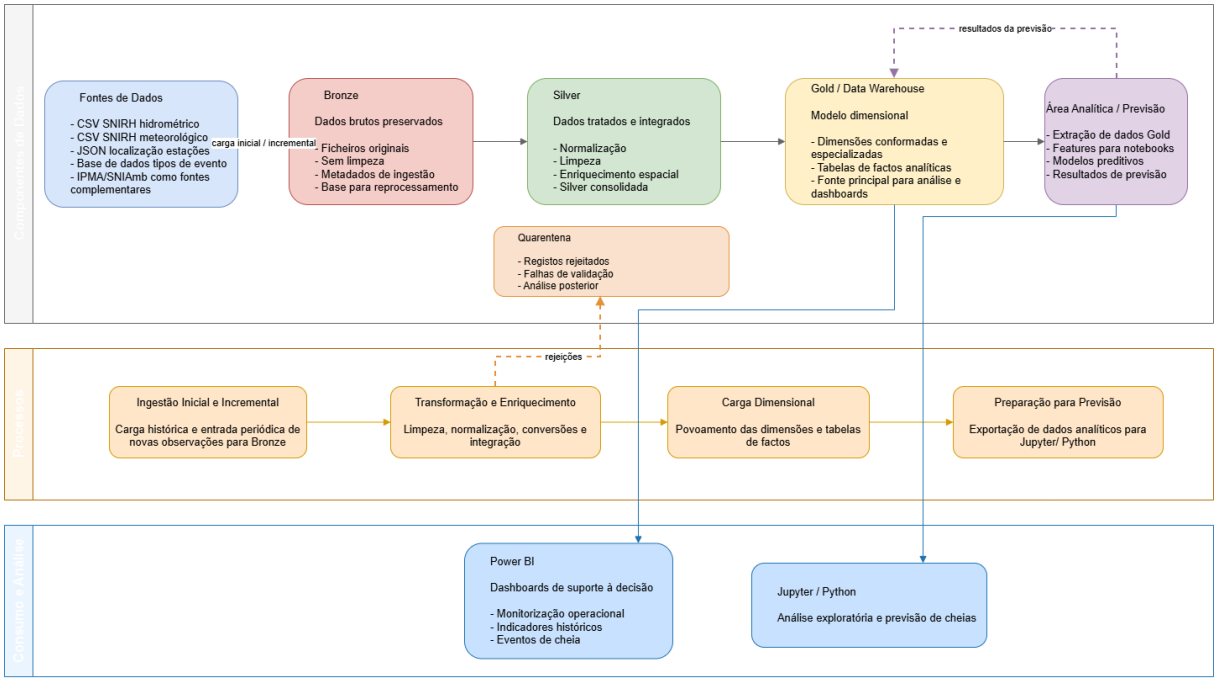
A arquitetura do sistema de suporte à decisão da HidroVigilância S.A. foi concebida segundo o paradigma de **Data Lakehouse**, combinando a flexibilidade de um **Data Lake** para armazenamento de dados brutos com a organização analítica de um **Data Warehouse**. Esta escolha justifica-se pelos requisitos do sistema, em particular RNF07, que exige a preservação do histórico completo de observações brutas, RNF08, que exige documentação da qualidade dos dados por fonte e por período, e RNF09, que exige que as transformações aplicadas sejam documentadas e reproduzíveis. A separação entre dados brutos, dados tratados e dados analíticos permite garantir rastreabilidade, reprocessamento e coerência na exploração da informação.

A solução organiza-se logicamente em três grandes áreas. A primeira corresponde aos **Componentes de Dados**, onde se representam as fontes externas, as camadas Bronze, Silver e Gold do Lakehouse, a zona de quarentena e a área analítica de preparação para previsão. A segunda corresponde aos **Processos**, que descrevem as operações aplicadas aos dados ao longo do seu ciclo de vida, desde a ingestão até à preparação de dados para modelos preditivos. A terceira corresponde à área de **Consumo e Análise**, onde se encontram as ferramentas usadas para visualização, exploração analítica e desenvolvimento preditivo.

A representação da arquitetura distingue explicitamente os locais onde os dados são armazenados das operações que atuam sobre esses dados. Esta separação é conceptualmente relevante porque evita confundir componentes persistentes, como Bronze, Silver ou Gold, com processos temporários, como ingestão, limpeza, transformação, enriquecimento, carga dimensional ou extração de dados para previsão.

O fluxo de dados é suportado por processos de pipeline implementados em ambiente Microsoft, com recurso a SQL Server Integration Services no Visual Studio para a execução das etapas de cópia, transformação, consolidação e carga. O armazenamento analítico da camada Gold é suportado pelo Microsoft SQL Server. A exploração visual é realizada em

Power BI, enquanto a componente de análise exploratória e previsão é preparada para ser desenvolvida em Python com notebooks Jupyter, consumindo dados analíticos extraídos da camada Gold.



A arquitetura apresentada na figura acima decompõe-se nos seguintes componentes e áreas de trabalho:

- **Fontes de Dados:** Sistemas e ficheiros externos que fornecem os dados de base ao sistema. No projeto são consideradas séries temporais hidrométricas e meteorológicas do SNIRH em formato CSV, um ficheiro JSON com informação de localização das estações, uma base de dados relacional com tipos de evento e, como fontes complementares, informação do IPMA e do SNIAmb. A heterogeneidade destas fontes justifica a adoção de uma arquitetura por camadas, capaz de preservar os dados originais e transformá-los progressivamente num modelo analítico coerente.
- **Data Lakehouse - Componentes de Dados:**
  - **Camada Bronze:** Camada onde os dados são mantidos no estado original, sem limpeza nem transformação. Esta camada preserva os ficheiros e estruturas recebidos das fontes, funcionando como base de reprocessamento e garantindo auditabilidade do percurso dos dados.

- **Zona de Quarentena:** Estrutura destinada a preservar registos rejeitados durante a validação. São encaminhados para esta zona dados que não cumprem regras mínimas de qualidade, como datas inválidas, valores não convertíveis ou ausência de atributos essenciais. A sua existência evita a perda de informação sobre erros de fonte e impede que registos não confiáveis avancem para Silver.
- **Camada Silver:** Camada onde os dados passam por limpeza, normalização, conversão de formatos, enriquecimento e consolidação. Nesta fase, os dados provenientes de diferentes fontes são integrados numa estrutura mais consistente, preparada para alimentar o modelo dimensional.
- **Camada Gold:** Camada analítica organizada segundo o modelo dimensional definido no capítulo 3. Nesta camada residem as dimensões conformadas e especializadas, bem como as tabelas de factos analíticas, constituindo a fonte principal para dashboards, consultas analíticas e preparação de dados para previsão.
- **Área Analítica / Previsão:** Área dedicada à preparação de dados para análise exploratória e modelos preditivos. Consome dados da camada Gold, gera conjuntos de dados orientados à previsão e suporta a produção de resultados analíticos associados ao risco de cheia.

- **Data Lakehouse - Processos:**
  - **Extração Inicial e Incremental:** Processo responsável pela entrada dos dados no sistema. A ingestão inicial carrega o histórico disponível para a camada Bronze, enquanto a ingestão incremental incorpora novas observações à medida que estas ficam disponíveis. Esta separação permite manter histórico analítico e, ao mesmo tempo, atualizar os dados. Inclui a consolidação das medições, o enriquecimento com informação territorial e de localização e o encaminhamento de registos inválidos para quarentena.
  - **Transformação e Preparação Silver:** Processo responsável pela limpeza, normalização, conversão, enriquecimento territorial, validação e consolidação dos dados. Nesta etapa são calculadas medidas derivadas, resolvidas associações dimensionais e, quando aplicável, os registos inválidos são encaminhados para a zona de quarentena prevista.

- **Carga Dimensional:** Processo responsável pelo povoamento das dimensões e tabelas de factos da camada Gold, a partir dos dados tratados na camada Silver.
- **Preparação para Previsão:** Processo responsável pela extração de dados analíticos da camada Gold para utilização em notebooks Jupyter/Python, com vista à análise exploratória e ao desenvolvimento de modelos preditivos.

- **Consumo e Análise:** Área onde os dados analíticos são explorados pelos agentes de decisão. O Power BI consome a camada Gold para produzir dashboards de monitorização operacional, indicadores históricos e eventos de cheia. Em paralelo, os notebooks Jupyter/Python consomem dados analíticos preparados para apoiar a análise exploratória e a futura previsão de situações de cheia.

4.2 Fontes de Dados

As fontes de dados consideradas no sistema foram selecionadas com base nos requisitos de decisão e funcionais identificados nos capítulos anteriores, tendo em conta a disponibilidade, acessibilidade e adequação ao caso de estudo da bacia do rio Mondego. A arquitetura proposta contempla fontes com formatos distintos, incluindo ficheiros CSV, ficheiros JSON e uma base de dados relacional de referência, permitindo demonstrar a integração de dados heterogéneos num modelo analítico comum.

No âmbito da implementação realizada, o SNIRH constitui a fonte operacional principal para as medições hidrometeorológicas. A informação de localização das estações é tratada através de um ficheiro de referência em formato JSON, posteriormente convertido e integrado na camada Silver. A classificação dos tipos de evento é disponibilizada através de uma base de dados relacional própria. O IPMA e o SNIAmb são considerados fontes complementares relevantes para evolução futura do sistema, nomeadamente para enriquecimento meteorológico, geográfico e preditivo.

SNIRH - Sistema Nacional de Informação de Recursos Hídricos

O SNIRH, gerido pela Agência Portuguesa do Ambiente, constitui a fonte de dados principal do sistema. Disponibiliza séries temporais de observações hidrometeorológicas recolhidas por uma rede de estações distribuídas pelo território nacional, incluindo estações localizadas na bacia do rio Mondego. No projeto, esta fonte suporta as medições de nível hidrométrico, cota de albufeira e precipitação utilizadas na construção da camada analítica.

SNIRH - Caracterização da fonte	
Tipo de dados	Séries temporais de observações hidrometeorológicas
Variáveis utilizadas	Precipitação (mm), nível hidrométrico (m) e cota de albufeira (m)
Granularidade temporal	Horária, de acordo com os ficheiros recolhidos para as estações selecionadas
Formato	CSV por estação e por variável
Cobertura utilizada	Séries temporais recolhidas para seis estações da bacia do Mondego
Limitações conhecidas	Possibilidade de falhas de registo, diferenças de disponibilidade entre estações e necessidade de normalização dos ficheiros antes da integração analítica
Elementos do modelo suportados	`Fact_Medicoes`, `Fact_Indicadores`, `Fact_Evento_Cheia`, `Dim_Estacao`, `Dim_Variavel`, `Dim_Tempo`
Acesso	https://snirh.apambiente.pt

Ficheiro JSON de localização das estações

Para complementar os dados provenientes do SNIRH, foi definido um ficheiro de referência em formato JSON com informação territorial e hidrológica das estações utilizadas no projeto. Esta fonte permite associar cada estação a atributos como bacia, concelho, distrito, zona de risco e tipo de zona, suportando a construção da dimensão `Dim_Localizacao`.

JSON de Localização - Caracterização da fonte	
Tipo de dados	Dados de referência territorial e hidrológica por estação
Dados disponíveis	Código da estação, nome da estação, bacia, concelho, distrito, zona de risco e tipo de zona
Formato	JSON
Periodicidade de atualização	Estática ou de atualização pontual
Limitações conhecidas	Fonte construída para o âmbito do caso de estudo, com valores de referência definidos para as estações selecionadas
Elementos do modelo suportados	`Dim_Localizacao` e enriquecimento territorial das medições

Base de dados de tipos de evento

A classificação dos tipos de evento foi representada através de uma base de dados relacional de referência. Esta fonte permite demonstrar a integração de dados provenientes de um sistema estruturado distinto dos ficheiros CSV e JSON, sendo utilizada para alimentar a dimensão `Dim_TipoEvento`.

Base de Dados de Tipos de Evento - Caracterização da fonte	
Tipo de dados	Dados de referência para classificação de eventos candidatos de cheia
Dados disponíveis	Designação do tipo de evento, severidade e origem
Formato	Tabela relacional
Periodicidade de atualização	Estática ou de atualização pontual
Limitações conhecidas	Classificação operacional definida para o âmbito do projeto, podendo ser refinada com validação por entidades especializadas
Elementos do modelo suportados	`Dim_TipoEvento` e `Fact_Evento_Cheia`

IPMA - Instituto Português do Mar e da Atmosfera

O IPMA disponibiliza dados meteorológicos observados e previstos através da sua API pública, incluindo observações meteorológicas, previsões e avisos. No contexto do presente projeto, o IPMA é considerado uma fonte complementar relevante para evolução futura do sistema, sobretudo para reforçar a componente de previsão e enriquecer a análise meteorológica associada ao risco de cheia.

IPMA - Caracterização da fonte complementar	
Tipo de dados	Dados meteorológicos observados e previstos, avisos meteorológicos
Dados disponíveis	Previsões meteorológicas, observações recentes e avisos por área geográfica
Formato	JSON via API pública
Periodicidade de atualização	Intra-diária, dependendo do produto disponibilizado
Limitações conhecidas	Dados orientados a localidades ou áreas meteorológicas, exigindo mapeamento adicional para integração direta com estações hidrométricas
Utilização prevista	Enriquecimento meteorológico e variáveis de entrada para modelos preditivos
Acesso	https://api.ipma.pt

SNIAmb - Sistema Nacional de Informação de Ambiente

O SNIAmb disponibiliza informação geográfica e ambiental de referência para o território nacional. No contexto do projeto, é considerado uma fonte complementar relevante para validação e enriquecimento futuro dos atributos territoriais associados à dimensão `Dim_Localizacao`, nomeadamente zonas inundáveis, delimitações hidrográficas e limites administrativos.

SNIAmb - Caracterização da fonte complementar	
Tipo de dados	Informação geográfica e ambiental de referência
Dados disponíveis	Zonas inundáveis, limites administrativos, informação territorial e ambiental
Formato	Serviços geográficos, shapefiles ou GeoJSON, dependendo do produto disponibilizado
Periodicidade de atualização	Estática ou de atualização pouco frequente
Limitações conhecidas	Exige tratamento geoespacial e cruzamento com coordenadas ou entidades territoriais compatíveis
Utilização prevista	Validação e enriquecimento futuro da dimensão `Dim_Localizacao`
Acesso	https://sniambgeoviewer.apambiente.pt

A tabela seguinte sintetiza a correspondência entre fontes de dados e componentes do modelo dimensional, permitindo verificar a origem principal dos dados usados em cada elemento analítico.

Componente do Modelo	**Fonte Principal**	**Fonte Complementar**
`Fact_Medicoes`	SNIRH	
`Fact_Indicadores`	`Fact_Medicoes`	
`Fact_Evento_Cheia`	`Fact_Medicoes`	`Dim_TipoEvento`
`Dim_Tempo`	Data/hora das medições SNIRH	
`Dim_Estacao`	SNIRH	
`Dim_Localizacao`	JSON de localização das estações	SNIAmb
`Dim_Variavel`	SNIRH	
`Dim_TipoEvento`	Base de dados de tipos de evento	

Área Analítica / Previsão	Gold (`Fact_Medicoes`, `Fact_Indicadores`, `Fact_Evento_Cheia`)	IPMA

4.3 Área de Preparação de dados

A área de preparação de dados do sistema corresponde às camadas Bronze e Silver da arquitetura, complementadas por uma zona de quarentena para registos rejeitados durante a validação. Esta área funciona como espaço intermédio entre as fontes de dados e o armazém de dados analítico, evitando que dados brutos ou inconsistentes sejam carregados diretamente na camada Gold.

A existência desta área justifica-se, em primeiro lugar, pela heterogeneidade das fontes. Os dados considerados no projeto chegam em formatos diferentes, nomeadamente ficheiros CSV provenientes do SNIRH, um ficheiro JSON de referência para localização das estações e uma base de dados relacional com tipos de evento. Esta diversidade exige uma zona intermédia onde os dados possam ser preservados, normalizados e integrados antes de alimentarem o modelo dimensional.

A segunda razão prende-se com a qualidade dos dados. As séries temporais hidrometeorológicas podem apresentar falhas de registo, diferenças de estrutura entre ficheiros, valores em falta, linhas informativas, cabeçalhos ou valores que exigem validação antes da análise. A existência de uma área de preparação permite aplicar regras de validação sem alterar diretamente os dados brutos recebidos das fontes.

A terceira razão é a rastreabilidade e o reprocessamento. A separação entre dados brutos na camada Bronze, dados tratados na camada Silver e registos rejeitados em quarentena permite reconstruir o percurso dos dados ao longo do pipeline. Sempre que uma regra de transformação, um limiar de alerta ou uma associação dimensional é alterada, o processo pode ser reexecutado a partir dos dados preservados na Bronze, sem depender novamente das fontes externas.

Camada Bronze

A camada Bronze atua como repositório dos dados no seu estado original. Os ficheiros e estruturas recebidos das fontes são carregados sem aplicação de regras analíticas, preservando a estrutura inicial dos dados. Esta camada é essencial para garantir auditabilidade e reprocessamento, uma vez que qualquer transformação aplicada posteriormente pode ser revista ou repetida a partir da mesma base original.

No contexto do projeto, a Bronze inclui os ficheiros CSV do SNIRH, o ficheiro JSON de localização das estações e os dados de referência provenientes da base de dados de tipos de evento. Para além dos atributos provenientes das fontes, a Bronze prevê metadados técnicos de ingestão, como um identificador interno do registo e a data de entrada no sistema. Estes metadados não alteram o conteúdo da fonte, mas permitem controlar quando cada registo foi carregado e suportam a análise de execuções incrementais.

Camada Bronze	
Função	Preservar os dados brutos tal como chegam das fontes
Transformações aplicadas	Nenhuma transformação analítica; apenas registo técnico de ingestão
Conteúdo	CSV SNIRH hidrométrico, CSV SNIRH meteorológico, JSON de localização das estações e dados de referência dos tipos de evento
Metadados técnicos	Identificador interno do registo e data/hora de ingestão
Utilidade	Auditabilidade, rastreabilidade, suporte a cargas incrementais e possibilidade de reprocessamento
Requisitos suportados	RNF07, RNF08, RNF09

Camada Silver

A camada Silver recebe os dados da Bronze e aplica as transformações necessárias para os tornar consistentes e preparados para o carregamento dimensional. Nesta camada são realizadas operações de limpeza, normalização, conversão de tipos, uniformização de nomes de atributos, enriquecimento com dados de localização e consolidação das medições numa estrutura integrada.

No caso das medições do SNIRH, a preparação inclui a normalização das colunas, a identificação da estação, do tipo de estação, da variável observada, da unidade, do valor

observado e do instante temporal. A partir da data e hora original são derivados atributos temporais como hora, semana, mês, trimestre, ano e estação do ano. As medições são ainda enriquecidas com informação territorial proveniente do ficheiro de localização, como bacia, concelho, distrito, zona de risco e tipo de zona.

A Silver concentra também as derivações necessárias para o modelo factual, incluindo o cálculo do nível de alerta, a variação entre medições consecutivas, os indicadores agregados e os eventos candidatos de cheia. Esta decisão evita que a camada Gold contenha lógica operacional de transformação, mantendo-a como camada de publicação analítica.

O resultado principal desta camada é um conjunto de fontes Silver já preparadas para carga analítica: uma fonte consolidada de medições enriquecidas, uma fonte derivada para a `Fact_Medicoes`, uma fonte agregada para a `Fact_Indicadores` e uma fonte de eventos candidatos para a `Fact_Evento_Cheia`. Desta forma, as operações de limpeza, cálculo de medidas derivadas, agregação de indicadores e identificação de eventos candidatos ocorrem na área de preparação, ficando a camada analítica responsável sobretudo pelo povoamento dimensional e factual.

Camada Silver	
Função	Limpar, normalizar, enriquecer, validar e consolidar os dados preparados para carga analítica
Transformações aplicadas	Normalização de colunas, conversão de tipos, derivação de atributos temporais, enriquecimento territorial, cálculo de medidas derivadas e resolução de chaves estrangeiras
Conteúdo	Dimensões preparadas, medições consolidadas, indicadores agregados e eventos candidatos de cheia
Output	Dados preparados para publicação na camada Gold
Requisitos suportados	RNF02, RNF07, RNF08, RNF09

Zona de Quarentena

A zona de quarentena é usada para armazenar registos que não cumprem as regras mínimas de validação durante a passagem de Bronze para Silver. São exemplos de registos a

encaminhar para esta zona linhas com datas inválidas, valores observados não convertíveis, atributos obrigatórios em falta ou falhas na associação a dimensões essenciais.

A decisão de manter estes registos em quarentena, em vez de os eliminar, é relevante para a qualidade do sistema. Em dados hidrometeorológicos, a ausência ou incorreção de valores pode estar associada a falhas de sensores, problemas de transmissão ou diferenças de estrutura entre ficheiros. Preservar estes registos permite analisar posteriormente a origem dos problemas, medir a qualidade das fontes e corrigir regras de transformação sem perder evidência do erro.

Zona de Quarentena	
Função	Preservar registos rejeitados durante a validação
Critérios de encaminhamento	Datas inválidas, valores não convertíveis, campos essenciais em falta ou falhas de associação dimensional
Utilidade	Análise da qualidade das fontes, rastreabilidade de rejeições e suporte à correção de regras ETL
Relação com Silver	Apenas registos validados avançam para Silver; registos rejeitados permanecem disponíveis para análise posterior
Requisitos suportados	RNF08, RNF09

A organização da área de preparação permite que o armazém de dados seja alimentado apenas por dados válidos, mantendo simultaneamente acesso aos dados brutos e aos registos rejeitados. Esta separação é essencial para sustentar o processo de integração de dados, uma vez que permite distinguir dados de origem, dados em preparação, dados rejeitados e dados analíticos publicados.

4.4 O Armazém de Dados

O armazém de dados do sistema corresponde à camada Gold da arquitetura e constitui a estrutura analítica otimizada para consulta, exploração e suporte à decisão. É alimentado a partir dos dados preparados na camada Silver, recebendo informação já limpa, normalizada, enriquecida e derivada. Deste modo, a camada Gold não tem como função principal executar

transformações operacionais complexas, mas sim organizar os dados no modelo dimensional definido para análise.

A organização do armazém de dados segue o modelo dimensional definido no capítulo 3, assente numa estrutura de constelação (**galaxy schema**) na qual três tabelas de factos partilham um conjunto de dimensões conformadas. Esta estrutura garante consistência semântica entre diferentes níveis de análise e permite relacionar observações detalhadas, indicadores agregados e eventos candidatos de cheia através dos mesmos eixos temporais, espaciais e semânticos.

A `Fact_Medicoes` armazena as observações hidrometeorológicas elementares, tendo como grão uma medição por estação, variável observada e instante temporal. Inclui a medida `valor_observado`, o atributo factual `nivel_alerta` e a medida derivada `variacao_valor`, constituindo o repositório de detalhe máximo do sistema. A `Fact_Indicadores` armazena indicadores agregados previamente preparados na camada Silver, como `precipitacao_acumulada`, `nivel_maximo_periodo`, `caudal_medio_periodo` e `num_excedencias_limiar`. A métrica `caudal_medio_periodo` corresponde, na implementação atual, ao valor médio observado no período, apesar da designação física herdada. A `Fact_Evento_Cheia` regista eventos candidatos derivados das medições em alerta, caracterizados pela sua duração, precipitação total e nível máximo, suportando a análise histórica de situações críticas e a preparação de dados para modelos de previsão.

As dimensões conformadas `Dim_Tempo`, `Dim_Estacao` e `Dim_Localizacao` são partilhadas pelas três tabelas de factos, assegurando consistência temporal, operacional e territorial entre medições elementares, indicadores agregados e eventos candidatos de cheia. A `Dim_Variavel` é partilhada pela Fact_Medicoes e pela Fact_Indicadores, permitindo distinguir o fenómeno monitorizado e a unidade associada. A `Dim_TipoEvento` é utilizada exclusivamente pela Fact_Evento_Cheia, permitindo classificar os eventos candidatos segundo a sua severidade, origem e tipo de evento.

Paradigma	Modelo dimensional galaxy schema (constelação)
Tabelas de factos	`Fact_Medicoes` (uma medição por estação, variável e instante temporal), `Fact_Indicadores` (indicadores agregados por estação, localização, variável e período temporal), `Fact_Evento_Cheia` (eventos candidatos derivados de medições em alerta)
Dimensões conforme	`Dim_Tempo`, `Dim_Estacao`, `Dim_Localizacao`, `Dim_Variavel` partilhadas pelas tabelas de factos
Dimensões especializadas	`Dim_TipoEvento` utilizada na classificação dos eventos candidatos de cheia
Motor de armazenamento	Microsoft SQL Server usado na implementação prática da camada Gold
Interface de acesso	SQL analítico standard, compatível com Power BI, Jupyter/Python e com os processos ETL implementados em Visual Studio/SSIS

A escolha do Microsoft SQL Server justifica-se por três razões. Primeiro, por ser uma plataforma relacional madura com suporte nativo a consultas analíticas SQL, adequada para o galaxy schema definido no capítulo 3. Segundo, por se integrar de forma nativa com o Microsoft SSIS utilizado na orquestração dos pipelines, simplificando a arquitetura tecnológica global. Terceiro, por oferecer mecanismos robustos de controlo de acesso e auditoria, suportando os requisitos de rastreabilidade do sistema.

4.5 Exploração e Visualização de Dados

A componente de exploração e visualização tem como objetivo tornar acessível a informação armazenada na camada Gold, disponibilizando interfaces interativas que permitem aos diferentes perfis de decisão consultar, filtrar e interpretar os dados de acordo com as suas necessidades. Esta componente responde diretamente aos requisitos RF05, RF06, RF10, RF11 e RF12, bem como aos requisitos não funcionais RNF05 e RNF06.

O sistema de dashboarding consome as tabelas de factos da camada Gold: a `Fact_Medicoes`, para análise detalhada das observações; a `Fact_Indicadores`, para análise agregada de indicadores; e a `Fact_Evento_Cheia`, para análise de eventos candidatos derivados de situações críticas. A exploração organiza-se em três vistas diferenciadas, correspondendo aos três perfis de agentes de decisão identificados no capítulo 2.

Sistema de Dashboarding	
Ferramenta	Power BI, enquanto plataforma de visualização e análise de dados
Fonte de dados	Camada Gold implementada em Microsoft SQL Server, acedida através de conector SQL
Tabelas consumidas	`Fact_Medicoes` (observações detalhadas), `Fact_Indicadores` (indicadores agregados), `Fact_Evento_Cheia` (eventos candidatos de cheia)
Tipo de visualizações	Séries temporais, indicadores de estado, tabelas comparativas e representações territoriais por concelho, bacia, zona de risco e tipo de zona
Requisitos suportados	RF05, RF06, RF10, RF11, RF12, RNF05, RNF06

A escolha do Power BI justifica-se por três razões principais. Primeiro, pela adequação à construção de dashboards interativos orientados à exploração de séries temporais, indicadores e filtros territoriais. Segundo, pelo suporte a conectores SQL para o Microsoft SQL Server, permitindo consumir diretamente a camada Gold sem criar uma camada intermédia adicional. Terceiro, pela facilidade de configurar medidas, filtros e elementos visuais que destacam situações de criticidade, recorrendo aos atributos `nivel_alerta` da `Fact_Medicoes` e `num_excedencias_limiar` da `Fact_Indicadores`.

As três vistas do sistema organizam-se da seguinte forma:

- A **vista do Operador de Monitorização Hidrológica** centra-se na consulta da situação recente das estações, nos valores observados de precipitação, nível hidrométrico e cota de albufeira, e na evolução temporal das medições. Esta vista utiliza sobretudo a `Fact_Medicoes`, por ser a tabela com o maior detalhe temporal, e responde aos requisitos RD01, RD02 e RD03.
- A **vista do Coordenador Operacional de Risco** centra-se na comparação entre zonas, estações e períodos, recorrendo aos indicadores agregados da `Fact_Indicadores` e aos atributos territoriais da `Dim_Localizacao`, como `bacia`, `concelho`, `distrito`, `zona_risco` e `tipo_zona`. Esta vista permite identificar áreas com maior número de excedências e comparar comportamentos entre locais, respondendo aos requisitos RD04, RD05 e RD06.
- A **vista do Analista de Risco e Planeamento** centra-se na exploração histórica e na preparação de análises mais avançadas. Utiliza séries temporais da `Fact_Medicoes`, agregações da `Fact_Indicadores` e eventos candidatos da `Fact_Evento_Cheia`, permitindo estudar

padrões temporais, sazonalidade, recorrência de situações críticas e relações entre precipitação e resposta hidrométrica. Esta vista responde aos requisitos RD07, RD08 e RD09.

4.6 Aquisição de Conhecimento

Neste projeto a aquisição de conhecimento é adaptada ao domínio da monitorização hidrometeorológica. A componente analítica procura caracterizar perfis de comportamento hidrometeorológico por estação, variável, período temporal e zona de risco, bem como suportar a previsão de situações críticas associadas a cheias na bacia do Mondego.

A componente de aquisição de conhecimento tem como objetivo transformar os dados integrados no armazém de dados em conhecimento analítico e preditivo. Esta componente utiliza os dados estruturados da camada Gold, disponibilizados através da camada de serving para Jupyter/Python, permitindo construir conjuntos de dados analíticos, explorar padrões históricos, criar variáveis derivadas e desenvolver modelos de previsão.

Ao contrário das componentes Bronze, Silver e Gold, a aquisição de conhecimento não corresponde a uma nova camada transacional nem a uma nova tabela factual do armazém de dados. Trata-se de uma componente analítica de exploração e modelação, executada sobre dados já consolidados e validados. Esta decisão é justificada pelo facto de os resultados de modelos preditivos dependerem de parametrizações, janelas temporais, algoritmos, métricas de avaliação e versões de treino. Por esse motivo, nesta fase do projeto, as previsões são tratadas como artefactos analíticos produzidos em ambiente Jupyter/Python e não como factos observados persistidos no modelo dimensional principal.

Componente de Aquisição de Conhecimento	
Objetivo	Extrair conhecimento analítico e preditivo a partir dos dados hidrometeorológicos integrados, apoiando a identificação de padrões e a previsão de risco de cheia
Fonte de dados	Dataset analítico exportado a partir da camada Gold/Serving, contendo medições, atributos temporais, informação de estação, localização, variável, nível de alerta, variação do valor e indicadores agregados

Unidade de análise	Medições e séries temporais por estação, variável observada, instante temporal e contexto territorial
Implementação	Python com notebooks Jupyter, permitindo exploração interativa, documentação do processo analítico e experimentação com modelos
Preparação analítica	Criação de variáveis temporais, lags, médias móveis, acumulados de precipitação, variações entre medições e seleção de subconjuntos por estação, variável e período
Tipo de modelos	Modelos de previsão e classificação de risco baseados em séries temporais e variáveis hidrometeorológicas, detalhados no capítulo 7
Output	Datasets de features, métricas de avaliação, modelos treinados e previsões experimentais produzidas em Jupyter/Python
Integração	Os resultados podem ser analisados em Jupyter e, numa evolução futura, poderão ser reintegrados numa camada de serving ou numa tabela específica de previsões, desde que sejam acompanhados de metadados como versão do modelo, horizonte de previsão e data de geração
Requisitos suportados	RD09, RF11, RF12

A utilização de Jupyter/Python justifica-se pela natureza exploratória da aquisição de conhecimento. Esta fase exige testes sucessivos de variáveis, janelas temporais, métodos de validação e algoritmos, o que torna mais adequado um ambiente flexível e documentável do que a inclusão direta desta lógica no processo ETL principal. O armazém de dados mantém-se, assim, como fonte estruturada e confiável de factos observados e indicadores derivados, enquanto a componente de aquisição de conhecimento concentra-se na exploração, modelação e avaliação de previsão.

5. O Povoamento de Dados

5.1 Apresentação da Abordagem Realizada

O processo de integração de dados foi desenvolvido segundo uma abordagem ETL organizada por camadas, acompanhando a arquitetura Data Lakehouse definida no capítulo anterior. A integração não foi concebida como uma carga direta das fontes para o armazém de dados, uma vez que as fontes apresentam formatos, granularidades e estruturas distintas. Em vez disso, foi definido um processo por fases, no qual os dados são primeiro preservados na Bronze, depois preparados e validados na Silver, e só posteriormente publicados na Gold.

Esta abordagem permite separar responsabilidades ao longo do pipeline. A Bronze funciona como camada de preservação da origem, mantendo os dados recebidos das fontes e os respetivos metadados técnicos de ingestão. A Silver concentra as transformações, validações, normalizações, enriquecimentos e cálculos derivados. A Gold disponibiliza a versão final do modelo dimensional, já preparada para exploração analítica, visualização e aquisição de conhecimento.

O processo foi concebido para suportar dois modos complementares de carregamento: carga inicial e carga incremental. A carga inicial permite construir a base histórica necessária à análise, integrando o conjunto de dados disponível nas fontes. A carga incremental permite incorporar novas observações à medida que estas são disponibilizadas, sem reprocessar continuamente todo o histórico. Esta decisão é coerente com o contexto de monitorização de cheias, uma vez que o sistema necessita de histórico para análise de padrões e comparação, mas também de atualização recorrente para apoiar a vigilância operacional.

A integração incremental é suportada pela existência de metadados de ingestão na Bronze, como identificador interno e data de entrada do registo. Estes metadados permitem distinguir registos já carregados de novas observações e acompanhar o momento em que os dados entram no sistema. A utilização de metadados técnicos não altera o conteúdo funcional das fontes, mas aumenta a capacidade de rastreabilidade e controlo do processo de integração.

Durante a passagem de Bronze para Silver, os dados são sujeitos a regras de validação. Registos que não cumprem condições mínimas, como datas válidas, valores convertíveis ou atributos essenciais preenchidos, não avançam para o fluxo analítico principal. Em vez de serem eliminados, são encaminhados para uma zona de quarentena. Esta decisão preserva evidência dos problemas encontrados nas fontes e permite analisar posteriormente a qualidade dos dados rejeitados sem contaminar as estruturas Silver e Gold.

A ordem de execução do povoamento foi definida de acordo com as dependências do modelo dimensional. Primeiro são carregadas as fontes para Bronze. Em seguida, são povoadas as dimensões na Silver, uma vez que as tabelas de factos dependem das respetivas chaves estrangeiras. Depois é carregada a `Fact_Medicoes`, que constitui o núcleo factual do sistema. A partir desta tabela são derivadas a `Fact_Indicadores` e a `Fact_Evento_Cheia`. Por fim, as estruturas validadas na Silver são publicadas na Gold, respeitando novamente a ordem entre dimensões e factos para garantir integridade referencial.

A notação utilizada para modelar o processo foi BPMN. Esta notação permitiu representar as tarefas de ingestão, transformação, validação, carregamento e publicação de forma independente da ferramenta técnica utilizada. A utilização de BPMN é bastante adequada porque explicita a sequência dos subprocessos, os pontos de paralelização, as dependências entre tarefas e os fluxos alternativos, como o encaminhamento de registos inválidos para quarentena.

A implementação técnica foi realizada em Microsoft Visual Studio com SQL Server Integration Services. Ao nível do **Control Flow**, foram definidas as dependências entre as tarefas de carga, assegurando que as dimensões são carregadas antes das tabelas de factos e que a Gold só é publicada depois da preparação na Silver. Ao nível do **Data Flow**, foram utilizados componentes de leitura, conversão de dados, ordenação, `Conditional Split`, `Lookup`, `Multicast`, componentes de script e destinos `OLE DB`.

Os componentes `Conditional Split` foram utilizados para separar registos válidos de registos inválidos, permitindo impedir que cabeçalhos, linhas informativas ou valores não convertíveis avançassem para as estruturas analíticas. Os componentes `Lookup` foram utilizados

para resolver as chaves estrangeiras das tabelas de factos através das dimensões previamente carregadas. Os componentes de script foram utilizados quando a estrutura original das fontes exigia normalização específica, cálculo de medidas derivadas ou identificação de eventos candidatos.

Abordagem de Integração de Dados	
Método	Processo ETL estruturado por camadas
Camadas envolvidas	Bronze, Silver, Quarentena e Gold
Modo de carregamento	Carga inicial para construção histórica e carga incremental para novas observações
Notação de modelação	BPMN para representação dos subprocessos e dependências
Ferramentas de implementação	Microsoft Visual Studio/SSIS, Microsoft SQL Server e SQL Server Management Studio
Componentes principais	Flat File Source, OLE DB Source, Script Component, Conditional Split, Data Conversion, Sort, Lookup, Multicast e OLE DB Destination
Mecanismos de controlo	Metadados de ingestão, validação de registos, encaminhamento para quarentena e verificação de integridade referencial

A abordagem realizada estabelece uma separação clara entre preservação, preparação e publicação dos dados. Esta separação permite que o sistema integre fontes heterogéneas, mantenha rastreabilidade sobre os dados recebidos, controle registos rejeitados e disponibilize uma camada analítica coerente com o modelo dimensional construído.

5.2 Mapeamento de Dados

O mapeamento de dados foi desenvolvido segundo uma lógica **source-to-target**, identificando, para cada atributo de destino, a respetiva origem, o tipo de dados, a transformação aplicada e a tabela final onde o atributo é carregado.

A primeira etapa do mapeamento corresponde à consolidação das medições hidrometeorológicas. Os ficheiros CSV do SNIRH são normalizados para uma estrutura comum, independentemente da estação ou variável monitorizada. Esta normalização permite integrar medições hidrométricas e meteorológicas numa estrutura Silver coerente, preparada para povoar as dimensões e tabelas de factos do modelo dimensional.

Mapeamento para a dimensão Tempo

Origem	Atributo origem	Tipo origem	Transformação	Atributo destino	Tipo destino	Destino
Bronze / séries SNIRH	data_hora_raw	VARCHAR	Calcular id_tempo no formato AAAAMMDDHH a partir da data e hora da observação.	id_tempo	INT	Dim_Tempo
Bronze / séries SNIRH	data_hora_raw	VARCHAR	Extrair a hora da observação.	hora	INT	Dim_Tempo
Bronze / séries SNIRH	data_hora_raw	VARCHAR	Calcular a semana do ano.	semana	INT	Dim_Tempo
Bronze / séries SNIRH	data_hora_raw	VARCHAR	Extrair o mês da observação.	mes	INT	Dim_Tempo
Bronze / séries SNIRH	data_hora_raw	VARCHAR	Calcular o trimestre a partir do mês.	trimestre	INT	Dim_Tempo
Bronze / séries SNIRH	data_hora_raw	VARCHAR	Extrair o ano da observação.	ano	INT	Dim_Tempo
Bronze / séries SNIRH	data_hora_raw	VARCHAR	Classificar o mês na respetiva estação do ano.	estacao_ano	VARCHAR	Dim_Tempo

Mapeamento para a dimensão Estação

Origem	Atributo origem	Tipo origem	Transformação	Atributo destino	Tipo destino	Destino
Bronze / localização	codigo_estacao	VARCHAR	Manter código natural da estação para rastreabilidade e resolução de chaves.	codigo_estacao	VARCHAR	Dim_Estacao
Bronze / localização	nome_estacao	VARCHAR	Normalizar designação da estação.	nome	VARCHAR	Dim_Estacao
Bronze / localização	tipo_estacao	VARCHAR	Classificar estação segundo a sua função operacional.	tipo	VARCHAR	Dim_Estacao

Mapeamento para a dimensão Localização

Origem	Atributo origem	Tipo origem	Transformação	Atributo destino	Tipo destino	Destino
Bronze / localização	bacia	VARCHAR	Associar estação à bacia hidrográfica principal.	bacia	VARCHAR	Dim_Localizacao
Bronze / localização	concelho	VARCHAR	Associar estação ao concelho correspondente.	concelho	VARCHAR	Dim_Localizacao
Bronze / localização	distrito	VARCHAR	Associar estação ao distrito correspondente.	distrito	VARCHAR	Dim_Localizacao
Bronze / localização	zona_risco	VARCHAR	Classificar localização segundo o nível de risco territorial.	zona_risco	VARCHAR	Dim_Localizacao
Bronze / localização	tipo_zona	VARCHAR	Classificar posição funcional da estação no sistema fluvial.	tipo_zona	VARCHAR	Dim_Localizacao

Mapeamento para a dimensão Variável

Origem	Atributo origem	Tipo origem	Transformação	Atributo destino	Tipo destino	Destino
Bronze / séries SNIRH	tipo_variavel	VARCHAR	Normalizar tipo da variável observada.	tipo_variavel	VARCHAR	Dim_Variavel
Bronze / séries SNIRH	unidade	VARCHAR	Normalizar unidade de medida associada à variável.	unidade	VARCHAR	Dim_Variavel

Mapeamento para a dimensão Tipo de Evento

Origem	Atributo origem	Tipo origem	Transformação	Atributo destino	Tipo destino	Destino
Bronze / tipo evento ref.	designacao_evento	VARCHAR	Normalizar designação do tipo de evento.	tipo_evento	VARCHAR	Dim_TipoEvento
Bronze / tipo evento ref.	grau_operacional	VARCHAR	Normalizar classificação de severidade do evento.	severidade	VARCHAR	Dim_TipoEvento
Bronze / tipo evento ref.	origem_evento	VARCHAR	Normalizar origem do evento.	origem	VARCHAR	Dim_TipoEvento

Mapeamento para a Fact_Medicoes

Origem	Atributo origem	Tipo origem	Transformação	Atributo destino	Tipo destino	Destino
Silver / medições normalizadas	valor_observado_raw	VARCHAR	Converter valor observado para decimal e preservar a medição validada.	valor_observado	DECIMAL(10,3)	Fact_Medicoes
Silver / regras ETL	valor_observado	DECIMAL	Comparar valor observado com limiares operacionais definidos por variável e estação.	nivel_alerta	INT	Fact_Medicoes
Silver / regras ETL	Valor observado atual e anterior	DECIMAL	Calcular diferença entre medições consecutivas da mesma estação e variável.	variacao_valor	DECIMAL(10,3)	Fact_Medicoes
Silver / lookup	codigo_estacao	VARCHAR	Resolver chave estrangeira através de Dim_Estacao.	fk_id_estacao	INT	Fact_Medicoes
Silver / lookup	tipo_variavel	VARCHAR	Resolver chave estrangeira através de Dim_Variavel.	fk_id_variavel	INT	Fact_Medicoes
Silver / lookup	id_tempo	INT	Resolver chave estrangeira através de Dim_Tempo, usando o identificador AAAAMMDDHH.	fk_id_tempo	INT	Fact_Medicoes
Silver / lookup	bacia, concelho, distrito, zona_risco, tipo_zona	VARCHAR	Resolver chave estrangeira através de Dim_Localizacao.	fk_id_localizacao	INT	Fact_Medicoes

Mapeamento para a Fact_Indicadores

Origem	Atributo origem	Tipo origem	Transformação	Atributo destino	Tipo destino	Destino
Silver / Fact_Medicoes	valor_observado	DECIMAL	Somar valores observados quando a variável é PRECIPITACAO.	precipitacao_acumulada	DECIMAL(10,3)	Fact_Indicadores
Silver / Fact_Medicoes	valor_observado	DECIMAL	Obter valor máximo para variáveis hidrométricas no período.	nivel_maximo_periodo	DECIMAL(10,3)	Fact_Indicadores
Silver / Fact_Medicoes	valor_observado	DECIMAL	Calcular média dos valores observados para variáveis hidrométricas ou hidrológicas no período.	caudal_medio_periodo	DECIMAL(10,3)	Fact_Indicadores
Silver / Fact_Medicoes	nivel_alerta	INT	Contar medições do período com nível de alerta superior a zero.	num_excedencias_limiar	INT	Fact_Indicadores
Silver / lookup	fk_id_tempo	INT	Associar o indicador ao período temporal de referência.	fk_id_tempo	INT	Fact_Indicadores
Silver / lookup	fk_id_estacao	INT	Preservar associação à estação de monitorização.	fk_id_estacao	INT	Fact_Indicadores
Silver / lookup	fk_id_variavel	INT	Preservar associação à variável monitorizada.	fk_id_variavel	INT	Fact_Indicadores
Silver / lookup	fk_id_localizacao	INT	Preservar associação à localização da estação.	fk_id_localizacao	INT	Fact_Indicadores

Mapeamento para a Fact_Evento_Cheia

Origem	Atributo origem	Tipo origem	Transformação	Atributo destino	Tipo destino	Destino
Silver / Fact_Medicoes	fk_id_tempo inicial e final	INT	Calcular duração do evento candidato a partir da sequência de medições em alerta.	duracao_horas	DECIMAL(8,2)	Fact_Evento_Cheia
Silver / Fact_Medicoes	valor_observado	DECIMAL	Somar precipitação associada ao período do evento candidato.	precipitacao_total_evento	DECIMAL(10,3)	Fact_Evento_Cheia
Silver / Fact_Medicoes	valor_observado	DECIMAL	Obter nível hidrométrico ou cota máxima atingida durante o evento candidato.	nivel_max_evento	DECIMAL(10,3)	Fact_Evento_Cheia
Silver / lookup	tipo_evento	VARCHAR	Resolver chave estrangeira através de Dim_TipoEvento.	fk_id_Tipo	INT	Fact_Evento_Cheia
Silver / lookup	fk_id_estacao	INT	Preservar associação à estação onde o evento candidato foi identificado.	fk_id_estacao	INT	Fact_Evento_Cheia
Silver / lookup	fk_id_localizacao	INT	Preservar associação à localização da estação.	fk_id_localizacao	INT	Fact_Evento_Cheia
Silver / lookup	fk_id_tempo inicial	INT	Resolver chave temporal de início através de Dim_Tempo.	tempo_inicial	INT	Fact_Evento_Cheia
Silver / lookup	fk_id_tempo final	INT	Resolver chave temporal de fim através de Dim_Tempo.	tempo_final	INT	Fact_Evento_Cheia

Este mapeamento permite justificar a coerência entre as fontes, a área de preparação e o armazém de dados. As transformações mais complexas são executadas antes da carga Gold, na camada Silver, garantindo que o armazém de dados recebe dados já preparados, consistentes e alinhados com o modelo dimensional. A camada Gold fica, assim, responsável por publicar a versão final das dimensões e factos já preparados e validados na Silver, preservando as relações entre entidades e disponibilizando dados estruturados para exploração analítica, visualização e aquisição de conhecimento.

5.3 Modelação do Sistema de Povoamento

A modelação do sistema de povoamento foi realizada em BPMN, com o objetivo de representar de forma estruturada as etapas de integração de dados entre as fontes, a camada Bronze, a zona de quarentena, a camada Silver e a camada Gold. A utilização desta notação permite separar a visão conceptual do processo de integração da sua implementação técnica em SSIS, tornando explícitas as dependências entre tarefas, a ordem de execução e os pontos onde existem subprocessos de transformação.

O modelo global foi organizado em três subprocessos principais: extração inicial e incremental para Bronze, transformação e preparação Silver, e povoamento Gold. Esta decomposição acompanha a arquitetura definida no capítulo anterior e separa responsabilidades distintas: entrada e preservação dos dados, preparação e validação, e publicação analítica. A existência de subprocessos permite ainda detalhar internamente cada etapa sem tornar o diagrama global excessivamente complexo.

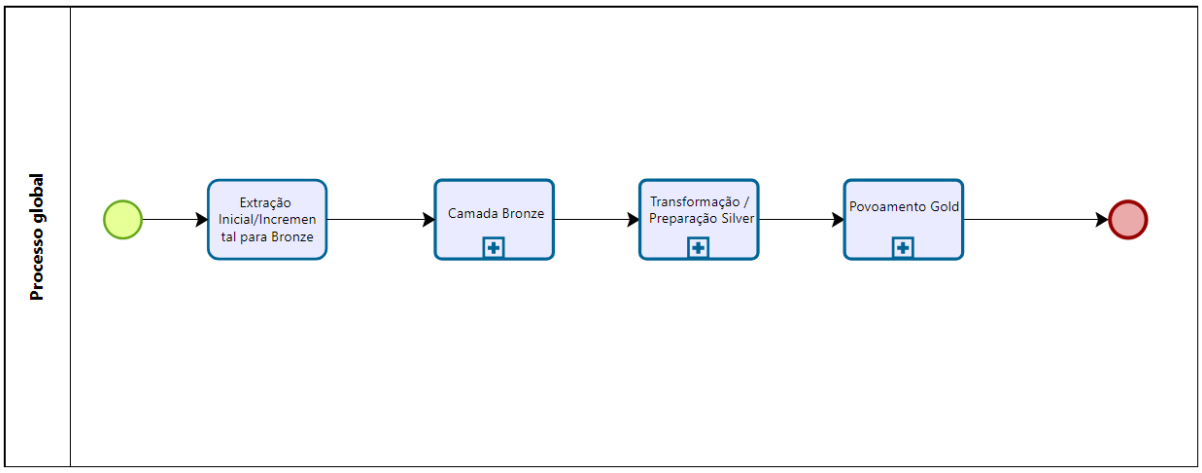


Figura 7: Modelo BPMN global do processo de povoamento

No subprocesso de extração para Bronze são considerados dois modos de carregamento: carga inicial e carga incremental. A extração inicial permite carregar o histórico disponível nas fontes, enquanto a extração incremental representa a entrada periódica de novas observações. Esta distinção é necessária porque o sistema deve suportar simultaneamente análise

histórica e atualização recorrente de medições, especialmente relevante no contexto de monitorização de cheias.

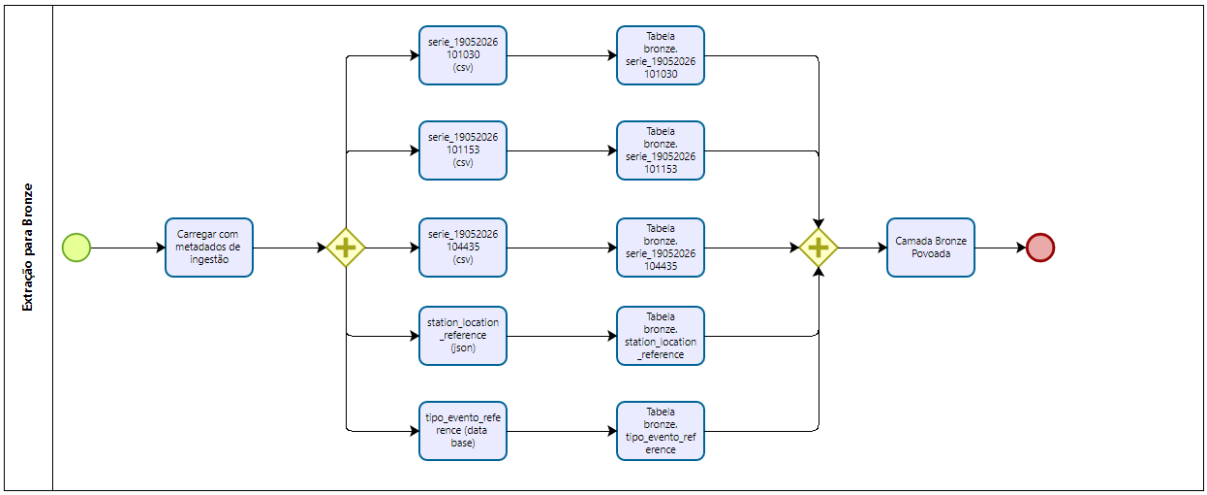


Figura 8: Subprocesso BPMN de extração para Bronze

A extração para Bronze preserva os dados recebidos das fontes e carrega-os com metadados técnicos de ingestão, como identificador interno e data de entrada. Estes metadados permitem distinguir registos carregados em diferentes execuções e suportam a rastreabilidade do processo. A camada Bronze não executa regras analíticas, mantendo os dados disponíveis para reprocessamento.

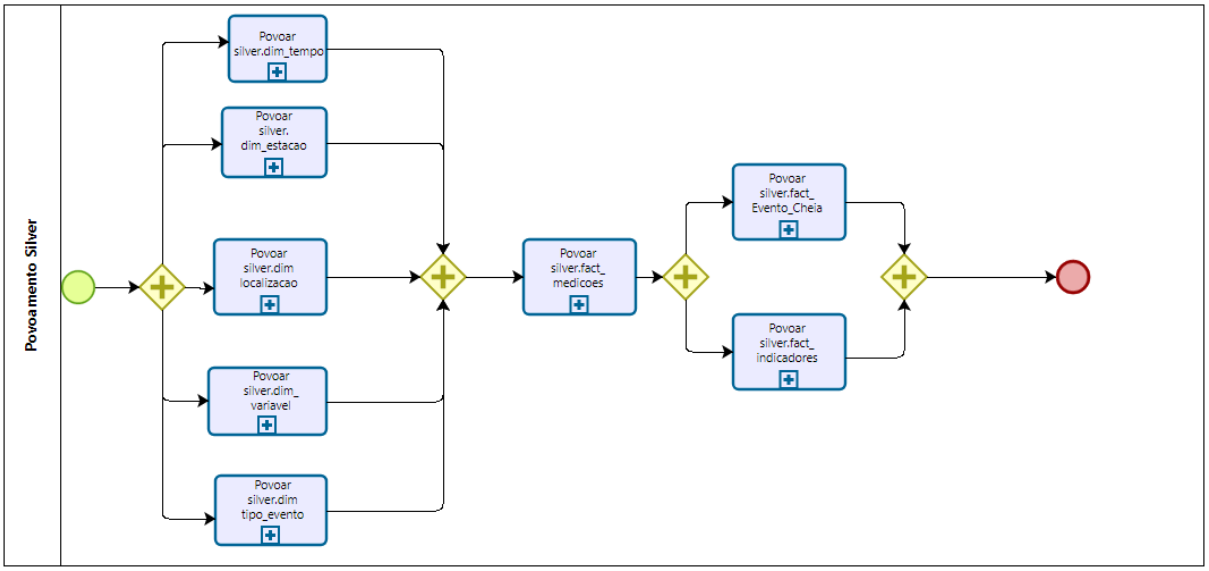


Figura 9: Subprocesso BPMN de preparação e povoamento da camada Silver

O povoamento das dimensões é executado antes do povoamento das tabelas de factos, porque as tabelas de factos dependem das chaves primárias das dimensões. Esta dependên-

cia foi representada através da separação entre a fase de povoamento dimensional e a fase de povoamento factual. As dimensões `Dim_Tempo`, `Dim_Estacao`, `Dim_Localizacao`, `Dim_Variavel` e `Dim_TipoEvento` podem ser preparadas em paralelo, mas a `Fact_Medicoes` só deve avançar depois de concluída a disponibilidade das dimensões necessárias.

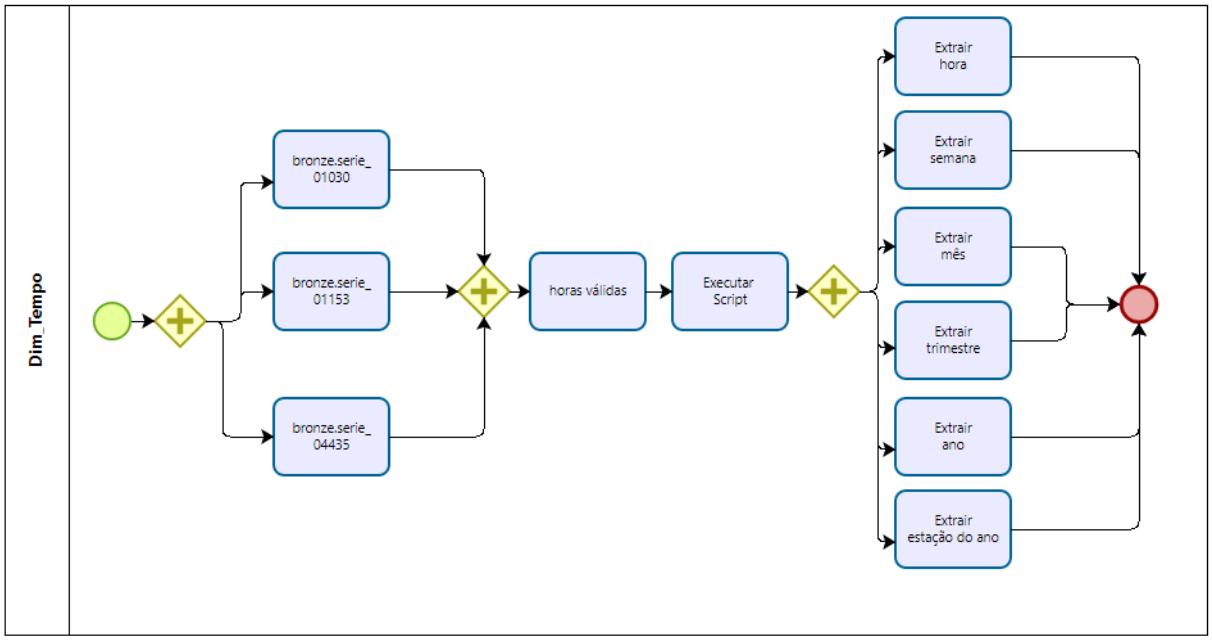


Figura 10: Subprocesso BPMN de povoamento da Dim_Tempo

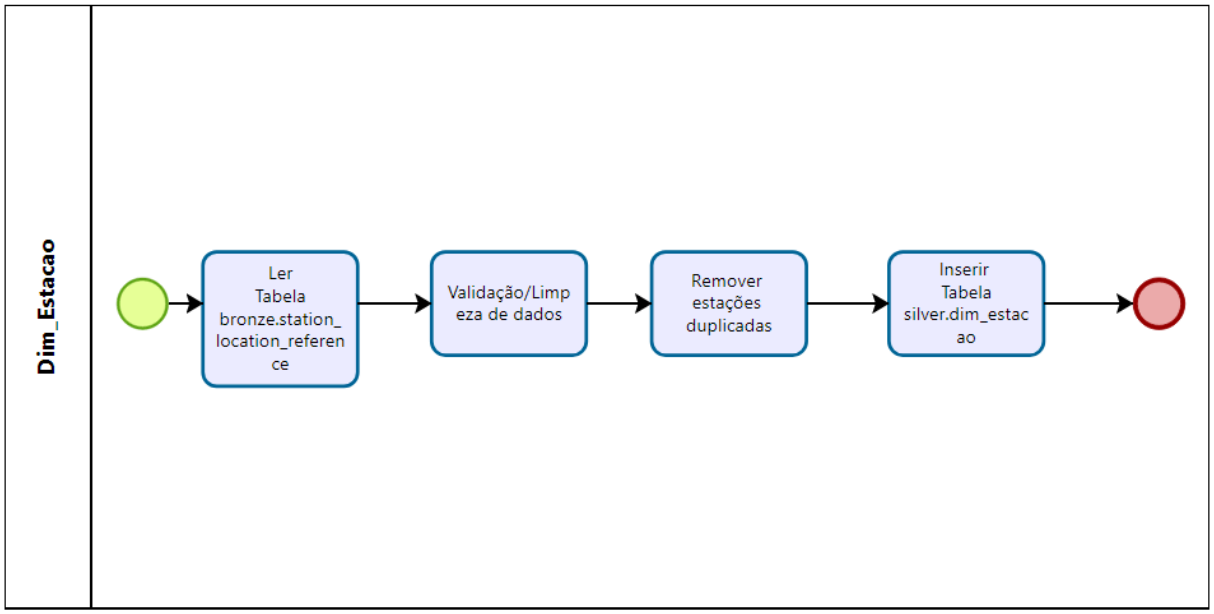


Figura 11: Subprocesso BPMN de povoamento da Dim_Estacao

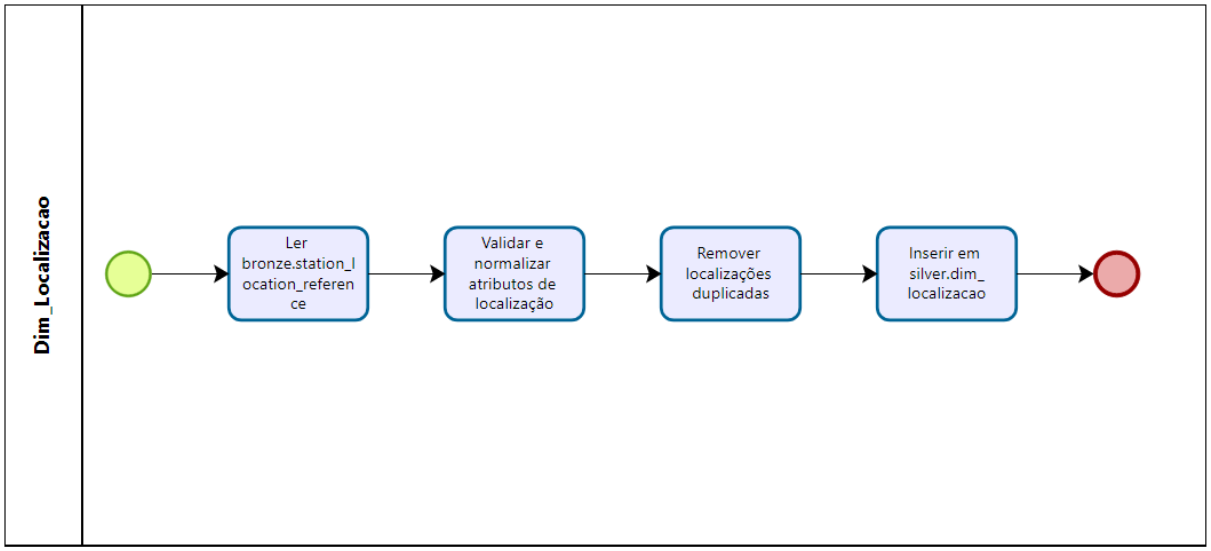


Figura 12: Subprocesso BPMN de povoamento da Dim_Localizacao

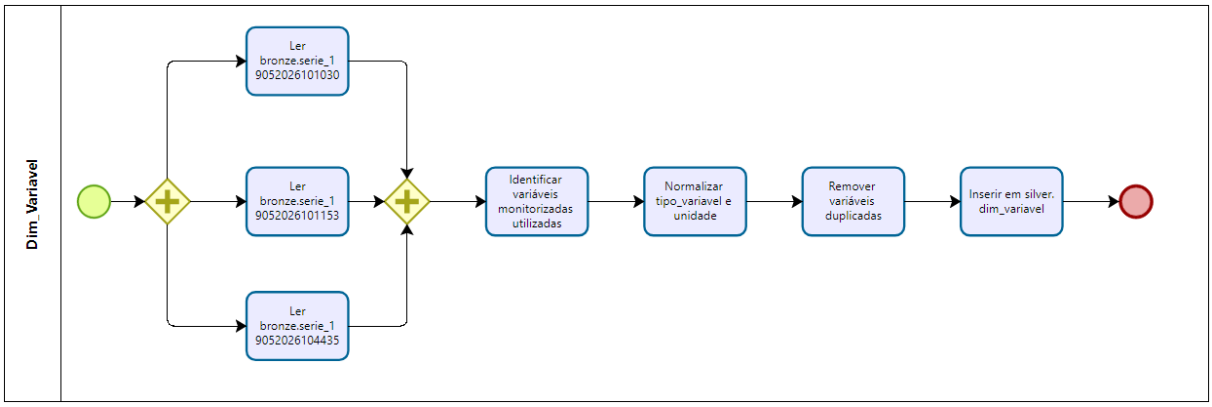


Figura 13: Subprocesso BPMN de povoamento da Dim_Variavel

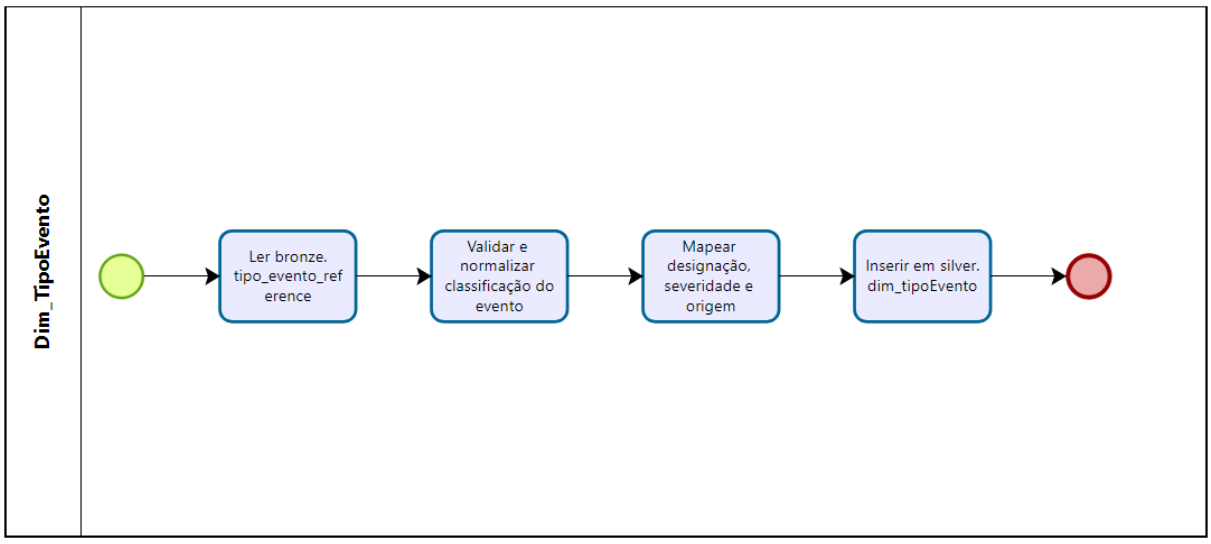


Figura 14: Subprocesso BPMN de povoamento da Dim_TipoEvento

A `Fact_Medicoes` foi modelada como a tabela factual base do sistema. O respetivo subprocesso lê as séries preservadas na Bronze, normaliza as medições por estação e variável, valida as

linhas, converte os valores observados, calcula o `nivel_alerta` e a `variacao_valor`, e resolve as chaves estrangeiras para as dimensões Silver. Os registos que falham as validações mínimas são encaminhados para quarentena, mantendo a separação entre dados rejeitados e dados preparados.

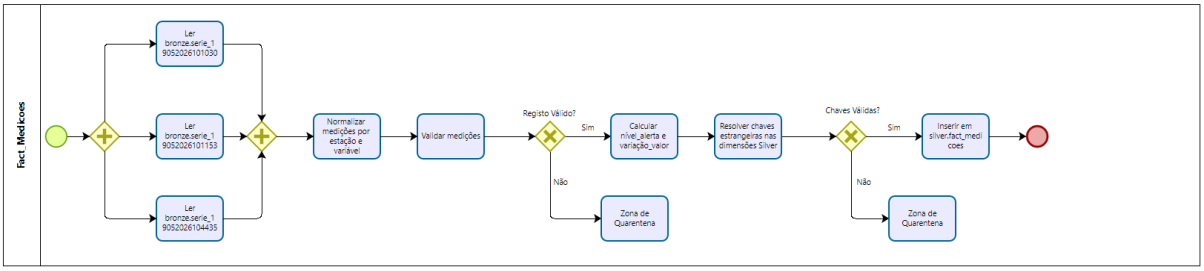


Figura 15: Subprocesso BPMN de povoamento da Fact_Medicoes

A `Fact_Indicadores` é modelada como uma tabela derivada da `Fact_Medicoes`. Esta dependência foi representada para deixar explícito que os indicadores não são calculados diretamente das fontes, mas sim a partir de medições já validadas, normalizadas e associadas às dimensões. O subprocesso calcula precipitação acumulada, nível máximo do período, valor médio do período e número de excedências de limiar.

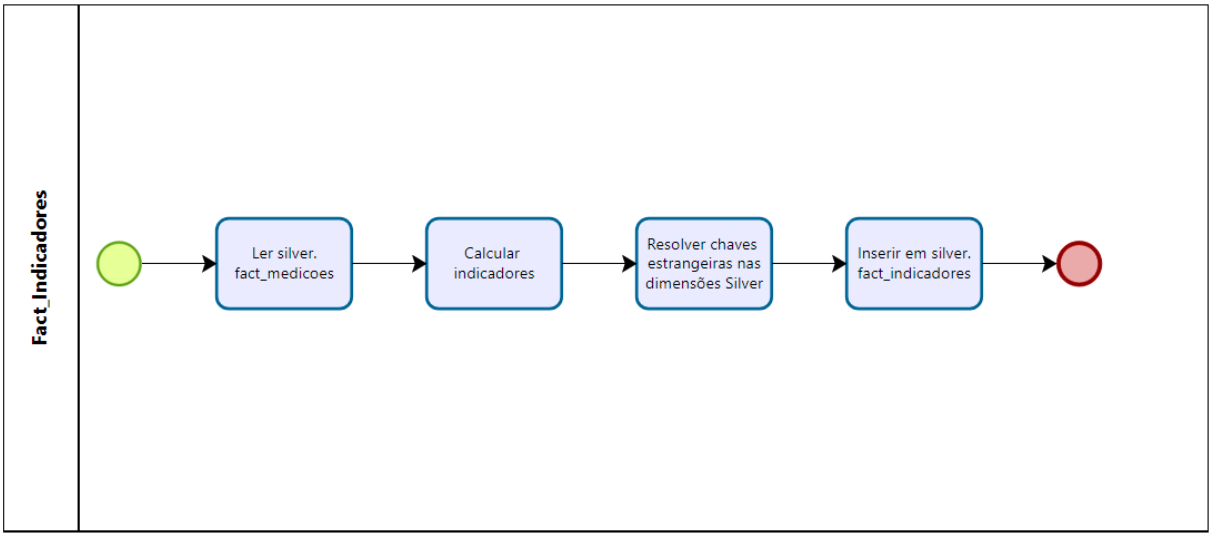


Figura 16: Subprocesso BPMN de povoamento da Fact_Indicadores

A `Fact_Evento_Cheia` também é derivada da `Fact_Medicoes`, utilizando como base medições com `nivel_alerta` superior a zero. O BPMN representa este filtro como etapa explícita, uma vez que apenas medições em situação crítica contribuem para a identificação de eventos

candidatos. O subprocesso calcula duração, precipitação total, nível máximo e classificação do evento, resolvendo posteriormente as respetivas chaves estrangeiras.

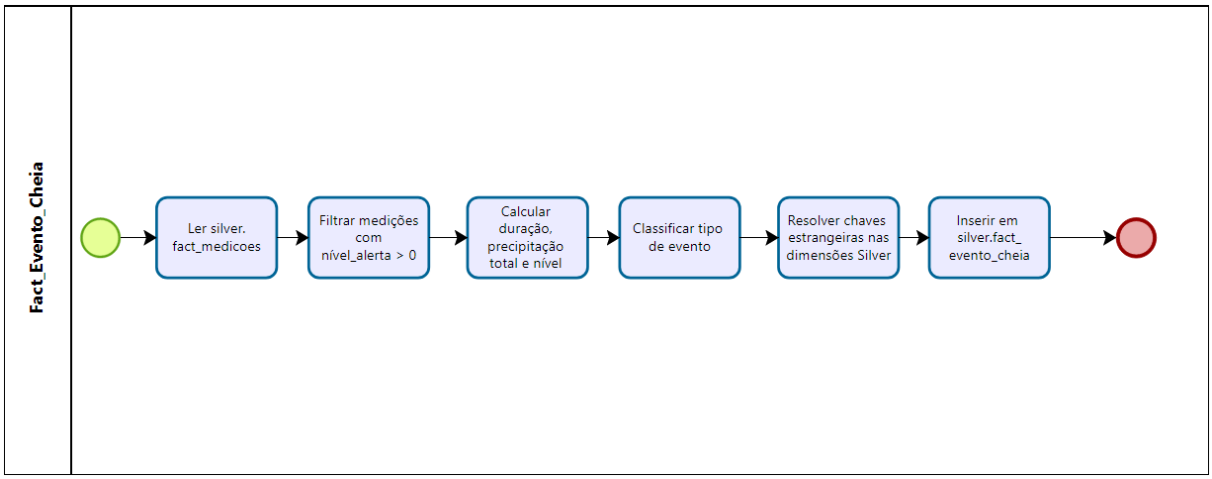


Figura 17: Subprocesso BPMN de povoamento da Fact_Evento_Cheia

O povoamento Gold foi modelado como uma etapa de publicação a partir da Silver. As dimensões são publicadas primeiro e, após a sua conclusão, são publicadas as tabelas de factos. Esta ordem reflete a necessidade de manter integridade referencial na camada analítica final. A Gold não executa transformações de limpeza ou derivação, recebe apenas dados já preparados na Silver.

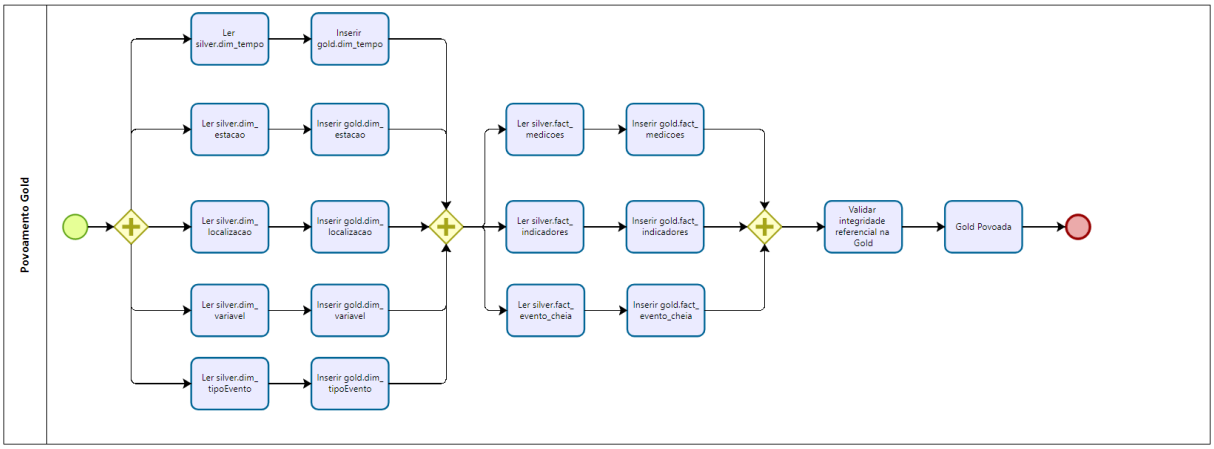


Figura 18: Subprocesso BPMN de povoamento da camada Gold

Em termos de pipelining, o modelo BPMN evidencia que o processo não corresponde a uma transferência direta das fontes para o armazém de dados. Os dados são primeiro preservados na Bronze, depois validados e transformados na Silver, podendo ser desviados para a zona de quarentena em caso de rejeição, e só posteriormente publicados na camada Gold. Esta

organização permite controlar dependências, preservar rastreabilidade e impedir que dados inválidos avancem para a camada Silver validada e, posteriormente, para a camada Gold.

5.4 Implementação do Sistema de Povoamento

A implementação do sistema de povoamento foi realizada em Microsoft Visual Studio, recorrendo ao SQL Server Integration Services (SSIS), e em Microsoft SQL Server, onde foram criadas as estruturas relacionais correspondentes às camadas Bronze, Silver e Gold. A implementação segue o modelo BPMN descrito na secção anterior. Cada subprocesso representado no BPMN foi implementado como um ou mais fluxos SSIS, cuja ordem de execução é controlada no **Control Flow** e cujas transformações são definidas no **Data Flow**.

O processo foi organizado por camadas, utilizando schemas SQL distintos para separar responsabilidades. O schema `bronze` armazena os dados recebidos das fontes, o schema `silver` contém os dados preparados, normalizados e validados, e o schema `gold` contém a versão final do modelo dimensional disponibilizada para análise. Esta separação foi adotada para impedir que dados brutos, dados em preparação e dados publicados sejam misturados na mesma estrutura, reduzindo o risco de consumo analítico sobre dados ainda não tratados.

Implementação da camada Bronze

A primeira fase da implementação corresponde à carga das fontes para a camada Bronze. Foram criadas tabelas específicas para cada fonte utilizada no projeto: séries hidrométricas do SNIRH, séries meteorológicas do SNIRH, referência de localização das estações e referência de tipos de evento.

A carga dos ficheiros CSV foi implementada através de componentes `Flat File Source`, ligados a destinos relacionais `OLE DB Destination`. Para o ficheiro JSON de localização foi utilizado um `Script Component`, responsável por ler a estrutura JSON e gerar uma saída tabular compatível com a tabela `bronze.station_location_reference`. Para a referência de tipos de

evento, a origem foi carregada a partir de uma base de dados relacional, mantendo a distinção entre esta fonte e os ficheiros CSV/JSON.

Os dados são guardados antes da limpeza e normalização, permitindo rastrear posteriormente de onde veio cada informação. As linhas informativas e cabeçalhos dos ficheiros SNIRH são tratadas apenas na passagem para Silver, uma vez que a Bronze deve manter a referência ao conteúdo recebido da fonte.

Para reforçar a rastreabilidade da ingestão, as tabelas Bronze incluem metadados técnicos como `id_bronze` e `data_ingestao`. O `id_bronze` identifica internamente cada registo carregado e a `data_ingestao` regista automaticamente o momento em que o dado entrou no sistema. Estes atributos não alteram o conteúdo funcional das fontes, mas permitem acompanhar cargas iniciais e incrementais e distinguir registos carregados em diferentes execuções.

Implementação da camada Silver

A camada Silver concentra a preparação dos dados. Nesta fase foram implementados fluxos de dados responsáveis por validar registos, normalizar estruturas, converter tipos de dados, derivar atributos, calcular medidas e resolver chaves estrangeiras. Esta decisão evita que a camada Gold contenha lógica operacional de transformação, ficando esta reservada à publicação dos dados já preparados.

A arquitetura prevê uma zona de quarentena para preservar registos rejeitados durante a validação. Na implementação atual, os fluxos SSIS já separam o percurso principal de dados válidos através de componentes como `Conditional Split`, conversões de dados e `Lookup`. A extensão para quarentena permite que registos rejeitados sejam armazenados para análise posterior, em vez de serem simplesmente excluídos do fluxo principal.

O povoamento da Silver foi dividido em duas fases: primeiro as dimensões e depois as tabelas de factos. Esta ordem foi necessária porque as tabelas de factos dependem das chaves primárias das dimensões. Assim, a `Fact_Medicoes`, a `Fact_Indicadores` e a `Fact_Evento_Cheia` só são carregadas depois de existirem registos válidos nas dimensões `Dim_Tempo`, `Dim_Estacao`, `Dim_Localizacao`, `Dim_Variavel` e `Dim_TipoEvento`.

Povoamento das dimensões Silver

A dimensão `Dim_Tempo` foi construída a partir das datas e horas presentes nas séries SNIRH. O fluxo lê as tabelas Bronze que contêm medições, filtra apenas linhas com estrutura temporal válida, remove duplicados e deriva os atributos `hora`, `semana`, `mes`, `trimestre`, `ano` e `estacao_ano`. A data e hora original da observação é usada apenas para calcular o identificador temporal id_tempo no formato AAAAMMDDHH, não sendo armazenada como atributo autónomo da Dim_Tempo por ser redundante com esse identificador. O identificador `id_tempo` é calculado a partir da data e hora da observação no formato `AAAAMMDDHH`, garantindo uma chave temporal única por instante horário. Esta opção preserva a granularidade horária necessária à análise temporal, à ordenação cronológica e à preparação dos dados para modelos de previsão.

A dimensão `Dim_Estacao` foi povoada a partir da tabela `bronze.station_location_reference`. O fluxo seleciona os atributos identificativos da estação, normaliza os valores textuais e remove duplicados antes da inserção em `silver.dim_estacao`. O atributo `codigo_estacao` foi mantido como identificador natural da fonte, não como chave primária. Esta decisão permite rastreabilidade para os dados SNIRH sem tornar o modelo dependente de identificadores externos.

A dimensão `Dim_Localizacao` também é alimentada pela referência de localização das estações, mas utiliza apenas os atributos territoriais e funcionais com cobertura consistente como `bacia`, `concelho`, `distrito`, `zona_risco` e `tipo_zona`. Esta opção evita a introdução de atributos incompletos ou sem utilidade analítica efetiva na dimensão.

A dimensão `Dim_Variavel` foi construída a partir das variáveis presentes nas séries carregadas. O fluxo identifica os tipos de variável monitorizada e as respetivas unidades, normalizando-os antes da inserção. Esta dimensão é essencial para interpretar corretamente as medidas factuais, uma vez que precipitação, nível hidrométrico e cota de albufeira têm comportamentos analíticos distintos.

A dimensão `Dim_TipoEvento` foi carregada a partir da tabela de referência de tipos de evento. Os atributos de origem são normalizados e mapeados para `tipo_evento`, `severidade` e `origem`.

Esta dimensão é usada apenas pela `Fact_Evento_Cheia`, mantendo a classificação de eventos separada das medições elementares.

Povoamento da Fact_Medicoes

A `Fact_Medicoes` foi implementada como a primeira tabela de factos da Silver, uma vez que serve de base à derivação dos indicadores e dos eventos candidatos de cheia. O fluxo lê as séries SNIRH armazenadas na camada Bronze, normaliza os dados por estação e variável, filtra medições válidas, converte o valor observado para decimal e calcula medidas derivadas.

A filtragem das linhas válidas é feita através de um `Conditional Split`. Este componente permite excluir cabeçalhos, linhas informativas e registos sem valor observado antes da conversão numérica. Esta decisão evita erros de conversão e garante que apenas medições com significado analítico avançam no pipeline principal.

A normalização das séries foi implementada com `Script Components`, porque os ficheiros originais não apresentam uma estrutura única por estação e variável. Os scripts transformam colunas específicas das fontes em registos normalizados com os atributos `data_hora_raw`, `codigo_estacao`, `tipo_variavel` e `valor_observado_raw`. Esta transformação é necessária para que medições de estações e variáveis distintas possam ser tratadas por um fluxo comum.

Depois da conversão de tipos, as medições são ordenadas por estação, variável e instante temporal. Esta ordenação é necessária para calcular `variacao_valor`, que representa a diferença entre uma medição e a medição anterior da mesma estação e variável. No mesmo componente é calculado o `nivel_alerta`, aplicando limiares operacionais definidos em função da estação e da variável observada.

As chaves estrangeiras são resolvidas através de componentes `Lookup`, que procuram nas dimensões da camada Silver os identificadores correspondentes a tempo, estação, localização e variável. A inserção na `silver.fact_medicoes` ocorre apenas depois deste procedimento, garantindo que cada registo factual fica associado a registos dimensionais válidos.

Povoamento da Fact_Indicadores

A `Fact_Indicadores` foi implementada a partir da `silver.fact_medicoes`, e não diretamente a partir das fontes camada Bronze. Esta decisão garante que os indicadores são calculados sobre medições já validadas, normalizadas e associadas às respetivas dimensões.

O fluxo calcula medidas agregadas por estação, variável, localização e período. Para a precipitação é calculada a `precipitacao_acumulada`, para variáveis hidrométricas é calculado o `nivel_maximo_periodo`, para variáveis hidrológicas é calculado o `caudal_medio_periodo`, e, em todos os casos, é calculado o `num_excedencias_limiar` através da contagem de medições com `nivel_alerta` superior a zero.

Povoamento da Fact_Evento_Cheia

A `Fact_Evento_Cheia` também foi derivada a partir da `silver.fact_medicoes`. O fluxo filtra medições com `nivel_alerta` superior a zero e identifica eventos candidatos de cheia com base em períodos críticos observados. Para cada evento candidato são calculadas medidas como `duracao_horas`, `precipitacao_total_evento` e `nivel_max_evento`.

A classificação do evento é associada através da `Dim_TipoEvento`, permitindo distinguir episódios segundo a sua severidade e origem. Estes registos devem ser interpretados como eventos candidatos derivados de regras operacionais do ETL, e não como ocorrências oficiais externas. Esta distinção é importante porque a tabela resulta da análise das medições em alerta preservadas no sistema.

Povoamento da camada Gold

Depois da preparação na Silver, os dados são publicados para a camada Gold. Esta fase foi implementada através de fluxos `OLE DB Source` para `OLE DB Destination`, lendo as tabelas

Silver e carregando as tabelas Gold correspondentes. A publicação segue a mesma ordem lógica do modelo dimensional: primeiro dimensões e depois tabelas de factos.

Antes da carga na camada Gold, são aplicadas validações de existência de chaves e integridade referencial. Esta validação garante que as tabelas de factos só são publicadas quando os seus identificadores dimensionais têm correspondência nas dimensões Gold. A Gold não recalcula medidas nem refaz transformações, recebe apenas os dados já preparados e validados, funcionando como camada de consulta analítica.

As relações entre as tabelas de factos e as dimensões são reforçadas através de chaves estrangeiras declaradas no modelo relacional. Esta decisão permite que o próprio sistema de base de dados impeça a existência de registos factuais sem correspondência dimensional, reforçando a integridade do modelo publicado.

5.5 Validação e Testes

A validação do sistema de povoamento foi realizada através de consultas SQL aplicadas sobre as três camadas: Bronze, Silver e Gold. O objetivo foi confirmar que os dados foram carregados nas estruturas esperadas, que as transformações executadas na Silver produziram registos coerentes com o modelo dimensional e que o povoamento para Gold não introduziu perdas de dados nem quebras de integridade referencial.

O processo de testes foi organizado em quatro grupos principais: validação de volume de dados por camada, validação da correspondência entre Silver e Gold, validação das chaves estrangeiras das tabelas de factos e validação analítica dos principais resultados obtidos. Esta divisão permite testar se o pipeline executou sem erro e também se os dados carregados mantêm coerência estrutural.

Validação da camada Bronze

A primeira validação incidiu sobre a camada Bronze, confirmando se todas as fontes previstas foram carregadas nas respetivas tabelas. Esta verificação é necessária porque a Bronze constitui a base de reprocessamento das restantes camadas; se uma fonte não for corretamente carregada nesta fase, todas as transformações posteriores ficam incompletas.

Tabela Bronze	Total de registos
bronze.tipo_evento_reference	4
bronze.station_location_reference	6
bronze.serie_19052026101030	108742
bronze.serie_19052026101153	19292
bronze.serie_19052026104435	46488

Os resultados confirmam que todas as fontes previstas foram carregadas. A existência de volumes diferentes entre tabelas é um resultado esperado porque as séries correspondem a fontes e períodos distintos. A tabela da localização contém seis registos, correspondentes às seis estações consideradas no processo de integração.

Validação da camada Silver

A segunda validação foi sobre a camada Silver, onde são executadas as transformações principais do sistema. Nesta fase foi verificado se as dimensões e tabelas de factos foram povoadas com volumes compatíveis com as fontes e com o modelo dimensional.

Tabela Silver	Total de registos
silver.dim_tempo	49049
silver.dim_estacao	6
silver.dim_localizacao	6
silver.dim_variavel	3
silver.dim_tipoEvento	4
silver.fact_medicoes	263785
silver.fact_indicadores	343
silver.fact_evento_cheia	6

Os totais obtidos são coerentes com o modelo desenvolvido. A `Dim_Estacao` e a `Dim_Localizacao` apresentam seis registos, correspondentes às estações integradas. A `Dim_Variavel` apresenta três registos, refletindo as variáveis efetivamente carregadas: cota de albufeira, nível hidrométrico e precipitação. A `Fact_Medicoes` apresenta o maior volume de registos, como esperado, uma vez que preserva o detalhe temporal das medições.

Validação da publicação para Gold

Depois do povoamento da camada Silver, foi validada a publicação para a camada Gold. Esta verificação compara os totais das tabelas Silver e Gold, garantindo que a etapa de publicação não removeu nem duplicou registos.

Tabela	Silver	Gold
`dim_tempo`	49049	49049
`dim_estacao`	6	6
`dim_localizacao`	6	6
`dim_variavel`	3	3
`dim_tipoEvento`	4	4
`fact_medicoes`	263785	263785
`fact_indicadores`	343	343
`fact_evento_cheia`	6	6

A correspondência total entre Silver e Gold confirma que a publicação final preservou os registos preparados. Esta validação é relevante porque a Gold é a camada exposta à análise; por isso, deve refletir fielmente a versão validada na Silver, sem voltar a executar lógica de transformação.

Validação da integridade referencial

Foi também verificada a integridade referencial das tabelas de factos, confirmando se todas as chaves estrangeiras possuem correspondência nas dimensões. Este teste é essencial num modelo dimensional, uma vez que tabelas de factos sem dimensão associada impediriam análises coerentes por tempo, estação, localização ou variável.

Teste	Registos inválidos
`Fact_Medicoes` com FK inválidas	0
`Fact_Indicadores` com FK inválidas	0
`Fact_Evento_Cheia` com FK inválidas	0

O resultado igual a zero em todos os testes confirma que as chaves estrangeiras foram corretamente resolvidas. Esta validação suporta a decisão de realizar a resolução de chaves na Silver, antes da passagem para Gold.

Foi ainda analisada a unicidade do grão da `Fact_Medicoes`, definido como uma observação por estação, variável e instante temporal. Esta verificação permitiu identificar que algumas combinações de `codigo_estacao`, `tipo_variavel` e `id_tempo` apresentam mais do que uma medição associada, devido à existência de múltiplas observações associadas ao mesmo identificador temporal nas fontes de origem.

Na camada Gold, estes registos são preservados para manter rastreabilidade face aos dados carregados. No entanto, para a componente preditiva, foi realizada uma consolidação horária em ambiente Jupyter/Python, garantindo uma linha por estação, variável e `id_tempo`. Nessa consolidação, o valor observado foi agregado pela média e o `nivel_alerta` pelo máximo, preservando a situação de maior criticidade. Este procedimento resultou numa redução de 59.258 registos face ao conjunto de medições inicial, produzindo a série horária consolidada usada na modelação.

Validação analítica dos dados carregados

Para além dos testes estruturais, foram realizadas validações analíticas sobre os dados carregados. Estas verificações permitem confirmar se a distribuição dos registos é coerente com as estações e variáveis integradas.

Código da estação	Nome	Tipo	Total de medições
11H/01A	ALBUFEIRA DA AGUIEIRA	Hidrométrica	16855
11K/01UG	SEIA	Meteorológica	27767
12G/04H	PONTE SANTA CLARA COIMBRA	Hidrométrica	56266
12G/08H	PONTE CONRARIA	Hidrométrica	81848
13F/01G	SOURE	Meteorológica	37594
13H/03UG	LOUSA	Meteorológica	43455

A distribuição confirma que as seis estações previstas foram integradas no sistema. As diferenças de volume entre estações são compatíveis com a existência de séries com períodos e granularidades distintas.

Variável	Unidade	Total	Mínimo	Máximo	Média
COTA_ALBUFEIRA	m	16855	113.430	125.000	119.926515
NIVEL_HIDROMETRICO	m	138114	−0.190	7.050	1.546935
PRECIPITACAO	mm	108816	0.000	26.600	0.090579

Os valores obtidos são compatíveis com a natureza das variáveis monitorizadas. A precipitação apresenta valores acumuláveis e maior número de registos meteorológicos, enquanto a cota de albufeira e o nível hidrométrico apresentam valores em metros, analisáveis sobretudo por máximos, mínimos e médias.

Validação dos indicadores e eventos

Por fim, foram analisadas as tabelas derivadas. A `Fact_Indicadores` foi validada através da distribuição de linhas e excedências por variável, enquanto a `Fact_Evento_Cheia` foi verificada pela existência de eventos candidatos identificados a partir das medições em alerta.

Variável	Linhas de indicadores	Total de excedências	Maior valor
COTA_ALBUFEIRA	68	7236	125.000
NIVEL_HIDROMETRICO	120	6449	7.050
PRECIPITACAO	155	256	294.300

A presença de excedências confirma que o atributo `nivel_alerta` foi calculado e utilizado na produção dos indicadores. O valor de precipitação apresentado na tabela de indicadores corresponde a precipitação acumulada por período, pelo que pode ser superior ao maior valor observado numa medição individual.

Tipo de evento	Total de eventos	Maior duração	Maior nível do evento	Maior precipitação
Cheia hidrométrica	3	7236.00	125.000	–
Evento pluviométrico intenso	3	99.00	26.600	862.800

A validação da `Fact_Evento_Cheia` confirma a existência de eventos candidatos derivados das medições em alerta, distinguindo episódios hidrométricos e episódios pluviométricos intensos. Estes eventos devem ser interpretados como episódios identificados por regras operacionais do ETL, e não como ocorrências oficiais externas.

Em síntese, os testes realizados confirmam que o sistema de povoamento carrega as fontes previstas, prepara corretamente os dados na Silver, publica a Gold sem perda de registos e mantém integridade referencial entre tabelas de factos e dimensões. As validações analíticas demonstram ainda que os dados finais são coerentes com a monitorização hidrometeorológica e com os grãos definidos no modelo dimensional.

6. Exploração e Análise de Dados

6.1 Organização geral do sistema de dashboarding

A organização do sistema de dashboarding foi definida de acordo com os perfis dos agentes de decisão identificados anteriormente e com os diferentes níveis de detalhe necessários à análise do risco de cheia na bacia do Mondego. Em vez de concentrar toda a informação num único painel, a solução foi organizada em três dashboards complementares, cada um orientado para uma necessidade específica de acompanhamento, análise e suporte à decisão.

O primeiro dashboard, **Monitorização Operacional**, foi concebido para apoiar a leitura imediata do estado das estações e das variáveis monitorizadas. Este painel privilegia informação proveniente da `Fact_Medicoes`, como o valor observado, o nível de alerta, a variação entre medições consecutivas e a evolução temporal das medições. A sua organização permite identificar rapidamente estações com valores elevados, variáveis em situação crítica e zonas com maior concentração de alertas.

O segundo dashboard, **Indicadores Históricos**, foi organizado para suportar uma análise agregada e comparativa. Este painel utiliza principalmente a `Fact_Indicadores`, permitindo observar excedências de limiar, precipitação acumulada, níveis máximos e medidas agregadas por estação, mês, tipo de zona e zona de risco. Esta separação justifica-se porque os indicadores históricos não exigem a mesma granularidade da monitorização operacional, sendo mais adequados para identificar padrões, recorrências e períodos de maior pressão hidrometeorológica.

O terceiro dashboard, **Eventos de Cheia**, foi orientado para a análise dos episódios críticos identificados pelo sistema. Este painel consome a `Fact_Evento_Cheia` e permite caracterizar eventos segundo a sua duração, nível máximo, precipitação total, estação associada, tipo de evento, severidade e zona de risco. A sua função é apoiar a leitura histórica dos eventos mais relevantes e facilitar a comparação entre ocorrências críticas.

A separação dos dashboards por finalidade analítica permite evitar a sobrecarga visual e reduz o risco de misturar níveis de análise diferentes no mesmo painel. A monitorização operacional trabalha ao nível da medição, os indicadores históricos trabalham ao nível agregado e os eventos de cheia trabalham ao nível do episódio. Esta organização mantém coerência com o modelo dimensional desenvolvido, uma vez que cada dashboard explora a tabela de factos mais adequada ao tipo de decisão que pretende apoiar.

Todos os dashboards foram desenvolvidos em Power BI, com ligação à camada Gold do armazém de dados. Esta escolha garante que os utilizadores consomem apenas dados já tratados, validados e organizados segundo o modelo dimensional. As dimensões `Dim_Tempo`, `Dim_Estacao`, `Dim_Localizacao`, `Dim_Variavel` e `Dim_TipoEvento` são utilizadas como eixos de filtragem e contextualização, de acordo com a tabela de factos explorada em cada dashboard. As medições e indicadores podem ser analisados por período, estação, localização e variável, enquanto os eventos candidatos são analisados por período, estação, localização e tipo de evento.

6.2 Serviços de exploração e análise implementados

6.2.1 Dashboard de Monitorização Operacional

O dashboard de **Monitorização Operacional** foi desenvolvido para apoiar o acompanhamento do estado das estações e das variáveis hidrometeorológicas monitorizadas. Este responde sobretudo às necessidades do operador de monitorização, uma vez que privilegia a consulta de medições detalhadas, a identificação de valores críticos e a leitura da evolução temporal recente.

A base principal deste dashboard é a **Fact_Medicoes**, complementada pelas dimensões `Dim_Tempo`, `Dim_Estacao`, `Dim_Localizacao` e `Dim_Variavel`. A partir destas estruturas, o dashboard apresenta cartões de síntese, uma tabela operacional de medições e gráficos comparativos por estação, zona e variável. Os cartões permitem obter rapidamente uma leitura global do estado do sistema, enquanto os gráficos e a tabela permitem aprofundar a análise e identificar as estações, variáveis e zonas responsáveis pelos valores mais relevantes.

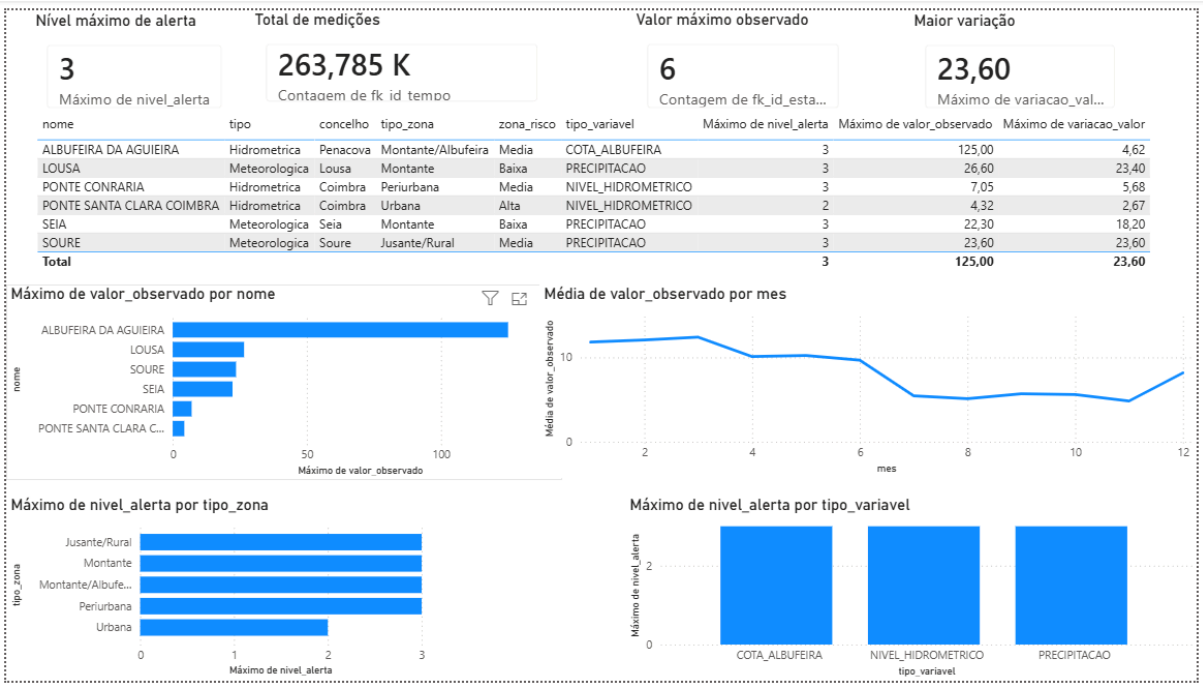


Figura 19: Dashboard de Monitorização Operacional

A figura apresenta a organização visual deste dashboard, combinando indicadores de síntese, tabela de detalhe e gráficos comparativos. Os elementos visuais permitem observar o número total de medições, o nível máximo de alerta, o maior valor observado e a maior variação registada. A tabela operacional permite consultar as observações por estação, variável, zona de risco e tipo de zona, enquanto os gráficos permitem comparar o comportamento das medições por estação, mês, tipo de zona e tipo de variável.

Sendo assim, o dashboard suporta diretamente a identificação de situações de criticidade operacional, uma vez que permite filtrar os dados por período, estação, variável e localização. Assim, o utilizador pode partir de uma visão geral do estado do sistema e chegar rapidamente às estações ou variáveis responsáveis por valores mais elevados ou por maiores variações.

6.2.2 Dashboard de Indicadores Históricos

O dashboard de **Indicadores Históricos** foi concebido para suportar uma análise agregada do comportamento hidrometeorológico ao longo do tempo. Ao contrário do dashboard operacional, que trabalha ao nível da medição individual, este explora indicadores consolidados,

sendo mais adequado para análise comparativa, identificação de padrões históricos e apoio à coordenação operacional.

A base principal deste dashboard é a **Fact_Indicadores**, que contém medidas agregadas como `precipitacao_acumulada`, `nivel_maximo_periodo`, `caudal_medio_periodo` e `num_excedencias_limiar`. Estas medidas são analisadas segundo as dimensões de tempo, estação, localização e variável, permitindo comparar períodos, zonas de risco, tipos de zona e estações.

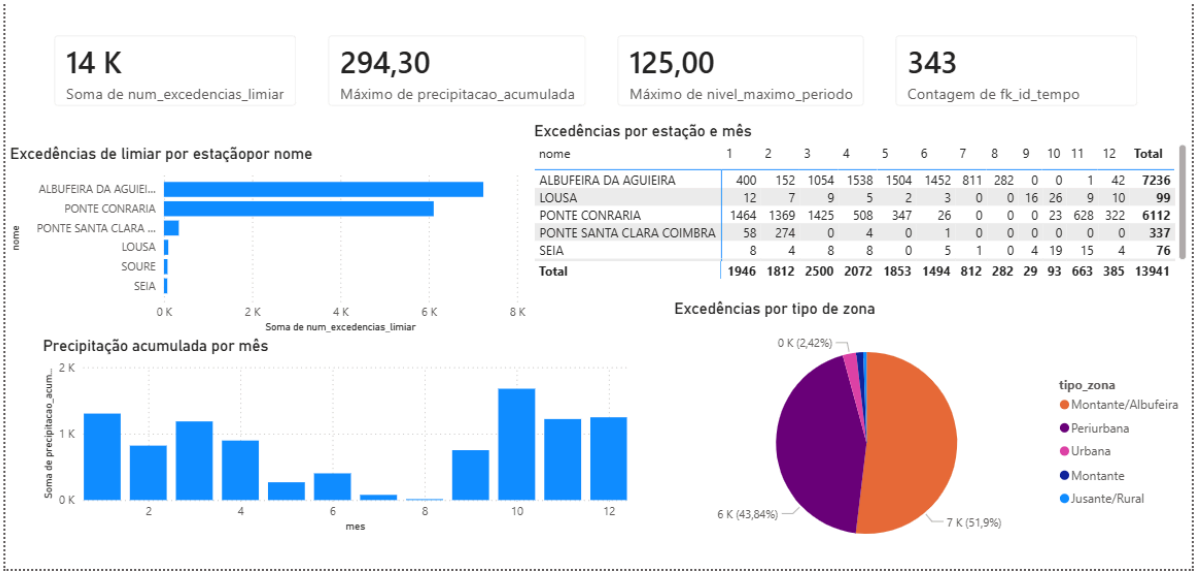


Figura 20: Dashboard de Indicadores Históricos

A figura mostra a organização do dashboard em torno de indicadores agregados e comparações históricas. Os cartões de síntese apresentam valores globais relevantes, como o número de excedências de limiar, a precipitação acumulada, o nível máximo observado e o número de registos de indicadores disponíveis. Os gráficos permitem analisar a distribuição das excedências por estação e zona de risco, bem como a evolução da precipitação acumulada por mês.

A matriz por estação e período permite identificar meses com maior concentração de excedências e comparar o comportamento das estações ao longo do tempo. Esta funcionalidade é relevante para o coordenador operacional de risco, uma vez que permite perceber que zonas ou estações apresentam maior recorrência de situações críticas e em que períodos essas situações tendem a ocorrer.

Este dashboard suporta também a análise territorial, uma vez que os indicadores podem ser filtrados por zona de risco, tipo de zona, estação, variável e período temporal. Desta forma, o dashboard permite passar de uma leitura temporal agregada para uma análise territorial mais detalhada, mantendo coerência com a dimensão Dim_Localizacao.

6.2.3 Dashboard de Eventos de Cheia

O dashboard de **Eventos de Cheia** foi desenvolvido para caracterizar episódios críticos identificados pelo sistema. Este dashboard utiliza a **Fact_Evento_Cheia** e centra-se nos eventos candidatos derivados das medições em alerta, permitindo analisar cada episódio como uma unidade discreta, com início, fim, duração e medidas próprias.

Este dashboard distingue-se dos anteriores, porque não trabalha diretamente sobre medições individuais nem sobre indicadores mensais, mas sobre eventos consolidados. Cada evento é caracterizado por medidas como `duracao_horas`, `precipitacao_total_evento` e `nivel_max_evento`, sendo contextualizado por `estação`, `localização`, `tempo` e `tipo de evento`.

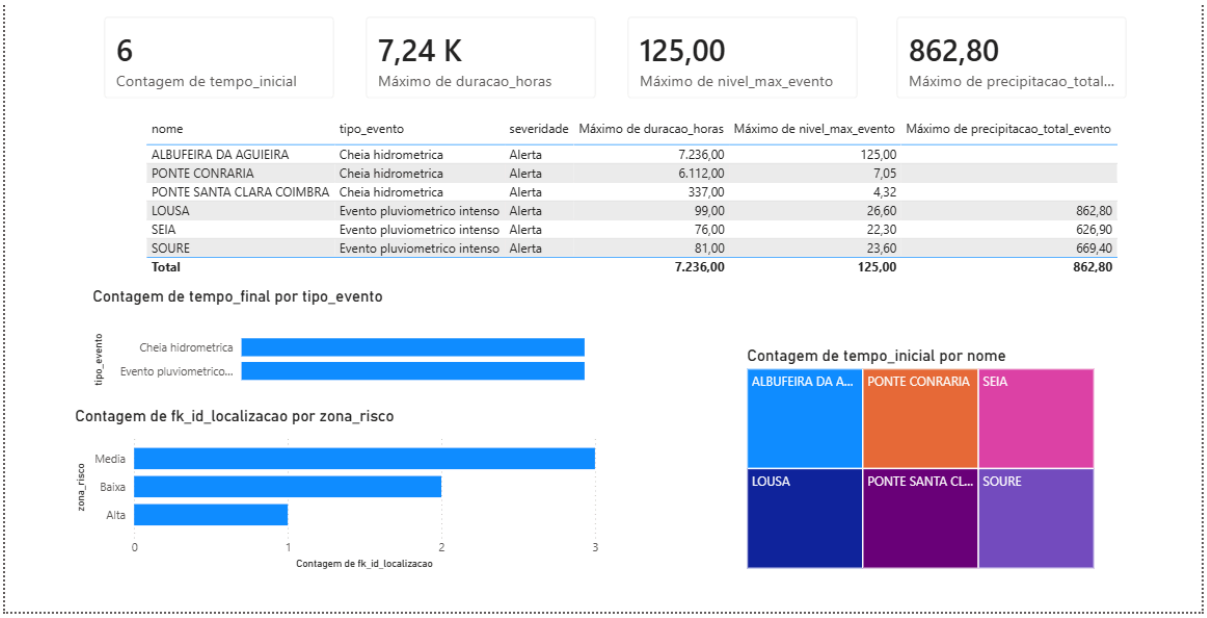


Figura 21: Dashboard de Eventos de Cheia

A figura apresenta o dashboard dedicado à análise de eventos, combinando cartões de síntese, tabela de detalhe e gráficos de distribuição por tipo de evento, zona de risco e estação. Os cartões permitem observar rapidamente o número de eventos candidatos, a maior duração

registada, o nível máximo atingido e a maior precipitação total associada a um evento. A tabela permite consultar os eventos individualmente, enquanto os gráficos permitem comparar a distribuição dos episódios por tipo, localização e estação.

Este dashboard é particularmente relevante para o coordenador operacional de risco e para o analista de risco e planeamento. Para o coordenador, permite comparar episódios críticos e identificar estações ou zonas com maior concentração de eventos. Para o analista, permite estudar a recorrência e a severidade dos episódios, bem como selecionar períodos e eventos relevantes para análises posteriores ou para apoio à componente preditiva.

De realçar também que os eventos apresentados devem ser interpretados como eventos candidatos de cheia, identificados por regras operacionais aplicadas no processo ETL com base nas medições em alerta. Não correspondem necessariamente a ocorrências oficiais externas, mas constituem uma estrutura analítica útil para detetar e caracterizar períodos de maior criticidade hidrometeorológica.

6.2.4 Validação dos dashboards face aos requisitos

A validação destes foi realizada através da correspondência entre os dashboards implementados, os requisitos levantados e as tabelas de factos exploradas em cada caso. Esta validação permite confirmar que a componente de exploração e análise não foi construída apenas como visualização genérica dos dados, mas como mecanismo de suporte às decisões identificadas no início do projeto.

Vista analítica	Tabela de factos principal	Requisitos suportados	Validação
Monitorização Operacional	Fact_Medicoes	RD01, RD02, RD03, RF01, RF02, RF03, RF04	Permite consultar medições por estação, variável, período e localização; identificar valores elevados, níveis de alerta e variações recentes; e acompanhar a evolução temporal das variáveis monitorizadas.

Indicadores Históricos	Fact_Indicadores	RD04, RD05, RD06, RF05, RF06, RF08, RF09, RF10, RF12	Permite comparar indicadores agregados por estação, período, zona de risco e tipo de zona; identificar excedências de limiar; e analisar padrões temporais e territoriais relevantes para a gestão do risco.
Eventos de Cheia	Fact_Evento_Cheia	RD07, RD08, RF07, RF11, RF12	Permite analisar eventos candidatos de cheia segundo duração, nível máximo, precipitação total, estação, localização, severidade e tipo de evento, suportando comparação histórica e estudo de recorrência.

O requisito RD09 é coberto principalmente pela componente de previsão descrita no capítulo 7, uma vez que a seleção de variáveis e períodos históricos relevantes para modelação é realizada no processo de preparação do dataset preditivo.

O **dashboard de Monitorização Operacional** valida os requisitos associados à observação corrente e à deteção de situações críticas, uma vez que permite acompanhar valores observados, variações e níveis de alerta ao nível da medição. Assim, é especialmente relevante para os requisitos do operador de monitorização hidrológica.

O **dashboard de Indicadores Históricos** valida os requisitos associados à comparação entre locais, períodos e zonas de risco. Assim, ao utilizar indicadores agregados, permite reduzir a complexidade dos dados transacionais e disponibilizar métricas diretamente interpretáveis, alinhadas com as necessidades do coordenador operacional de risco.

O dashboard de Eventos de Cheia valida os requisitos associados à análise de episódios críticos, recorrência e comparação histórica. Assim, permite observar os eventos candidatos como entidades próprias, distinguindo-os das medições individuais e dos indicadores periódicos.

Em conjunto, os três dashboards implementados cobrem os principais níveis de análise definidos no modelo dimensional: medição, indicador agregado e evento candidato. Esta cobertura confirma a **coerência entre os requisitos levantados, o modelo dimensional, o povoamento da camada Gold e a componente de exploração em Power BI.**

7. Previsão de Cheias

A componente de previsão foi desenvolvida com o objetivo de explorar a capacidade dos dados integrados no armazém de suportarem modelos de antecipação de risco hidrológico a curto prazo. Esta fase utiliza um dataset analítico exportado da camada Gold, contendo medições, atributos temporais, informação sobre estação, localização, variável, níveis de alerta e variação entre medições consecutivas.

A previsão foi implementada em ambiente Jupyter/Python, permitindo documentar o processo de preparação dos dados, construção das variáveis explicativas, formulação do alvo, treino dos modelos e avaliação dos resultados. Esta abordagem é coerente com a componente de aquisição de conhecimento definida na arquitetura do sistema, na qual os dados consolidados no armazém são usados para experimentação analítica e desenvolvimento de modelos.

O ficheiro de entrada utilizado corresponde a uma exportação completa da camada Gold, contendo 264.134 registos. Destes, 263.785 correspondem a medições, 343 correspondem a indicadores agregados e 6 correspondem a eventos candidatos de cheia. Para a componente preditiva foram utilizados apenas os registos do tipo `MEDICAO`, uma vez que estes preservam a granularidade temporal necessária para criar variáveis de atraso, médias móveis e o alvo de previsão.

7.1 Definição do problema e compreensão dos elementos de análise envolvidos

O problema preditivo foi formulado como uma tarefa de classificação binária. O objetivo é prever se, para uma determinada estação e variável monitorizada, existirá uma situação de alerta nas 24 horas seguintes. Esta formulação permite distinguir a previsão de risco futuro da simples classificação do estado atual.

A variável alvo foi definida da seguinte forma:

Valor do alvo	Interpretação
`target_alerta_24h = 1`	Existe pelo menos uma medição futura com `nivel_alerta >= 1` nas próximas 24 horas, para a mesma estação e variável.
`target_alerta_24h = 0`	Não existe qualquer medição futura em alerta nas próximas 24 horas, para a mesma estação e variável.

A definição do alvo exclui a própria observação atual, considerando apenas medições futuras dentro do horizonte de 24 horas. Esta decisão evita que o modelo aprenda apenas a reproduzir a classificação corrente do nível de alerta, obrigando-o a utilizar atributos históricos, temporais e contextuais para antecipar situações futuras.

Foram consideradas duas experiências. A primeira experiência incluiu todas as variáveis monitorizadas: precipitação, nível hidrométrico e cota de albufeira. Esta experiência permitiu validar o processo de modelação e obter uma primeira referência de desempenho. No entanto, verificou-se que esta formulação misturava fenómenos de natureza distinta, uma vez que a precipitação representa sobretudo uma condição meteorológica antecedente, enquanto o nível hidrométrico e a cota de albufeira representam diretamente o estado hidrológico do sistema.

Por essa razão, foi definida uma segunda experiência, considerada a formulação final para o relatório. Nesta segunda experiência, a previsão foi restringida às variáveis hidrológicas `COTA_ALBUFEIRA` e `NIVEL_HIDROMETRICO`. Esta opção torna o problema mais alinhado com a

previsão de cheias, uma vez que o alvo passa a representar alerta futuro associado ao comportamento hidrológico do sistema.

7.2 Seleção e preparação dos dados

O dataset inicial utilizado na componente preditiva foi extraído da camada Gold e contém 263.785 registos de medições. Estes registos incluem observações hidrometeorológicas, atributos temporais, informação sobre estação, variável, localização, nível de alerta e variação entre medições consecutivas.

Antes da criação do alvo, os dados foram filtrados para manter apenas os registos do tipo `MEDICAO`. Como a exportação da Gold podia conter mais do que uma medição para a mesma combinação de estação, variável e instante temporal, foi realizada uma consolidação horária, garantindo uma linha por `codigo_estacao`, `tipo_variavel` e `id_tempo`. Nesta consolidação, o valor observado foi agregado pela média e o nível de alerta foi agregado pelo máximo, preservando a situação de maior criticidade observada em cada instante horário.

Após a criação da variável alvo futura a 24 horas, foram removidos os registos para os quais não existia horizonte futuro suficiente para calcular o alvo. O dataset de modelação da primeira experiência ficou com 204.268 registos. A distribuição do alvo evidenciou um forte desbalanceamento, com 189.385 registos negativos e 14.883 registos positivos, correspondendo a 92,71% sem alerta futuro e 7,29% com alerta futuro.

Classe	Nº registos	Percentagem
`target_alerta_24h = 0`	189.385	92,71%
`target_alerta_24h = 1`	14.883	7,29%

Na formulação final hidrológica foram selecionados apenas os registos associados às variáveis `COTA_ALBUFEIRA` e `NIVEL_HIDROMETRICO`. O dataset hidrológico ficou com 95.463 registos, dos quais 84.869 correspondem a ausência de alerta futuro e 10.594 correspondem a alerta futuro nas 24 horas seguintes. A percentagem de casos positivos nesta formulação é

de 11,10%, mantendo-se o problema desbalanceado, mas com maior concentração de casos relevantes para o domínio da previsão de cheias.

Classe	Nº registos	Percentagem
`target_alerta_24h = 0`	84.869	88,90%
`target_alerta_24h = 1`	10.594	11,10%

A preparação dos dados incluiu a conversão e validação do identificador temporal id_tempo, a reconstrução auxiliar da data e hora em ambiente Python a partir desse identificador, a normalização de colunas numéricas, a criação de atributos temporais adicionais e a criação de variáveis derivadas com base em valores passados.

Foram criadas variáveis temporais como dia do mês, dia da semana, indicação de fim de semana e representações cíclicas da hora e do mês. Para capturar dependências temporais, foram criados lags do valor observado a 1, 3, 6, 12 e 24 horas, bem como médias móveis e máximos móveis com janelas de 3, 6, 12 e 24 horas. Estas variáveis foram calculadas por par `codigo_estacao` e `tipo_variavel`, usando apenas informação passada, de modo a evitar fuga de informação futura.

Foram excluídas algumas colunas do conjunto de atributos explicativos. A coluna `nivel_alerta` foi excluída porque representa a classificação operacional do estado atual, calculada por limiares, e a sua utilização poderia levar o modelo a aprender diretamente a regra atual em vez de prever risco futuro. As colunas `target_alerta_24h` e `max_alerta_prox_24h` foram excluídas por conterem diretamente a informação alvo ou informação futura. Os indicadores mensais foram também excluídos da experiência principal para reduzir o risco de **data leakage**, uma vez que podem conter informação agregada do próprio mês em que a previsão está a ser feita.

A separação entre treino e teste foi realizada temporalmente. Os primeiros 80% do período foram usados para treino e os últimos 20% para teste. Esta decisão é mais adequada do que uma divisão aleatória, porque respeita a natureza temporal do problema e evita treinar modelos com informação posterior ao período de avaliação.

Importa referir que as variáveis de atraso e janelas móveis foram calculadas sobre a sequência ordenada das observações disponíveis após consolidação horária. Assim, em séries com falhas temporais, um atraso de 24 posições não corresponde necessariamente a exatamente 24 horas cronológicas contínuas. Esta limitação deve ser considerada na interpretação dos resultados, embora o identificador id_tempo tenha sido usado para preservar a ordenação temporal correta.

7.3 Identificação e fundamentação da técnica de análise

Foram testados quatro modelos de classificação binária: um modelo baseline, regressão logística, árvore de decisão e Random Forest. Esta escolha permitiu comparar uma referência simples com modelos de complexidade crescente.

O modelo baseline utiliza a classe maioritária e serve como referência mínima. Num problema desbalanceado, este modelo pode apresentar uma accuracy aparentemente aceitável, mas não identifica qualquer caso positivo. Por essa razão, não é suficiente avaliar apenas a accuracy. Foram utilizadas também precision, recall, F1-score, ROC-AUC e average precision.

A regressão logística foi incluída por ser um modelo simples, interpretável e adequado como primeira abordagem para classificação binária. A árvore de decisão foi incluída por permitir representar regras de decisão de forma mais intuitiva. A Random Forest foi incluída como modelo de ensemble, capaz de capturar relações não lineares e interações entre atributos, mantendo ainda a possibilidade de analisar importância de variáveis.

Dado o desbalanceamento do alvo, os modelos supervisionados foram configurados com ponderação das classes através de `class_weight="balanced"`. Esta opção penaliza mais os erros sobre a classe minoritária, incentivando o modelo a identificar casos de alerta futuro.

Modelo	Papel na análise
Baseline	Referência mínima baseada na classe maioritária. Permite verificar se os modelos supervisionados acrescentam valor real.
Regressão Logística	Modelo simples e interpretável para classificação binária, adequado como primeira abordagem.

Árvore de Decisão	Modelo baseado em regras, útil para interpretação e comparação com métodos lineares.
Random Forest	Modelo de ensemble com maior capacidade preditiva, adequado para capturar relações não lineares entre variáveis temporais, hidrológicas e territoriais.

7.4 Construção do modelo de previsão

A construção do modelo foi realizada através de um pipeline de machine learning em Python. O pipeline separa o pré-processamento dos dados da etapa de classificação, permitindo aplicar de forma consistente imputação, normalização e codificação de variáveis categóricas.

As variáveis numéricas foram tratadas com imputação pela mediana e normalização com `StandardScaler`. As variáveis categóricas foram tratadas com imputação pelo valor mais frequente e codificação **one-hot**, permitindo representar atributos como estação, variável e zona de risco de forma compatível com os modelos supervisionados.

Na experiência hidrológica foram treinados os seguintes modelos:

Baseline hidrológico baseado na classe maioritária; Regressão logística hidrológica; **Árvore de decisão hidrológica;** Random Forest hidrológica.

A Random Forest foi configurada com 100 árvores, profundidade máxima de 10, mínimo de 25 amostras por folha e ponderação automática das classes. Estes parâmetros procuram equilibrar capacidade preditiva e controlo de sobreajustamento.

A experiência 1, com todas as variáveis, foi mantida como referência exploratória. A experiência 2, limitada às variáveis hidrológicas, foi adotada como formulação final por estar mais alinhada com o objetivo de previsão de cheia.

As métricas apresentadas foram obtidas no ambiente Python usado na execução do notebook entregue, com dependências indicadas no ficheiro `requirements.txt`.

7.5 Validação do desempenho do modelo

A validação foi realizada sobre o conjunto de teste temporal, correspondente ao período final do histórico disponível. Na experiência hidrológica, o conjunto de teste contém 18.174 registos, dos quais 14.282 correspondem à classe negativa e 3.892 correspondem à classe positiva.

A tabela seguinte apresenta os resultados obtidos pelos modelos testados na experiência hidrológica.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	Average Precision
Random Forest hidrológica	0,9123	0,7511	0,8834	0,8119	0,9741	0,9484
Regressão Logística hidrológica	0,8905	0,6920	0,8805	0,7750	0,9605	0,9320
Árvore de Decisão hidrológica	0,8727	0,6467	0,8936	0,7504	0,9506	0,9227
Baseline hidrológico	0,7858	0,0000	0,0000	0,0000	0,5000	0,2142

Os resultados mostram que os modelos supervisionados superam claramente o baseline. O baseline apresenta accuracy de 0,7858, mas recall e F1 iguais a zero, porque nunca prevê a classe de alerta. Isto confirma que a accuracy isolada não é adequada para avaliar o problema.

A Random Forest hidrológica foi o modelo com melhor F1-score, atingindo 0,8119. O modelo apresentou ainda precision de 0,7511 e recall de 0,8834. O recall elevado é particularmente relevante neste domínio, uma vez que o custo de não identificar uma situação futura de alerta pode ser superior ao custo de gerar alguns falsos positivos.

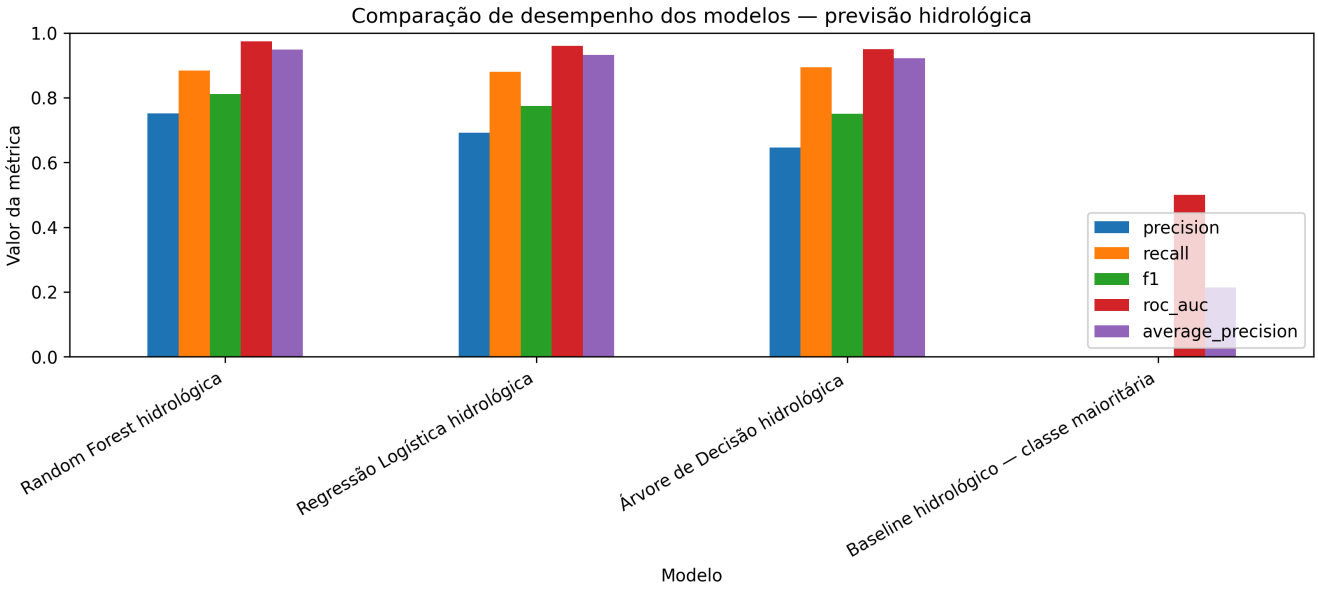


Figura 22: Comparação de desempenho dos modelos na experiência hidrológica

A matriz de confusão da Random Forest hidrológica permite analisar o tipo de erros cometidos. O modelo identificou corretamente 13.143 casos negativos e 3.438 casos positivos. Produziu 1.139 falsos positivos e 454 falsos negativos.

	Previsto: sem alerta	**Previsto: alerta**
Real: sem alerta	13.143	1.139
Real: alerta	454	3.438

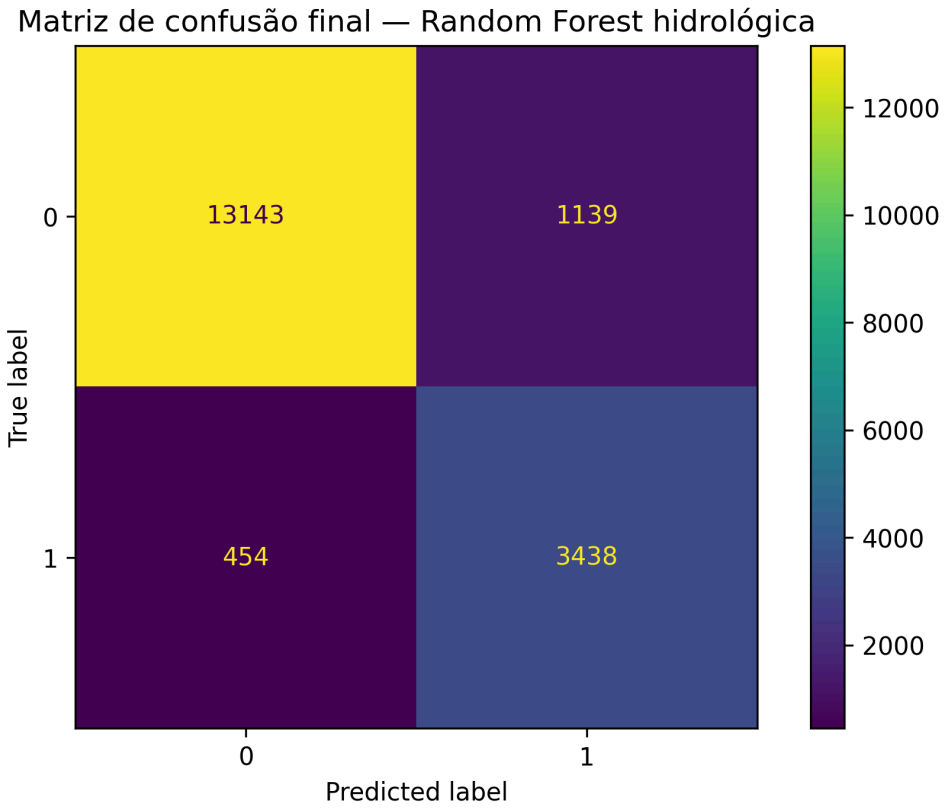


Figura 23: Matriz de confusão da Random Forest hidrológica

A avaliação por variável hidrológica revela diferenças importantes no comportamento do modelo. Para `COTA_ALBUFEIRA`, o desempenho foi quase perfeito, com F1-score de 0,9994. Para `NIVEL_HIDROMETRICO`, o desempenho foi mais moderado, com F1-score de 0,5675, precision de 0,4784 e recall de 0,6972.

Variável	Registos	Alertas reais	Accu-racy	Preci-sion	Recall	F1	ROC-AUC
`COTA_ALBUFEIRA`	2.467	2.396	0,9988	0,9992	0,9996	0,9994	1,0000
`NIVEL_HIDROMETRICO`	15.707	1.496	0,8988	0,4784	0,6972	0,5675	0,9325

Esta análise por variável é essencial para interpretar corretamente os resultados. O desempenho global da Random Forest é forte, mas é influenciado pela elevada previsibilidade da variável `COTA_ALBUFEIRA`. O caso do `NIVEL_HIDROMETRICO` é mais exigente e apresenta maior margem de melhoria.

7.6 Avaliação dos resultados

Os resultados obtidos mostram que os dados integrados no sistema têm utilidade para a previsão de alerta hidrológico a curto prazo. A Random Forest hidrológica foi o modelo com melhor equilíbrio global entre precision e recall, atingindo F1-score de 0,8119 e recall de 0,8834. Isto significa que o modelo conseguiu identificar a maioria dos casos positivos no conjunto de teste, o que é relevante num contexto de monitorização de risco.

A comparação com o baseline confirma que a modelação acrescenta valor. Embora o baseline apresente accuracy de 0,7858, não identifica nenhum alerta futuro, o que o torna inútil para o objetivo do sistema. Os modelos supervisionados, pelo contrário, conseguem detetar uma proporção significativa de situações futuras de alerta, justificando a utilização de técnicas preditivas sobre os dados do armazém.

A opção pela experiência hidrológica como formulação final também se revelou adequada. A primeira experiência, com todas as variáveis, obteve F1-score de 0,7292 na Random Forest. A experiência hidrológica melhorou o F1-score para 0,8119, além de apresentar melhor precision, melhor ROC-AUC e melhor average precision. Esta melhoria reforça a decisão de restringir o alvo final às variáveis diretamente associadas ao estado hidrológico do sistema.

Experiência	Melhor modelo	Precision	Recall	F1
Todas as variáveis	Random Forest	0,6326	0,8606	0,7292
Variáveis hidrológicas	Random Forest hidrológica	0,7511	0,8834	0,8119

A análise da importância das variáveis permite ainda interpretar parcialmente o comportamento da Random Forest. As features mais relevantes estão associadas a valores observados recentes, máximos móveis, médias móveis e atributos contextuais relacionados com a estação e a variável. Isto é coerente com o domínio do problema, uma vez que a evolução recente do nível ou da cota é um sinal importante para antecipar situações futuras de alerta.

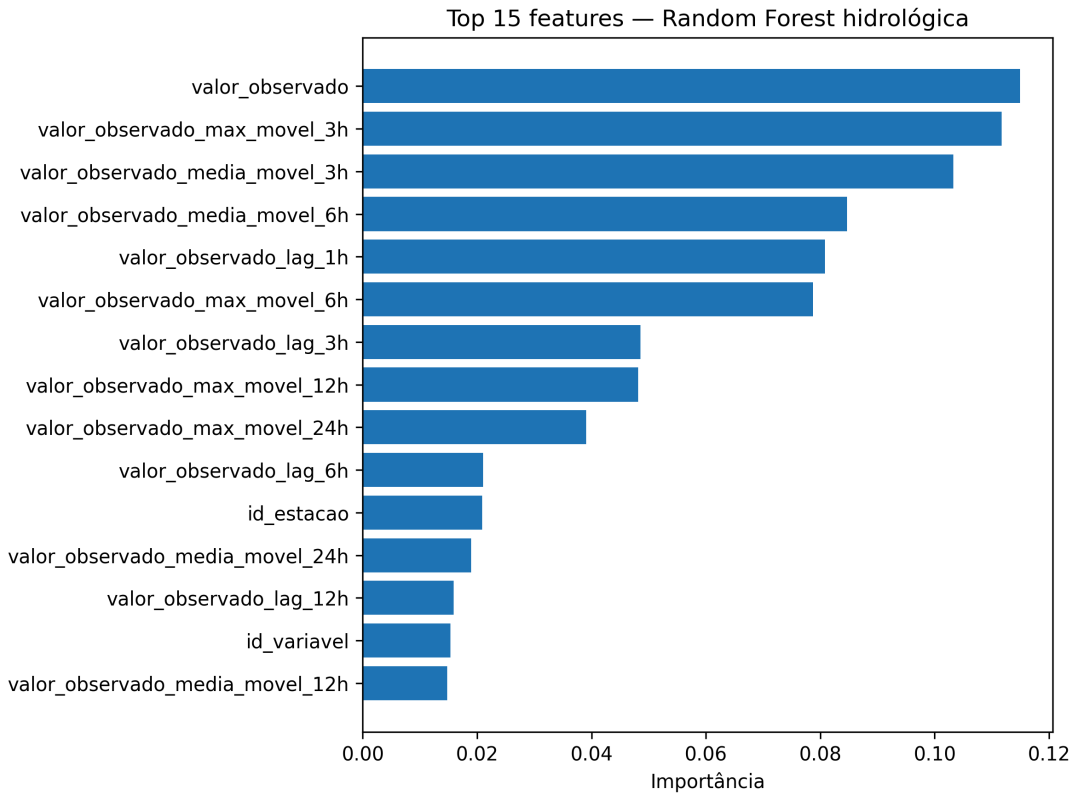


Figura 24: Importância das variáveis na Random Forest hidrológica

Apesar dos resultados positivos, a componente preditiva deve ser interpretada como uma prova de conceito analítica e não como um sistema operacional pronto para produção. Existem limitações relevantes. Em primeiro lugar, o conjunto de dados está desbalanceado, o que exige cuidado na interpretação das métricas. Em segundo lugar, os resultados por variável mostram desempenho desigual, especialmente no caso do nível hidrométrico. Em terceiro lugar, o modelo não integra previsões meteorológicas externas, como dados previstos de precipitação, que seriam relevantes para antecipação real de risco. Em quarto lugar, os limiares de alerta utilizados são operacionais e exemplificativos, devendo ser validados por entidades especializadas antes de qualquer utilização real.

Como trabalho futuro, a componente preditiva poderá ser melhorada através da integração de dados meteorológicos previstos, da validação dos eventos candidatos com registos históricos oficiais, da calibração de limiares por estação, da criação de variáveis hidrológicas adicionais e da persistência das previsões numa tabela própria da camada Gold ou Serving.

Essa tabela deveria incluir metadados como versão do modelo, data de geração da previsão, horizonte temporal, probabilidade prevista e classificação final de risco.

Em síntese, a secção de previsão demonstra que o sistema de data warehousing desenvolvido não se limita à visualização de dados históricos. Os dados integrados, preparados e estruturados no armazém permitem também suportar processos de aquisição de conhecimento e previsão, fechando o ciclo analítico proposto para o sistema HidroVigilância.

8. Conclusões e Trabalho Futuro

8.1 Conclusões

O trabalho desenvolvido permitiu conceber e implementar um sistema de suporte à decisão para monitorização e previsão de cheias na bacia do rio Mondego, recorrendo a uma abordagem de data lakehouse e a técnicas de modelação dimensional. A solução resultante integra dados hidrometeorológicos, organiza-os em camadas de processamento e disponibiliza uma camada Gold orientada à exploração analítica, visualização e aquisição de conhecimento.

A definição inicial do sistema permitiu enquadrar o problema de decisão e identificar as necessidades dos principais perfis de utilização: operador de monitorização hidrológica, coordenador operacional de risco e analista de risco e planeamento. A partir destes perfis foram levantados e validados requisitos de decisão, funcionais e não funcionais, que serviram de base à modelação dimensional e à definição dos serviços analíticos implementados.

O modelo dimensional desenvolvido revelou-se adequado ao domínio do problema. A estrutura em constelação, composta pelas tabelas `Fact_Medicoes`, `Fact_Indicadores` e `Fact_Evento_Cheia`, permitiu representar três níveis complementares de análise: a medição individual, o indicador agregado e o evento candidato de cheia. As dimensões `Dim_Tempo`, `Dim_Estacao`, `Dim_Localizacao`, `Dim_Variavel` e `Dim_TipoEvento` permitiram contextualizar os factos segundo perspetivas temporais, operacionais, territoriais e hidrometeorológicas.

O sistema de povoamento implementado permitiu operacionalizar a passagem dos dados pelas camadas Bronze, Silver e Gold. A camada Bronze preserva os dados de origem, a camada Silver aplica normalização, limpeza e enriquecimento, e a camada Gold materializa o modelo dimensional final. A validação realizada confirmou o carregamento das principais estruturas analíticas, incluindo 263.785 medições, 343 indicadores agregados e 6 eventos candidatos de cheia.

A componente de exploração e análise em Power BI demonstrou a utilidade prática da camada Gold. Foram desenvolvidas três vistas analíticas complementares: monitorização

operacional, indicadores históricos e eventos de cheia. Estas vistas permitem consultar medições, comparar indicadores agregados e analisar episódios críticos, mantendo coerência com os requisitos definidos e com o modelo dimensional implementado.

A componente de previsão permitiu demonstrar que os dados estruturados no armazém podem também suportar processos de aquisição de conhecimento. O problema foi formulado como uma tarefa de classificação binária para previsão de alerta hidrológico nas 24 horas seguintes. A experiência final, restringida às variáveis hidrológicas `COTA_ALBUFEIRA` e `NIVEL_HIDROMETRICO`, obteve o melhor desempenho com uma Random Forest, atingindo F1-score de 0,8119 e recall de 0,8834. Estes resultados indicam que a informação histórica e temporal preservada no armazém possui valor para antecipação de situações de alerta a curto prazo.

Em síntese, o projeto concretiza um ciclo analítico completo: integração de dados, modelação dimensional, povoamento, validação, exploração visual e previsão. Apesar das limitações identificadas, a solução desenvolvida demonstra a viabilidade de utilizar sistemas de data warehousing para apoiar a monitorização, análise histórica e previsão de risco de cheia.

8.2 Trabalho Futuro

Como trabalho futuro, a solução poderá ser evoluída através da integração de novas fontes de dados, como previsões meteorológicas do IPMA, informação geográfica mais detalhada do SNIAmb e registos oficiais de ocorrências de cheia. Estas fontes permitiriam enriquecer a análise territorial, validar os eventos candidatos identificados no ETL e melhorar a capacidade preditiva do sistema.

Outra evolução relevante passa pela calibração dos limiares de alerta por estação, variável e contexto hidrológico. Esta melhoria permitiria refletir diferenças locais entre estações, zonas de montante, zonas de jusante e albufeiras, tornando a classificação de criticidade mais próxima da realidade operacional.

A componente preditiva também poderá ser reforçada com novas variáveis explicativas, horizontes temporais alternativos e técnicas de validação adicionais. A integração de precipitação prevista, acumulados antecedentes, variáveis espaciais e relações entre montante e jusante poderá melhorar especialmente a previsão de `NIVEL_HIDROMETRICO`, onde os resultados foram mais moderados. Numa fase posterior, as previsões poderiam ser persistidas numa tabela própria da camada Gold ou numa camada Serving, permitindo a sua disponibilização direta nos dashboards.

Por fim, a solução poderá evoluir para um ambiente operacional mais automatizado, com atualização periódica dos dados, controlo de qualidade contínuo, monitorização dos processos ETL e mecanismos de alerta associados aos dashboards. Esta evolução aproximaria o protótipo desenvolvido de um sistema de suporte à decisão utilizável em contexto real.

Bibliografia

[1] Golfarelli, M., Maio, D., & Rizzi, S. (1998). **The Dimensional Fact Model: A Conceptual Model for Data Warehouses**. International Journal of Cooperative Information Systems, 7(2–3), 215–247.

[2] Kimball, R., & Ross, M. (2013). **The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling**. 3rd Edition. Wiley.

[3] Inmon, W. H. (2005). **Building the Data Warehouse**. 4th Edition. Wiley.

[4] Microsoft. (2025). **SQL Server Integration Services documentation**. Microsoft Learn. Disponível em: https://learn.microsoft.com/en-us/sql/integration-services/sql-server-integration-services

[5] Microsoft. (2025). **SQL Server documentation**. Microsoft Learn. Disponível em: https://learn.microsoft.com/en-us/sql/sql-server

[6] Microsoft. (2025). **Power BI documentation**. Microsoft Learn. Disponível em: https://learn.microsoft.com/en-us/power-bi/

[7] Agência Portuguesa do Ambiente. (2025). **Sistema Nacional de Informação de Recursos Hídricos**. Disponível em: https://snirh.apambiente.pt/

[8] Agência Portuguesa do Ambiente. (2025). **Sistema Nacional de Informação de Ambiente**. Disponível em: https://sniamb.apambiente.pt/

[9] Instituto Português do Mar e da Atmosfera. (2025). **IPMA: Informação meteorológica e climática**. Disponível em: https://www.ipma.pt/

[10] The pandas development team. (2025). **pandas documentation**. Disponível em: https://pandas.pydata.org/docs/

[11] scikit-learn developers. (2025). **scikit-learn: Machine Learning in Python**. Disponível em: https://scikit-learn.org/stable/

[12] Hunter, J. D. (2007). **Matplotlib: A 2D Graphics Environment**. Computing in Science & Engineering, 9(3), 90–95.

Lista de Siglas e Acrónimos

Sigla	Significado
APA	Agência Portuguesa do Ambiente
BI	Business Intelligence
CSV	Comma-Separated Values
DFM	Dimensional Fact Model
DW	Data Warehouse
ETL	Extract, Transform and Load
FK	Foreign Key
IPMA	Instituto Português do Mar e da Atmosfera
KPI	Key Performance Indicator
ML	Machine Learning
PK	Primary Key
RD	Requisito de Decisão
RF	Requisito Funcional
RNF	Requisito Não Funcional
ROC-AUC	Receiver Operating Characteristic - Area Under the Curve
SNIAmb	Sistema Nacional de Informação de Ambiente
SNIRH	Sistema Nacional de Informação de Recursos Hídricos
SQL	Structured Query Language
SSIS	SQL Server Integration Services